啤酒化学数据与感官评分

摘要

本文基于一份含 250 款商用啤酒的化学与感官数据集，完成三项任务：由化学特征预测 50 个感官维度的 0 到 6 等级，找出每个感官维度的关键化合物，以及生成指定风格的化合物谱并完成跨风格迁移。

针对问题一，本文以作者公布的逐品评员原始评分的啤酒均分为训练目标、以均分取整为 0 到 6 级真值，不依赖附件四的标准化换算。用浅层梯度提升树逐维拟合化学特征到均分的映射，按 25 个日期组分组的嵌套交叉验证评估，再由内层折外残差构造等级预测分布，以分布中位数为主要输出、分位数切点为第二输出。主模型等级平均绝对误差为 0.479，显著低于只知风格的基线 0.527（配对差 -0.048，95% 置信区间 $[-0.062, -0.034]$），二次加权 Kappa 为 0.290，90% 等级区间覆盖 97.2%。只用附件还原等级的对照端到端平均绝对误差为 0.786，说明标准化换算本身是主要误差来源。

针对问题二，本文以附件二构建化合物共表达图，在阈值 0.6 下用平均连接层次聚类划分模块，再用图约束前向选择逐个取出控制已选化合物后的秩偏相关最强、且分属不同模块的 3 个化合物。显著性由置换检验把关，稳定性由 25 个日期组重抽 1,000 次量化。49 个维度中 A 级 26 个、B 级 22 个、C 级 1 个，多数维度可靠支持的关键化合物为 1 到 2 个。加标实验一致支持酯类作为酯类维度的关键因素，酒花与苦味对照不变，构成独立的因果证据。

针对问题三，本文对化学数据做秩变换，用风格条件潜在高斯模型刻画化合物谱，以因子载荷与共表达模块块描述风格内共变，再经问题一模型给出感官画像。跨风格迁移采用潜空间平移，配合化学层缺陷约束的投影与感官层的路径搜索，并做原尺度复查，保证缺陷化合物不恶化。问题三的正式结果尚未交付，正文结果以占位方式呈现。

三个问题共享同一批啤酒与化学特征，问题一的折外预测与问题二的共表达模块分别作为问题三感官画像与生成模型的输入，形成完整的方法链条。

关键词：啤酒风味；感官评分预测；梯度提升树；化合物共表达网络；秩变换；条件生成模型；跨风格迁移

目录

1 问题重述与分析 **2**

1.1 问题背景 2

1.2 三个问题的估计目标 2

1.3 问题间接口 2

1.4 三个问题的难点 3

2 模型假设与符号 **4**

2.1 全局假设 4

2.2 共用符号 6

3 数据预处理 **6**

3.1 数据来源、样本对齐与感官目标 6

3.2 化学特征的尺度与缺失 8

3.3 三项任务的数据表示与验证单位 9

4 问题一：缺失数据下的感官评分 **11**

4.1 问题分析 11

4.2 模型建立 11

4.2.1 化学特征到品评小组均分的连续模型 11

4.2.2 0 到 6 等级输出 12

4.3 实验设计 13

4.4 结果 15

4.4.1 主结果与关键对照 15

4.4.2 等级规则 16

4.4.3 逐维增益与可预测性 16

4.4.4 误差集中的等级 17

4.4.5 交付评分示例 18

4.4.6 文字报告 18

5 问题二：化合物共表达图与感官维度的关键化合物 19

5.1 问题分析 19

5.2 模型建立 19

5.2.1 候选集合 19

5.2.2 共表达图与模块 20

5.2.3 图约束前向选择 20

5.2.4 显著性门槛 21

5.3 实验设计 22

5.4 结果 24

5.4.1 找回率 24

5.4.2 共表达网络 24

5.4.3 稳定性 25

5.4.4 方法间一致性与风格内关联 26

5.4.5 代表维度证据 28

5.4.6 加标核验 29

5.4.7 文字报告 29

6 问题三：风格条件化合物谱生成与跨风格迁移 30

6.1 问题分析 30

6.2 模型建立 30

6.2.1 秩变换与潜变量 30

6.2.2 风格条件潜在高斯模型 31

6.2.3 感官画像与风味指纹 31

6.2.4 跨风格迁移四步 31

6.3 实验设计 33

6.4 结果 35

6.4.1 生成器验证 35

6.4.2 化学指纹与生成谱 35

6.4.3 感官画像 36

6.4.4 迁移的代价与收益 37
6.4.5 风格对热图 38
6.4.6 文字报告 39

7 模型评价与推广 **39**

7.1 优势 41
7.2 不足 41

1 问题重述与分析

1.1 问题背景

赛题提供一份商用啤酒风味数据集，包含八份附件。附件一记录 250 款啤酒的 231 个化学与理化特征，附件二给出这些特征两两之间的相关系数矩阵。附件三定义感官记分卡，附件四给出 250 款啤酒在 50 个感官维度上的标准化品评小组均值。附件八补充部分化合物的校准浓度、气味阈值、来源标签与缺陷描述。这些附件对应 Schreurs 等人在 *Nature Communications* 发表的数据记录，作者在同一数据记录的新版中另行公布了逐品评员、逐啤酒的原始 0 到 6 分评分，覆盖相同的 250 款啤酒，是三个问题的感官数据来源。

赛题要求完成三项任务。问题一以化学数据预测啤酒的感官评分，问题二找出每个感官维度的关键化合物，问题三生成指定风格的一款啤酒在各化学特征上的取值向量，即化合物谱，并进行跨风格迁移。三项任务共享同一批啤酒与化学特征，但估计目标、验证单位与交付物不同。本文把三项任务各自的估计目标、使用数据、交付物与验证判据列成一张接口表，后续各章按此表展开。

1.2 三个问题的估计目标

问题一的估计目标是品评小组等级。对啤酒 b（$b = 1, \ldots, 250$）与感官维度 d（$d = 1, \ldots, 50$），把该啤酒该维度的全部原始评分记录取算术平均得到 $\bar{x}_{bd}$，再截断到 0 到 6 并四舍五入，得到 0 到 6 的等级 G_{bd}。问题一从化学特征预测这一等级，交付每款啤酒每个维度的预测等级、等级概率与 90% 等级区间。

问题二的估计目标是每个感官维度上关联最强的三个化合物。第 1 位取与维度秩相关最强的化合物，第 2、3 位在控制已选化合物之后取秩偏相关最强、且不属于已选化合物所在共表达模块的化合物。这一目标把关键化合物定义为关联结果，而不是因果结果，附件中没有干预数据，化学合理性在结果产生后另行解释。

问题三的估计目标有三项。第一项是风格条件分布，即给定细分风格后 225 个生成列的联合分布。第二项是感官画像，即由该分布生成的化合物谱经问题一模型得到的 50 维等级分布。第三项是迁移映射，即把一种风格的化合物谱改为另一种风格，同时满足化学层与感官层两层缺陷约束。

1.3 问题间接口

三个问题按接口表的顺序衔接。问题一以取整等级 G_{bd} 为目标，其折外预测与残差池供问题三构造感官画像与迁移约束，折外预测指该啤酒不参与所用模型训练时得到的

预测。问题二的共表达模块交给问题三，作为生成模型中化合物共变的结构先验，其缺陷维度的关键化合物用于解释迁移结果。问题一与问题二都按 25 个日期组划分交叉验证，保证同一天品评的啤酒不横跨训练集与测试集。

表 1: 三个问题的接口

问题	估计目标	使用数据	交付物	验证单位与判据
一	品评小组原始均分取整后的 0–6 等级 G_{bd}	附件一 231 个化学特征；原始评分作为训练目标与真值	250 款 × 50 维的预测等级、等级概率与 90% 等级区间	等级 MAE、QWK、完全一致率与 ±1 内比例，按折外预测计算
二	控制已选化合物后秩关联最强、且分属不同模块的 3 个化合物	附件二的共表达关系；附件一的 225 个候选；原始评分均分的秩	49 个维度 × 3 名的关键化合物、稳定性分档与化学解释	置换检验显著性、日期组重抽入选频率、方法间 Jaccard、加标实验
三	风格条件分布、感官画像、满足两层缺陷约束的迁移映射	附件一的 225 个生成列；细分风格标签；问题一模型与问题二模块	22 个风格各 1,000 个化合物谱及画像；Pils/Lager 到 Tripel 的逐款迁移	生成保真、新颖性与迁移约束违约率

表 1 中 MAE 为平均绝对误差，QWK 为二次加权 Kappa，Jaccard 为两个集合交集与并集大小之比。问题二的 49 个维度是 50 个感官维度排除与 stale_hops 重复的 barnyard 后得到的。问题三的 225 个生成列是 231 个特征排除 5 个综合指标与 1 个内标后得到的。

1.4 三个问题的难点

问题一的难点有两层。第一层是附件一的化学数据有缺失值，第二层是待评分的新啤酒没有任何品评记录，评分只能由化学数据预测。感官评分本身含品评员之间的系统差异与随机噪声，同一天品评的啤酒共享出席名单与品评情境，不能当作相互独立的样本。因此问题一既要处理化学缺失，又要用按日期组分组的嵌套交叉验证控制同日信息泄漏。

问题二的难点在于把关联证据与因果主张分开。附件二只在全部 250 款啤酒上估计了两两相关，风格之间的配方差异会与风格内的共变混在一起。同一模块内的化合物高度相关，边际关联最强的几个化合物往往来自同一模块，直接取前 3 会重复选择同一条

信息。因此问题二需要先用模拟还原实验确定选择规则，再用日期组重抽量化入选频率。

问题三的难点在于样本量与维度之比。22 个细分风格中每个只有 3 到 31 款啤酒，少于 225 个生成列，风格专属的完整协方差不可估计。生成结果既要落在观测范围内，又要让风格判别器无法区分生成样本与真实啤酒，还不能只是复制训练啤酒。迁移时题面要求缺陷化合物不恶化，需要把这一要求写成可检验的约束，并在潜空间与原始尺度两处复查。

2 模型假设与符号

2.1 全局假设

本节只列出约束整个问题的数据、范围与环境的假设。与方法绑定的局部假设在引入该方法的一节说明，本节不重复。每条假设说明假设了什么、为何合理，以及对模型的影响。

表 2: 全局假设

假设	理由	对模型的影响
样本对齐以行号为准	原始评分文件中的编号对应附件一、四的行号，按行号对齐时逐维 Spearman 中位数为 0.969，按附件列对齐为 −0.010	所有连接都按行号，交叉验证分组与感官目标随之对齐
未校准信号列按 $\log_{10}$ 相对峰面积解释	157 个色谱质谱列没有绝对浓度校准数据，无法逐列证实底数	梯度提升树模型直接使用发布值，其分裂顺序不受底数选择影响；需要浓度时用 10^x 还原
共同下限按未检出状态处理	142 列共 6,807 个单元等于共同下限 −1.81781854，现有材料不能确认仪器检出限	树模型把该值作为最低秩，线性模型加逐列下限指示变量
化学缺失值以训练折列均值填充	缺失只有 73 个单元，删去含缺失啤酒会损失 25.2% 的样本	填充值只作计算占位，不解释为真实零或未检出
感官目标为当次出席品评员的平均分	加性模型中出席名单带来的偏移占啤酒间方差的中位数只有 2.2%	目标不校正出席名单差异，敏感性分析另行检验
细分风格标签准确	赛题以该标签作为问题三的条件变量	生成器按标签学习风格条件分布，不合并相近风格
文献气味阈值在啤酒基质中成立	阈值取自附件八的感官阈值	只有气味活度值的计算与迁移阈值依赖该假设

表 2 中的样本对齐与化学尺度两条属于数据审计的结论，其余属于建模选择。数据审计得到的其他发现，包括样本量、缺失分布与附件一和附件八的冲突，在第 3 章报告，不属于假设。

2.2 共用符号

跨问题共用的符号列于表 3。方法局部的符号在引入它们的一节定义，不在此列出。所有符号首次出现时给出定义，全文保持一致。

表 3: 共用符号

符号	含义	单位
b	啤酒索引，$b = 1, \ldots, 250$	无
d	感官维度，附件四的 50 列之一，$d = 1, \ldots, 50$	无
X_b	啤酒 b 的化学特征，即附件一的 231 列	混合，见数据审计
$\bar{x}_{bd}$	啤酒 b 在维度 d 上的品评小组原始评分均值	0–6 分
z_{bd}	附件四标准化后的品评小组评分	以每位品评员标准差为单位
$s(b)$	啤酒 b 的细分风格标签，共 22 类	无

$\bar{x}_{bd}$ 是问题一与问题二的感官目标，也是问题三感官画像的观测真值。z_{bd} 是 $\bar{x}_{bd}$ 的确定性标准化，按品评员与维度标准化后再对小组取平均，去掉 0 到 6 量表的均值与标准差，只在数据核对、仅用附件的对照与问题二的敏感性分析中使用。$s(b)$ 是问题三的条件变量，也是问题一基线所要超越的信息来源。

3 数据预处理

本研究先确定样本、变量和评分的含义，再分别构造三个问题的输入。化学缺失值填充属于特征预处理；没有品评记录的新啤酒的评分则属于问题一的预测任务。凡涉及模型拟合的变换均在训练折内估计，再作用于验证折。

3.1 数据来源、样本对齐与感官目标

附件 1 含 250 款啤酒、231 个化学及理化特征；赛题描述中的 226 个参数是化学参数数量，不是样本量，样本量以附件实测行数为准。附件 2 为这些特征的相关矩阵，附件 3 定义感官记分卡，附件 4 给出 250 款啤酒的 50 维标准化品评小组均值。附件 8 提供部分化合物的校准浓度、气味阈值及来源标签。附件 5、6 只作相关结构核对，附件 7 为另一套描述符，不与附件 3 的 50 维评分合并。

表 4 汇总数据核验结果，逐项列出核验方法、结果与处理。

表 4: 数据核验

核验项	方法	结果	处理
样本数	附件 1、4、7 核对	均为 250 个唯一啤酒，行序与风格标签一致	赛题描述的 226 是化学参数数量
条形码	按保留约 6 位有效数字模拟附件 1 导出	250 条全部一致	按行号连接，不按编号连接
附件 2 类型	逐对有效样本复算	Spearman 最大误差 6.67×10^{-16}，Pearson 平均绝对误差 0.088	只作图的边权，不作协方差
变换底数	与附件 8 校准数据比较	37 列对数、33 列线性	结论见表 6
缺失	逐单元检查	附件 1 有 73 个空值，附件 7 有 3 列全空，附件 4 无缺失	列均值填充
共同下限	逐单元检查	142 列共 6807 个单元等于 -1.81781854	按未检出状态处理
附件 1 与 8 冲突	逐单元格比较	24 款啤酒的 80 个单元格	以附件 1 为准
原始评分对齐	按行号与按编号列分别对齐	行号逐维 Spearman 中位数 0.969，编号列为 -0.010	按行号对齐

附件 1–8 与 Schreurs 等人在 *Nature Communications* 发表的数据记录（Zenodo 10653704）对应。作者后来在同一数据记录的新版（Zenodo 23624915）公布逐品评员原始评分，覆盖相同的 250 款啤酒。该文件在赛题发布后公布，本文明确披露其来源；问题一另设仅使用附件的完整对照，以展示没有该文件时的结果。

原始评分共 2197 条记录，来自 16 名品评员和 37 个品评日期；50 个维度均为 0–6 的整数且无缺失。原始文件中的 `beer_name` 对应附件 1、4 的行号，并非附件的 `beer` 列。以行号对齐后，原始品评小组均分与附件 4 逐维 Spearman 相关系数的中位数为 0.969；错误地按 `beer` 列对齐时为 -0.010。因此对齐检查先于任何建模。

设 $\mathcal{R}_b$ 为啤酒 b 的全部原始评分记录，x_{id} 为记录 i 在感官维度 d 的分数，则

$$\bar{x}_{bd}=\frac{1}{|\mathcal{R}_b|}\sum_{i\in\mathcal{R}_b}x_{id},\qquad G_{bd}=\lfloor\min\{6,\max\{0,\bar{x}_{bd}\}\}+0.5\rfloor\,. \tag{1}$$

同一啤酒即使在多个日期接受品评，也只形成一个啤酒层面的目标。附件 3 汇总表与原

始记录共有 50 个可用维度；模板中另有乙醛属性，但原始评分和附件 4 均无对应列，故不生成该属性的预测。

附件 4 是原始评分按“品评员 × 维度”标准化后再按啤酒汇总的结果。按这一规则可在 12500 个单元中复现 11274 个（90.2%，误差中位数 2.8×10^{-10}）。其余单元集中于 12 个维度，涉及标准差为零的品评员–维度组合，发布数据中的处理常数尚未识别。标准化去掉了原始 0–6 量表的位置和尺度，仅凭附件 4 不能唯一恢复原始等级。因此主分析直接以式 (1)为目标；附件 4 只用于数据核对、仅用附件的对照和问题二的敏感性分析。

只用附件时，能还原多少原始等级，由表 5 给出，以原始等级 G 为真值。零点还原分局部零点与线性参照两行。局部零点在品评团内以出现至少两次的最小标准化值为零点，线性参照用训练折标准化值的最小与最大端点线性映射到 0–6。合计行把有有效零点的单元格用局部零点、其余用线性参照。

表 5: 感官目标与只用附件的零点还原

还原方式	单元数	等级完全一致率	±1 内比例	等级 MAE	平均偏差
局部零点	约 3828（30.6%）	88.5%	99.5%	0.120	−0.09
线性参照	约 8672	51.9%	93.4%	0.559	+0.46
合计	12500	63.1%	95.3%	0.425	+0.29

表 5 说明，只用附件时约三分之一的单元格能定位零点并基本还原，其余单元格系统性偏高约半级。因此主线以原始评分为目标，用附件的完整方案 C1 作为问题一的对照，问题一不再复述这一论证，只引用本表。

3.2 化学特征的尺度与缺失

附件 1 的 231 列不能一律解释为浓度。将其中可对齐的 70 列与附件 8 的校准数据逐列比较，37 列在正浓度处满足 $x = \log_{10} c$，33 列在列级中位残差意义下保持线性尺度。后者仍有 80 个单元与附件 8 不一致，分布于 24 款啤酒；主分析以附件 1 为准，附件 8 替换值只作敏感性运行。其余 157 列是未经绝对浓度校准的气相色谱–质谱信号，另有 4 列为 `_sum` 综合指标。表 6 给出四类变量的处理。

对 37 个已校准对数列，$x < 0$ 只表示 $0 < c < 1$ 个该列的计量单位，并非负浓度。对 157 个未校准信号列，将其按常用对数相对峰面积解释是*尺度假设*，不是从附件逐列证实的事实；不能用 10^x 声称恢复绝对浓度。主树模型直接使用发布值，不再取一次对数。单调尺度变换不改变树的分裂顺序。

表 6: 附件 1 化学及理化特征的尺度判定与使用口径

类别	列数	证据与解释	建模处理
校准对数列	37	$\lvert x - \log_{10} c\rvert$ 的逐列中位数小于 10^{-6}；自然对数不符	需要浓度时用 10^x
校准线性列	33	$\lvert x - c\rvert$ 的逐列中位数小于 10^{-6}，但部分单元不一致	保留附件 1 原值
未校准色谱–质谱信号	157	无逐列底数和绝对浓度证据；共同下限按未检出状态解释	保留发布值及其秩
综合指标	4	组成与计算公式未提供	保留特征，不反变换

表注：*kcalperc* 属于 37 个对数列，但它是赛题所列五个综合属性之一，问题二、问题三与 4 个以 `_sum` 结尾的列一并按综合指标排除，因此后文写 5 个综合指标。

附件 1 的 $250 \times 231 = 57750$ 个特征单元有 73 个空值（0.126%），集中于 9 列和 63 款啤酒；删去这些啤酒将损失 25.2% 的样本。附件 8 在 8 个单化合物的 60 个空值位置记录为零，但跨附件的编码差异不足以证明这些空值必然低于检出限。主设定逐列使用训练折非缺失观测的均值填充，作为计算占位值，不赋予其真实浓度含义。内层与外层交叉验证均独立计算填充值。以训练折中位数加缺失指示、模型原生缺失路由，以及单化合物最低位编码作为敏感性对照。

另有 142 个未校准信号列共享下限 -1.81781854，涉及 6807 个单元。本文把该值作为未检出状态并赋予最低秩；现有材料不能确认其仪器检出限或替代流程，因此不把它解释成精确峰面积。极端化学取值和罕见的感官高分均保留原值，不以箱线图规则删除。对异常值的敏感性在具体模型中检验，避免预处理阶段先行抹去可能有意义的风味差异。

3.3 三项任务的数据表示与验证单位

问题一以 231 个特征预测式 (1)的品评小组均分，再由预测分布得到 0–6 等级。37 个品评日期因 12 款跨日期品评的啤酒相连，合并成 25 个日期组；交叉验证按日期组隔离，同一日期的品评情境不跨训练与测试两侧。

问题二将 231 列中的 5 个综合指标和 1 个内标排除，留下 225 个单体化合物候选。附件 2 提供共表达关系；化学特征及 $\bar{x}_{bd}$ 均转为秩，以免不同单位和尾部取值支配关联。`barnyard` 与 `stale_hops` 的原始记录有 99.4% 相同：前者仍可预测，但不单独做化合物归因。稳定性重抽以 25 个日期组为单位。

问题三以同一 225 列建立风格条件生成模型。未检出下限视为并列的离散状态，变换及反变换均在训练折内确定；综合指标由生成化合物另行派生，内标不作为生成对象。风格条件来自附件的细分风格标签。生成器用按风格分层的留出啤酒验证化学分布；涉及感官画像时另用问题一的日期组划分，避免借助同一品评情境评估自身。

图 1 汇总了数据核验、尺度处理与三个问题的接口。图中的数量是数据检查结果，模型效果由各问题的留出实验另行报告。

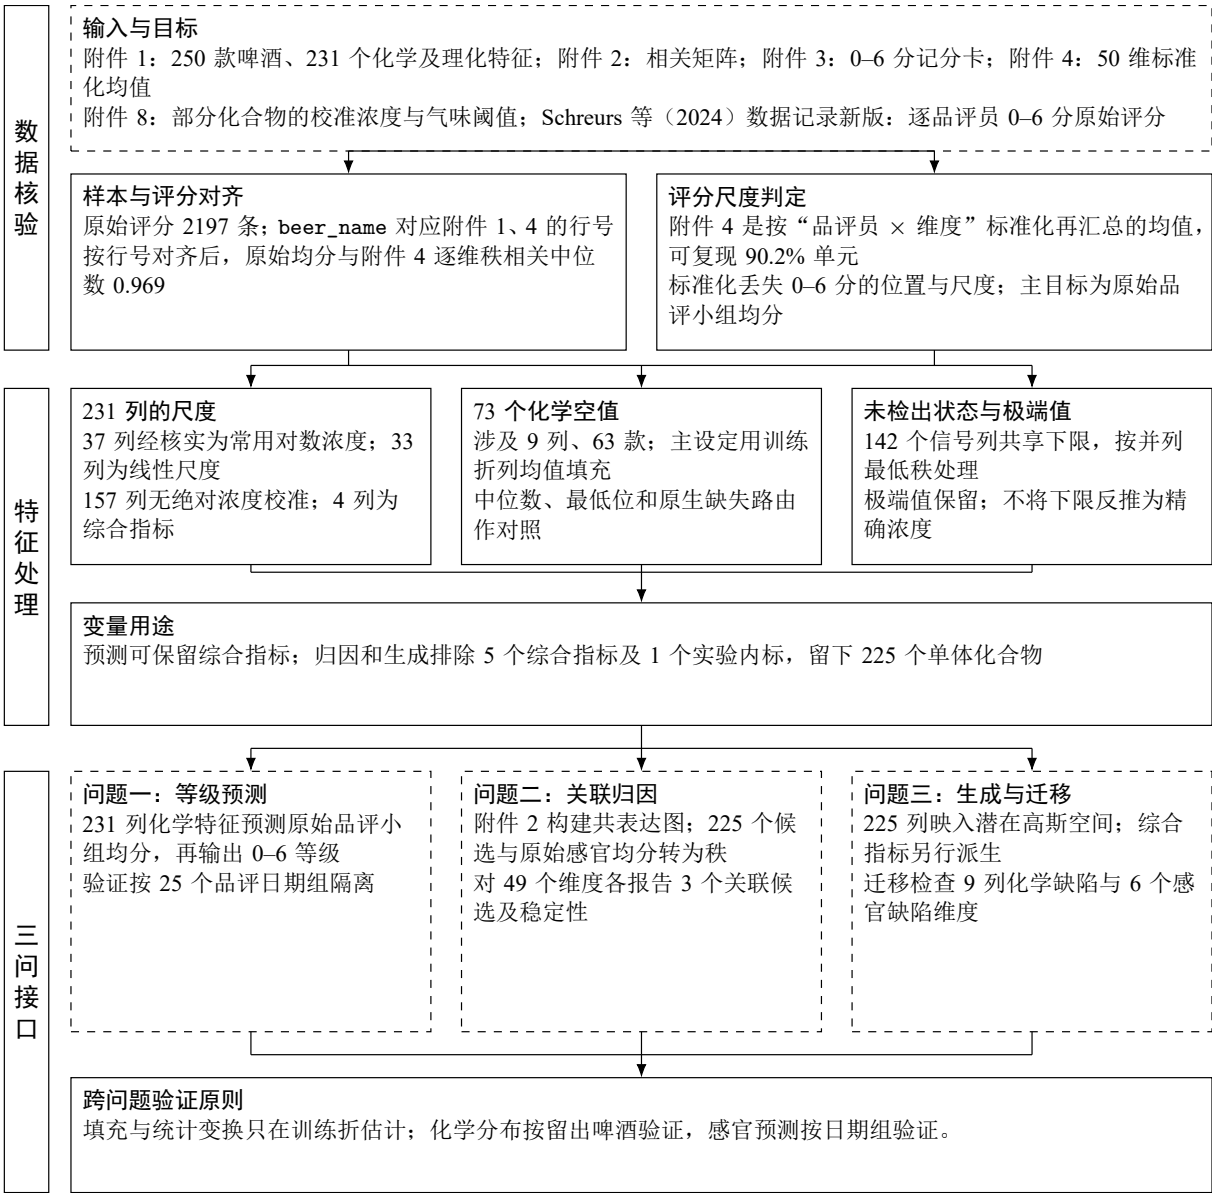


图 1: 数据来源、预处理决定与三个问题的输入输出。图内“原始评分”指作者在同一数据记录新版公布的逐品评员 0–6 分记录。

4 问题一：缺失数据下的感官评分

问题一从附件一的化学特征预测 250 款啤酒在 50 个感官维度上的 0 到 6 等级。估计目标是品评小组等级 G_{bd}，即啤酒 b 在维度 d 上全部原始评分的算术均值 $\bar{x}_{bd}$ 取整到 0 到 6。本章先用浅层梯度提升树建立化学特征到品评小组均分的连续模型，再由内层折外残差构造预测等级分布，以分布中位数作为主输出。

4.1 问题分析

问题一的数据缺失有两层含义。第一层是附件一的化学特征有 73 个空值，属于特征缺失。第二层是待评分的新啤酒没有任何品评记录，其评分只能由化学数据预测。对 250 款已有实测等级的啤酒同样给出预测，是因为交付值是折外预测，衡量模型对新啤酒的预测能力，实测等级只作对照。赛题所称约 40 个感官维度，按附件三汇总表解读为 50 个维度，全部建模并报告。

感官评分含品评员之间的系统差异与随机噪声。同一天品评的啤酒共享出席名单与品评情境，且大多属于同一风格。随机划分会把同一天品评的啤酒放到训练集与测试集两侧，泄漏同日信息。因此问题一的交叉验证按日期组隔离，把 37 个品评日期合并成 25 个日期组，每组 5 到 24 款。

4.2 模型建立

4.2.1 化学特征到品评小组均分的连续模型

对每个感官维度 d 单独训练一个模型 $\hat{\mu}_{bd} = f_d(X_b)$，以平方损失拟合 $\bar{x}_{bd}$。平方损失的最优预测是条件均值，与目标 $\bar{x}_{bd}$ 的定义一致。f_d 用 scikit-learn 的 `HistGradientBoostingRegressor` 是浅层梯度提升树集成。选用树模型的理由有三点。第一，Schreurs 等人的论文报告树集成的品评小组测试 R^2 为 0.21 到 0.22，线性回归为 -4.13，树集成明显更优。第二，树只依赖每个特征的顺序，不受 157 个未校准信号列对数底数的影响。第三，该估计器支持单调约束，也能直接保留缺失值作为敏感性对照。

超参数在每个维度组内共享，以组内平均内层交叉验证的 RMSE 与标准差之比为选择标准。搜索范围为最大深度 $\{2, 3\}$、叶节点最小样本 $\{10, 20\}$、学习率 0.05、迭代 $\{100, 200, 400\}$、l_2 正则 $\{0, 1\}$、单调约束开或关。六个维度组为香气、风味、缺陷、香料啤酒、酸啤酒、基本味口感与总体。在 250 款啤酒上逐维调参会拟合噪声，因此在 6 个维度组内共享超参数，由内层交叉验证选择。

单调约束来自事先固定的化学知识。在查看数据之前列出 12 个化合物到感官的配对，其中 11 个符号符合预期，对 6 个直接配对施加约束，包括乙醇到酒精感、苦味单位

到苦味、pH 到酸感取负向、乳酸到乳酸感、乙酸到乙酸感、4-乙烯基愈创木酚到酚味。约束是否开启作为内层交叉验证的超参数，不由外层结果决定。

4.2.2 0 到 6 等级输出

连续预测需要转为 0 到 6 的等级。在外层训练集 $\mathcal{T}$ 上做按日期组分组的 4 折内层交叉验证，得到内层折外预测 $\tilde{\mu}_{id}$ 与残差 $e_{id} = \bar{x}_{id} - \tilde{\mu}_{id}$。对测试啤酒 b，用同一批残差构造预测等级分布：

$$p_{bdk} = \frac{1}{|\mathcal{T}|} \sum_{i \in \mathcal{T}} \mathbf{1}\{q(\hat{\mu}_{bd} + e_{id}) = k\}, \qquad F_{bdk} = \sum_{j \le k} p_{bdj}, \qquad k = 0, \ldots, 6. \tag{2}$$

式 (2) 把测试啤酒的预测误差近似为与内层折外残差同分布。其中 $\mathbf{1}\{\cdot\}$ 为指示函数，p_{bdk} 是预测等级为 k 的概率，F_{bdk} 是累积概率。

主输出取预测分布的中位数：

$$\hat{G}_{bd} = \min\{k : F_{bdk} \ge 0.5\}. \tag{3}$$

主指标是等级 MAE，即平均绝对误差，指预测等级与真实等级之差的绝对值的平均。在预测分布下使期望等级绝对误差最小的点输出是分布的中位数，因此主输出与主指标匹配。第二输出取分位数切点，把连续预测 $\hat{\mu}_{bd}$ 在训练折累积等级频率处的分位数作为切点，输出 $\hat{G}^{\mathrm{Q}}_{bd} = \#\{k : \hat{\mu}_{bd} \ge c_k\}$，用于保留等级分布的场合。

主输出与四舍五入不同。零分主导的维度在 0 处截断，残差右偏，等级的中位数不等于 $q(\hat{\mu}_{bd})$。完全一致率不作主指标，因为不用化学数据、只输出训练折众数的常数规则完全一致率就有 56.6%。主输出、第二输出与主指标都在正式运行前写定。

图 2 给出问题一的完整流程。连续模型、等级输出、对照与不确定性各自对应一个模块，图内写出数据来源、目标、主要变换、输出与验证单位。



图 2: 问题一方法流程：化学特征与原始评分经日期组嵌套交叉验证得到连续评分与等级预测分布，主输出为分布中位数，第二输出为分位数切点。

4.3 实验设计

表 7 按目标与输入、化学缺失、划分、连续模型、搜索范围、等级与区间、对照与判据七个环节列出正文报告的设置，以及每个设置控制或检验的对象。软件版本、各折所选参数频数与对照模型的完整搜索网格放附录。

表 7: 问题一实验设置与对照

环节	正文报告的设置	控制或检验什么
目标与输入	250 款啤酒、231 个化学特征、50 个感官维度；以逐品评员原始评分的每款每维均分为连续目标，均分取整为 0–6 级真值；主模型不输入风格或附件四	预测目标、特征与真值同口径
化学缺失	73 个空值在训练折内按列均值填充，测试折不参与预处理	填充不泄漏测试信息
划分	37 个日期并为 25 个日期组，按日期组隔离、按风格分层的 5 折 × 5 次重复，种子 0 到 4，内层同为 4 折	同日品评信息不泄漏，调参与报告分开
连续模型	每维一个平方损失 HistGBR，六组内共享超参数，内层按组内平均 RMSE/SD 选参	控制模型复杂度
搜索范围	深度 $\{2,3\}$、叶节点 $\{10,20\}$、学习率 0.05、迭代 $\{100,200,400\}$、l_2 正则 $\{0,1\}$、六个单调约束开关由内层选择	选参可复现，正文另述迭代下边界检查
等级与区间	内层折外残差构造 0–6 等级概率；分布中位数为主输出，分位数切点为第二输出；90% 等级区间	连续预测转为可交付等级及其不确定性
对照与判据	风格收缩均值为要超越的基线，ElasticNet 检查线性替代，随机森林检查另一种树集成，只用附件四的两阶段方法为对照；主指标等级 MAE，辅助 QWK、完全一致率、±1 内比例；按日期组 bootstrap 2,000 次给配对差 95% 置信区间	每个实验为何存在，什么结果支持主张

表 7 的成功标准在运行前声明：主模型等级 MAE 低于风格收缩基线、配对差置信

区间上界小于零、且至少 25 个维度逐维 MAE 更低。指标口径为每次重复合并 250 款折外预测计算，五次再取平均。最终交付先平均五次概率再取等级，与折外指标口径不同，两者不混用。

4.4 结果

4.4.1 主结果与关键对照

表 8 给出主模型与五个关键对照的等级指标。主模型等级 MAE 为 0.479，风格收缩基线为 0.527，配对差为 -0.048，95% 置信区间为 $[-0.062, -0.034]$，31 个维度逐维 MAE 更低，满足成功标准。

表 8: 问题一主结果与关键对照

模型	等级 MAE	相对主模型的 MAE 差 [95% CI]	QWK	完全一致率	±1 内比例
风格收缩均值 B1	0.527	+0.048 [0.034, 0.062]	0.095	0.559	0.931
主模型（化学）	0.479	参照	0.290	0.581	0.950
化学 + 风格	0.479	−0.0001 [−0.0015, 0.0013]	0.289	0.580	0.950
ElasticNet	0.481	+0.002 [−0.010, 0.013]	0.199	0.585	0.946
随机森林	0.472	−0.008 [−0.015, −0.001]	0.251	0.589	0.950
只用附件 C1	0.786	+0.307 [0.271, 0.341]	0.323	0.433	0.827

表 8 中等级 MAE 为平均绝对误差，QWK 为二次加权 Kappa，完全一致率为预测等级与真实等级相同的单元比例，±1 内比例为误差不超过一级的单元比例，单位都是 12,500 个啤酒乘维度单元。

化学加风格一行的结果与主模型相同，回答领域读者最先会问的问题：模型是否只是在识别风格。只用风格的基线 QWK 为 0.095，在化学特征上再加风格，结果与主模型一致，说明风格信息已由化学谱携带，也支撑问题三只用化学谱给出画像。随机森林的等级 MAE 为 0.472，低于主模型，但 QWK 为 0.251，低于主模型的 0.290，两者同列呈现，主模型不称各项最优。只用附件的 C1 按自身规则选定等级映射，端到端等级 MAE 为 0.786，QWK 为 0.323，仍以同一原始等级为真值，其差距主要来自标准化去掉的位置和尺度。

4.4.2 等级规则

表 9 比较四种等级规则。预测分布中位数与四舍五入的等级 MAE 分别为 0.479 与 0.490，中位数更低且不增加参数。分位数切点的等级 MAE 为 0.578，高于中位数，但 QWK 为 0.371，高于中位数的 0.290，预测 5 到 6 级的占比为 1.57%，接近真值的 0.968%。主输出服务单款误差最小化，第二输出服务等级分布描述，两者同时交付。

表 9: 问题一等级规则比较

规则	等级 MAE	QWK	完全一致率	预测 5–6 级占比
常数等级（训练折众数）	0.549	−0.006	0.566	0%
四舍五入	0.490	0.293	0.565	0.04%
预测分布中位数（主输出）	0.479	0.290	0.581	0.02%
分位数切点（第二输出）	0.578	0.371	0.531	1.57%

保持等级分布提高 QWK，但单款啤酒的误差变大。原因是模型只解释了一部分方差，最优的单点预测必然向中间收缩。要让等级分布与真值一致，就得把部分啤酒推离它最可能的等级。这一取舍由表 9 与图 4 共同呈现。

4.4.3 逐维增益与可预测性

图 3 两栏共用纵轴，50 个维度按六个维度组排列。左栏为主模型减风格收缩基线的逐维等级 MAE 差，零线区分胜负，标出 31 个胜出维度及各组胜出数。逐维差只作描述，不把 50 个维度当独立重复求置信区间。右栏为逐维连续 R^2，配同维度的半组信度作短竖线标记。等级 MAE 受各维度等级分布影响，零分主导的维度 MAE 天然较小，只看左栏会误读维度间差异。图注写明信度是测量噪声参照，不是严格上限，并注明 R^2 为负的维度。



图 3: 逐维增益与可预测性。左栏零线区分主模型与风格收缩基线的逐维胜负，右栏显示逐维连续 R^2 与半组信度。

4.4.4 误差集中的等级

图 4 左栏为真值、主输出、第二输出的 0 到 6 级频率，右栏为按真实等级分层的主输出召回率。±1 内比例约 95% 会掩盖高等级漏判，本图回答这一疑虑。主输出几乎不给出 5 到 6 级，5 级真值 112 个单元、6 级 9 个单元的召回率接近零，误差集中在相邻等级。第二输出给出 1.57% 的 5 到 6 级，更接近真值。

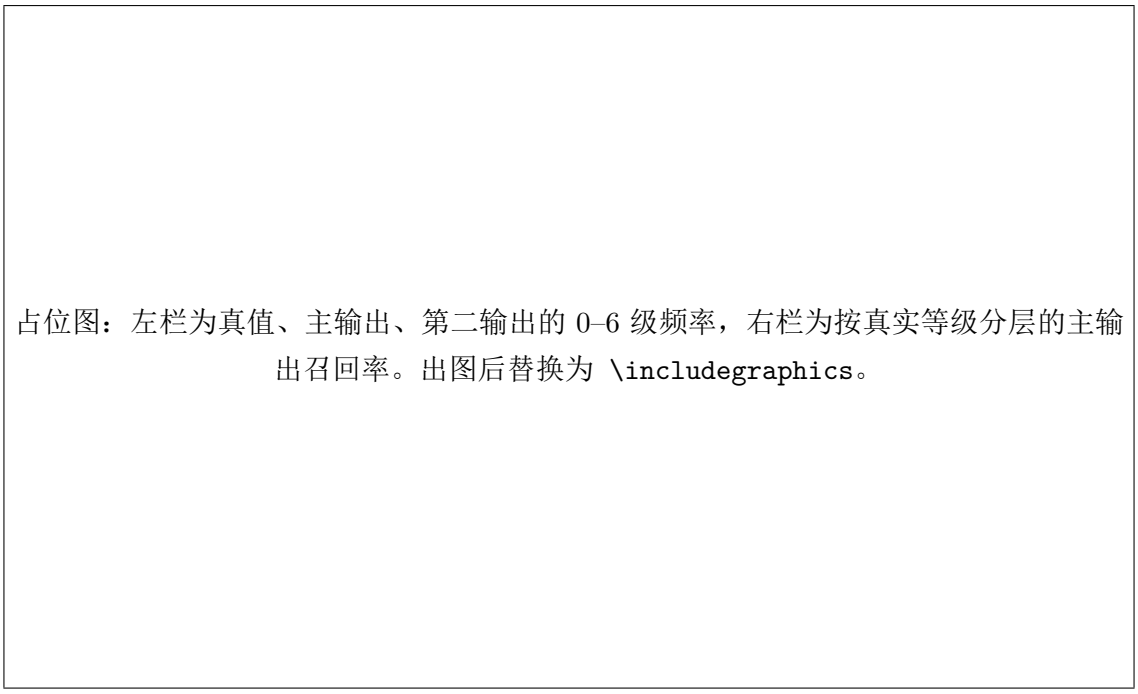


图 4: 误差集中的等级。左栏显示三种等级频率，右栏显示主输出按真实等级分层的召回率，图注注明每栏分母。

4.4.5 交付评分示例

赛题要求给出评分结果，表 10 展示交付物本身。选款规则事先固定，在 Pils/Lager、Tripel、Kriek 三个风格中各取原始评分记录数最多的一款，与问题三的风格相连。行为 15 个属性，列为三款啤酒的 Aroma 与 Flavour，共 6 列。单元格写交付等级与 90% 区间，再附实测等级。全部 250 款作为机器可读补充文件交付。

表 10: 交付评分示例：三款啤酒的 15 个属性

属性	Pils/Lager		Tripel		Kriek	
	Aroma	Flavour	Aroma	Flavour	Aroma	Flavour
malt_all	占位	占位	占位	占位	占位	占位

单元格格式为交付等级 [90% 区间] / 实测等级，取自最终交付口径 G_{hat}，与折外指标口径不同。

占位单元格由 Coding 从 `q1_final_scores.csv` 导出，三款啤酒按选款规则在三个风格中取评分记录数最多

4.4.6 文字报告

信度中位数约 0.53，作为噪声参照而非严格性能上限，说明可解释方差的上限就在这一量级。两半组等级 QWK 为 0.374，是真值本身含抽样噪声的直接证据。主模型连续

R^2 为 0.184，连续 MAE 为 0.473，连续 Spearman 为 0.360。90% 等级区间覆盖 97.2%，平均宽度 1.97 级，略宽于名义值，来自等级的离散性与折外残差的保守性。

敏感性分析共八项，其中七项的等级 MAE 配对差置信区间含 0，交付等级变化不超过 5.2%。训练目标改为训练折内估计的啤酒效应、化学缺失的三种替代填充、barnyard 的排除、四个综合指标的删除、附件八冲突单元替换、单调约束全开或全关，都不改变主要结论。网格扩展检查在重复 0 上把迭代下界扩展到 10 到 200，外层连续 MAE 与 R^2 不变，Spearman 低 0.019，未改善外层预测，主网格保持不变。只用附件的对照 C1，其零点还原的中间结果见表 5，端到端结果见表 8。

5 问题二：化合物共表达图与感官维度的关键化合物

问题二利用附件二的化合物相关矩阵构建共表达图，结合附件一的化学特征，给出每个感官维度上关联最强的三个化合物。估计目标 $T_d = (t_{d1}, t_{d2}, t_{d3})$ 定义为在 250 款啤酒上按控制已选化合物后的秩关联依次最强、且两两不属于同一共表达模块的 3 个化合物。这是关联定义，不是因果定义。

5.1 问题分析

题目要求找出关键化合物，本章将其操作化为关联结果。附件中没有干预数据，不能直接推断因果，化学合理性在结果产生后给出机理解释。唯一独立于这 250 款啤酒的核验是作者发布的加标实验，其结论只在第 5.4.6 节报告。因此本章的核心是让关联结果可重复、可独立于感官数据检验，而不是宣称因果。

稳定性重抽以日期组为单位，而不是以单款啤酒为单位。同一天品评的啤酒共享出席名单和品评情境，且大多属于同一风格。按单款啤酒重抽会把这些相关性当作独立样本，高估有效样本量。25 个日期组是可直接观测、粒度更粗的分组，重抽时每次抽取 25 个日期组并拼接其中的啤酒。

5.2 模型建立

5.2.1 候选集合

候选化合物为附件一的 231 列减去 5 个综合指标和 1 个内标，共 225 个。综合指标 $esters_sum$、$aroma_hops_sum$、$acids_sum$、$sulfur_sum$、$kcalperc$ 由其他化合物计算得到，各自几乎是某一个组成成分的副本，与其对应成分的 Spearman 相关系数绝对值分别为 0.92、0.96、0.97、0.78、0.85。把它们列为候选会使同一信息以总量和成分两次入选，且题目要求的是化合物。内标 3-甲基-2-丁烯醛在附件八中被标为内标溶

液，反映测量过程，不反映啤酒组成。6 个排除列仍作为图的注释节点保留，用于展示综合指标与成分的关系。

5.2.2 共表达图与模块

共表达图 G_τ 的节点为 231 列，边权为两两 Spearman 系数的绝对值 $|\rho_{jk}|$，符号作为边属性保留。使用无符号权重是因为强相关几乎都是正相关，$|\rho| \geq 0.5$ 的 597 条边中只有 13 条为负。模块由 $1-|\rho|$ 上的平均连接层次聚类得到，在高度 $1-\tau$ 处切开。平均连接只在两组之间平均边权不低于 τ 时合并，因此每个模块内的化合物彼此平均相关至少约为 τ。

主值 $\tau = 0.6$，其依据有三点。第一，0.6 是候选间 Spearman 相关系数绝对值的 99% 分位，仅最强的 1% 化合物对的相关达到该阈值。第二，$\tau = 0.5$ 时模块混入不同来源的化合物，来源纯度（多成员模块中占多数的附件八来源类别所占比例的平均值）降至 0.70，划分可重复性（调整兰德指数 ARI）降至 0.66。第三，$\tau = 0.7$ 时只有 65 个化合物属于多成员模块，冗余控制覆盖的范围变小。主值下得到 161 个模块，其中 33 个多成员模块覆盖 97 个化合物，代表性模块包括乙醇、乙酸乙酯、己酸乙酯、甘油构成的发酵强度模块，以及辛酸乙酯、癸酸乙酯构成的中链脂肪酸乙酯模块。化合物层的入选频率在三个 τ 下相同，所以 τ 主要影响模块层的解读。

5.2.3 图约束前向选择

第 1 位取边际关联最强者：

$$t_{d1} = \arg\max_{j \in \mathcal{C}} |r_{jd}|. \tag{4}$$

其中 $\mathcal{C}$ 为 225 个候选化合物集合，r_{jd} 是化合物 j 与维度 d 的 Spearman 系数，在两者的标准化秩上计算。第 k 位（$k = 2, 3$）在控制已选集合 S 后取秩偏相关最强者。令 H_S 为向 $\{\mathbf{1}, \tilde{x}_s : s \in S\}$ 张成空间的投影，

$$e_y = (I - H_S)\tilde{y}_d, \qquad e_j = (I - H_S)\tilde{x}_j, \qquad r_{jd|S} = \frac{e_j^\top e_y}{\|e_j\|\,\|e_y\|}, \qquad t_{dk} = \arg\max_{j \in \mathcal{C},\ M(j) \notin M(S)} |r_{jd|S}|. \tag{5}$$

式 (5) 中 $r_{jd|S}$ 是秩上的偏相关，衡量化合物 j 在已选化合物之外还能解释多少维度排序。图在第一处排除与已选者属于同一模块的化合物，在第二处把同模块化合物与入选者一起报告。

选用前向选择而不用边际选择，由模拟还原实验决定。边际选择按 $|r_{jd}|$ 降序、每模块至多一个取前 3，会反复选入第 1 个植入化合物的间接相关者。在真实化学矩阵上随机植入 3 个来自不同模块的化合物，按秩线性组合加噪声生成维度，第 1 个植入化合物的 r 取 0.2、0.3、0.45，权重取 (1, 0.75, 0.5) 与 (1, 1, 1)，每种设置 1,000 次。前向选择

在 $r \geq 0.3$ 时找回率更高，其中找回率指植入化合物被选入前 3 位的比例，而观测数据中 49 个维度第 1 位关键化合物的 $|r|$ 中位数为 0.38，四分位为 0.30 到 0.48，处于前向选择占优的区间。模拟只用化学矩阵，不使用感官数据，因此这一选择没有利用观测到的 Top-3 内容。

5.2.4 显著性门槛

每个维度的显著性门槛由置换检验给出。打乱 $\tilde{y}_d$ 的行 1,000 次，取 225 个化合物边际相关绝对值的最大值，得到维度 d 的零分布，95% 分位记为 q_d。q_d 的中位数为 0.229，第 1 位超过门槛的维度为 48 个。第 2、3 位用 Freedman–Lane 置换，打乱 e_y 后在可选化合物上取偏相关绝对值的最大值。逐行打乱忽略日期组内的相关，零分布偏窄，因此每个入选项另外用日期组簇 bootstrap 计算 95% 置信区间。入选项同时满足得分超过门槛与置信区间不含 0 时记为显著。

图 5 给出问题二的完整流程。化合物与感官秩经共表达图、模拟还原支持的图约束前向选择与置换检验，再经日期组重抽和替代方法，得到化学证据与前三项关联候选。



图 5: 问题二方法流程：化合物与感官秩经共表达图、图约束前向选择与置换检验得到关键化合物，稳定性由日期组重抽量化。

5.3 实验设计

表 11 按输入与目标、缺失与秩、图与模块、选择规则、显著性、稳定性、规则依据实验、对照方法八个环节列出正文报告的设置。

表 11: 问题二实验设置与对照

环节	正文报告的设置	控制或检验什么
输入与目标	250 款啤酒；附件一 231 列剔除 5 个综合指标与内标，剩 225 个候选；49 个维度，barnyard 记作同 stale_hops；感官目标为原始评分均分的秩	候选都是化合物或理化指标，目标与问题一同口径
缺失与秩	8 个单化合物列共 60 个空值按列均值填充，每次 bootstrap 样本内重算；信号下限按并列最低秩处理	填充值不解释为浓度
图与模块	边权取 $\lvert\rho\rvert$，$1-\lvert\rho\rvert$ 上平均连接层次聚类，$\tau = 0.6$ 切割	模块内平均相关至少约为 τ
选择规则	第 1 位取最大 $\lvert r_{jd}\rvert$，第 2、3 位取控制已选集合后的秩偏相关最大者，同一模块至多入选 1 个	用条件关联去除间接相关者
显著性	置换 1,000 次，第 1 位用全体候选最大相关零分布的 95% 分位，第 2、3 位用 Freedman–Lane 置换，并同时要求日期组 bootstrap 95% 置信区间不含 0	维度内多重比较与日期组内相关
稳定性	25 个日期组有放回重抽 $B = 1000$，每次重建相关矩阵与模块，报告化合物层与模块层入选频率 π^c、π^m，分档界限 0.6 与 1/3	结论对样本扰动的稳定程度
规则依据实验	真实化学矩阵植入 3 个不同模块的化合物，权重 (1,0.75,0.5) 与 (1,1,1)，第 1 个植入化合物的 r 取 0.2、0.3、0.45，每种设置 1,000 次，噪声含日期组偏移	只用化学矩阵、不用感官数据，回应根据结果改规则的质疑
对照方法	无图约束边际选择、图约束边际选择、ElasticNet、问题一梯度提升树、风格内分析	每种对照对应方法的一处改动

Top-3 是关联而非因果。维度等级按 Top-1 的显著性与入选频率分为三档，A 级为 Top-1 显著且 $\pi^{c} \geq 0.6$，B 级为 Top-1 显著但不满足 A，C 级为 Top-1 不显著。选择规则在预运行后由边际选择改为前向选择，已在正文披露。

5.4 结果

5.4.1 找回率

图 6 为 2 乘 3 小多图，行为两种植入权重，列为植入名次 1 到 3。横轴为第 1 个植入化合物的 r，纵轴为化合物层找回率，两条线为前向选择与图约束边际选择。每格加竖向阴影带，表示 49 维 Top-1 相关绝对值的四分位范围及中位线。图注写明每格 1,000 次，二项 95% 区间约正负 0.03，不画误差线。前向选择在中等与较大效应量下找回率更高，在小效应量下与边际选择相当，两种规则的实际差异按本图呈现。

占位图：2 乘 3 找回率小多图，行为两种权重，列为植入名次 1 到 3，横轴为第 1 个植入化合物的 r，纵轴为化合物层找回率。出图后替换为 `\includegraphics`。

图 6: 规则依据实验的找回率。两条线为前向选择与图约束边际选择，竖向阴影带为观测 Top-1 相关的四分位范围。

5.4.2 共表达网络

图 7 重绘共表达网络，只画多成员模块的化合物和 6 个注释节点，单成员节点只在图注计数。节点颜色为附件八来源，大小为该化合物进入主方法 Top-3 的维度数，未入选者空心。边宽与 $|\rho|$ 成正比，负相关边虚线。标注至少 3 个成员模块的枢纽、全部入选化合物，以及发酵强度、中链脂肪酸乙酯等代表模块。

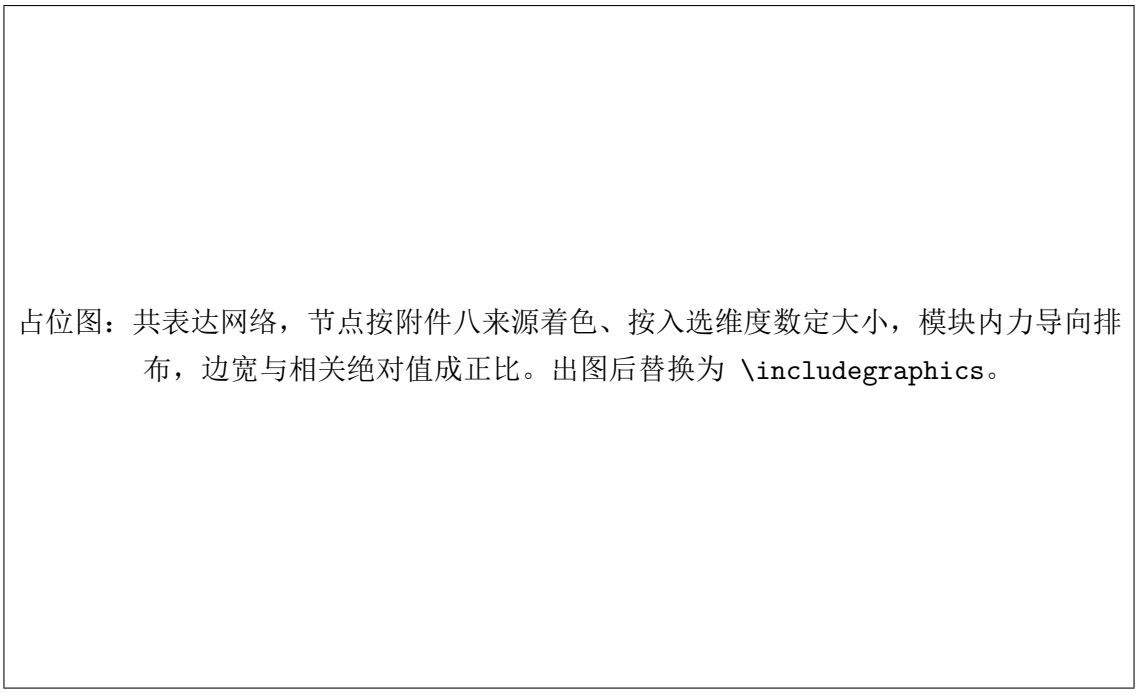


图 7: 化合物共表达网络。只画多成员模块与注释节点，图注计数单成员节点并说明综合指标的排除理由。

5.4.3 稳定性

图 8 左栏为 49 行乘 3 名次的化合物层入选频率 π^{c} 热图，行按六个维度组分块，三档离散色阶，格内写两位小数，不显著项加斜线纹。右栏为名次 1 到 3 各一根堆叠柱，按稳定、中等、不稳定的维度数堆叠，叠加化合物层与模块层入选频率的均值标记，两者之差反映同模块轮换。入选频率按名次为 0.60、0.36、0.22，稳定、中等、不稳定项分别为 33、41、73。此图支持多数维度可靠支持的关键化合物为 1 到 2 个这一结论。



图 8: 关键化合物的稳定性。左栏为逐维入选频率热图，右栏为三个名次按稳定程度堆叠的维度数。

5.4.4 方法间一致性与风格内关联

图 9 为竖向柱状图，横轴为五个方法，纵轴为 49 维平均 Jaccard，每个方法画化合物层、模块层两根柱，柱顶标 Top-1 一致比例。Jaccard 系数为两个集合交集与并集大小之比，衡量两个方法选出化合物的重合程度。随机 3 元集合基线 0.008 画细虚线，说明重合不是偶然。主方法与无图约束边际选择、图约束边际选择的化合物层 Jaccard 分别为 0.339 与 0.382，Top-1 按构造相同。与 ElasticNet 为 0.573，与梯度提升树为 0.267，与风格内分析为 0.259。梯度提升树的 Top-1 一致比例只有 0.45，解释为估计对象不同，相关特征下置换重要度被稀释，不同的维度在附录并列给出。

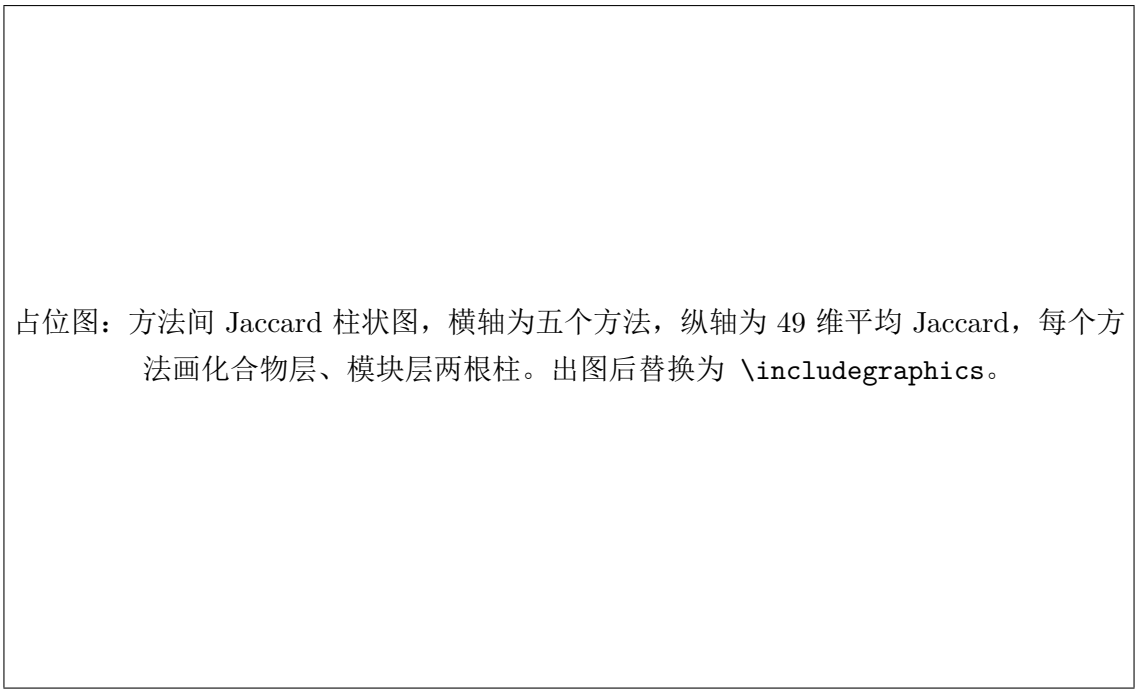


图 9: 方法间 Jaccard。细虚线为随机 3 元集合基线，柱顶标注 Top-1 一致比例。

图 10 为 147 个点的散点图，横轴为合并边际 Spearman r_{jd}，纵轴为风格内 $r_{jd}^{(s)}$，点形状表示名次，颜色表示风格内置信区间是否含 0。主 Top-3 的 147 项中 98% 在风格内保持同号，风格内与合并系数之比的中位数为 0.66。有 18 项的风格内 $|r^{(s)}| < 0.1$，即其关联几乎完全来自风格之间，包括乳酸到乳酸感、pH 到酸感、乙醇到麦芽风味。



图 10: 合并与风格内关联。参考线为 $y = x$ 与 $y = 0$，颜色表示风格内置信区间是否含 0。

5.4.5 代表维度证据

表 12 给出代表维度的 Top-3 证据。代表维度按事先规则选取，每个维度组至少一个，优先与加标属性对应的维度，含一个 C 级维度，共 21 行。化学解释写在正文，不入表。选择得分、95% 置信区间与风格内系数从最终合理性表导出，完整 147 项按六个维度组放附录。

表 12: 代表维度的 Top-3 证据

维度（等级）	名次	化合物	方向	π^c	OAV≥1 占比
A_esters_all（A）	1	己醇	+	0.61	无阈值
	2	乳酸	+	0.36	0.17
	3	乙醛	+	0.33	0.00
F_malt_all（A）	1	pH	+	0.79	无阈值
	2	乙醇	+	0.47	0.98
	3	色度	+	0.47	无阈值
bitternes（A）	1	苦味单位	+	1.00	0.86
	2	辛酸乙酯	+	0.74	0.26
	3	铁	−	0.09	0.48
body（A）	1	乙醇	+	0.99	0.98
	2	色度	+	0.56	无阈值
	3	铁	−	0.04	0.48
lactic（A）	1	pH	−	0.95	无阈值
	2	乙酸异戊酯	−	0.88	0.84
	3	蛋白质	+	0.53	1.00
clove（A）	1	柠檬烯	+	0.80	无阈值
	2	α-卡拉烯	−	0.21	无阈值
	3	乙酸丙酯	+	0.20	无阈值
t2n（C）	1	β-水芹烯	−	0.23	无阈值
	2	辛酸乙烯酯	+	0.18	无阈值
	3	己醇	−	0.04	无阈值

以苦味为例，苦味单位的入选频率为 1.00，与苦味的关联方向为正，气味活度值超过 1 的啤酒占 86%。以乳酸为例，pH 与乳酸感的关联方向为负，说明酸度由 pH 直接刻画。以 t2n 为例，其 Top-1 不显著，标记为未找到可靠的关键化合物，Top-3 仍列出供参考。

5.4.6 加标核验

表 13 为作者加标实验的同人配对差，加标物为 6 到 7 种化合物的混合物。酯类加标在三组中都提高 Esters，支持酯类作为酯类维度的关键因素。未加入任何酒花化合物，Hops 与 Bitterness 不变，是一组阴性对照。Fullness 在三组中都提高，与 body 的 Top-1 乙醇及其同模块的甘油方向一致，但无乙醇组同样提高，说明甘油或其他成分足以产生该效应。

表 13: 加标实验的同人配对差与对应维度

属性	Blond 含乙醇 n=20	Blond 无乙醇 n=13	NABLAB 无乙醇 n=13	对应维度（Top-1）
Esters	0.90（4.7）	1.08（2.9）	1.31（5.0）	酯类（己醇 / 蛋白
Fullness	1.30（6.3）	1.31（3.0）	1.38（4.8）	body（乙醇）
Alcohol warming	1.10（4.2）	0.92（4.4）	0.08（0.6）	alcohol（乙醇）
Sweetness	1.15（4.4）	0.69（2.0）	1.00（3.1）	sweetness（癸酸乙
Hops	−0.15（−0.5）	0.00（0.0）	−0.08（−0.2）	酒花（辛酸乙酯 /
Bitterness	0.05（0.2）	−0.15（−0.6）	−0.31（−0.9）	bitternes（苦味单
Malt	0.45（2.0）	−0.23（−1.0）	0.00（0.0）	麦芽（色度 / pH）
Overall	1.05（2.8）	1.15（3.6）	1.08（3.5）	overall（乙酸乙酯

5.4.7 文字报告

显著性门槛 q_d 的中位数为 0.229，第 1、2、3 位超过门槛的维度分别为 48、39、21 个。维度等级为 A 级 26 个、B 级 22 个、C 级 1 个，C 级为 t2n。共变标记项数 88 个，模块不可分假设被推翻 0 项。附件二与附件六的复算误差分别为 2.05×10^{-15} 与 6.66×10^{-16}，说明列对齐与逐对删除的实现正确。C 级维度 t2n 的零膨胀检查未发现关联随零膨胀而增强的证据。敏感性分析的主要结论是结论对模块阈值、候选集合、缺失处理与附件取值稳定，唯一的例外是感官目标改用附件四的标准化值后 Top-3 与等级变化较大，结论以原始评分均值为准。

6 问题三：风格条件化合物谱生成与跨风格迁移

问题三以细分风格标签为条件学习生成模型，在给定风格下生成化合物谱并给出感官画像，再把一种风格的化合物谱迁移为另一种风格，且缺陷化合物不恶化。估计目标有三项：风格条件分布 $p(x \mid s)$、感官画像、以及满足两层缺陷约束的迁移映射。本章的正式结果尚未交付，结果一节的图表只规定内容与形式，以占位方式呈现。

6.1 问题分析

任务要求生成的化合物谱合理，本章把合理写成三层可计算的操作定义。取值层要求每列取值落在 250 款啤酒的观测范围内，未检出的下限作为离散状态按应有比例出现，综合指标与其成分一致。分布层要求风格 s 的生成样本与留出的风格 s 真实啤酒在带风格标签的分类器双样本检验（C2ST，AUC 接近 0.5 表示未发现可区分性）中未表现出明显可区分性，也被独立的风格判别器判为 s。新颖性要求生成样本不是训练啤酒的复制品。三层分别作为结果表的分组行，每层都有可计算的指标。

迁移任务以超阈值项界定缺陷，即化合物在阈值以下时不构成缺陷。据此把不恶化写成两层约束。化学层约束 9 个缺陷列，要求迁移后取值不高于上界，有阈值时上界为源取值与阈值中的较大者，无阈值时为源取值。感官层约束 6 个缺陷维度，要求迁移后经问题一模型得到的预测等级不升高。两层的比较对象都是迁移前的同一款啤酒，不是目标风格的典型值。

6.2 模型建立

6.2.1 秩变换与潜变量

生成器不在附件一的原尺度上建模，而在逐列秩变换后的潜变量上建模。对列 j 取训练折的非缺失观测，把相同取值合并为块，块 k 覆盖经验累积概率区间 $(l_k, h_k]$，块内所有观测的潜变量取标准正态在该区间上的条件期望：

$$\phi_j(x) = \mathbb{E}\big[Z \mid \Phi^{-1}(l_k) < Z \le \Phi^{-1}(h_k)\big] = \frac{\varphi(\Phi^{-1}(l_k)) - \varphi(\Phi^{-1}(h_k))}{h_k - l_k}. \tag{6}$$

式 (6) 中 φ 与 Φ 分别是标准正态的密度与分布函数。无并列的取值时该式近似于正态得分，下限块的潜变量是截断正态的均值。反变换 $x_j = Q_j(\Phi(u_j))$ 中 Q_j 是保留并列取值全部概率质量的逆经验分布函数，把下限的整个概率区间映回下限值。

采用秩变换的原因有三点。第一，157 个信号列的变换方式未经核实，秩不受任何单调变换影响，37 个对数列与 33 个线性列混合时也不需要统一单位。第二，下限是离散状态，142 列的最小值是共同下限，共 6,807 个单元格，在原尺度用连续分布生成会产生低于下限的取值。第三，线性列有数量级很大的极端值，秩变换后不再主导协方差。

6.2.2 风格条件潜在高斯模型

在潜空间中，同一风格内的潜变量服从多元正态分布：

$$u_b \mid s(b) = s \;\sim\; \mathcal{N}(\mu_s,\, \Sigma_W), \qquad \Sigma_W = \Lambda\Lambda^{\top} + \Psi_M. \tag{7}$$

式 (7) 中 u_b 为啤酒 b 的潜变量向量，k 为因子数，Λ 为 $225 \times k$ 的因子载荷，Ψ_M 为按问题二共表达模块分块的特异协方差。风格均值向全局均值收缩：

$$\hat{\mu}_s = \frac{n_s \bar{u}_s + \kappa\, \bar{u}}{n_s + \kappa}, \tag{8}$$

式 (8) 中 n_s 为风格 s 的啤酒数，$\bar{u}_s$ 为风格 s 的样本均值，$\bar{u}$ 为全局均值，κ 为收缩强度。该式与问题一基线的收缩形式相同，小样本风格的均值估计由收缩稳定。风格内协方差由合并风格内残差估计，先拟合因子载荷，再保留同一模块内的元素与对角元作为 Ψ_M，负特征值截到 10^{-3} 保证正定。各风格共享同一个 Σ_W，因为单个风格最多 31 款、少于 225 维，风格专属的完整协方差不可估计。

风格只解释每个化合物潜变量方差的一部分，风格解释的潜变量方差比例 η^2 的中位数为 0.250，因此生成器必须同时刻画风格均值和风格内变化，只生成风格均值会丢掉约四分之三的方差。风格内变化有低维结构，合并风格内残差的前 30 个主成分解释 72% 的方差。纯因子模型会衰减强相关的化合物对，模块块恢复这一共变，预运行中留出真实啤酒的模块内平均 Spearman 为 0.724，加模块块后生成样本为 0.680。

在潜在高斯近似下，该模型给出两条闭式结果，见迁移四步：风格间的最优传输映射是平移，缺陷约束下的投影是高斯条件均值。这两条结果只对模型假定的潜在分布成立，不直接推出原尺度化合物谱上的最优性。

6.2.3 感官画像与风味指纹

感官画像由问题一的全数据模型给出。对风格 s 抽取 1,000 个潜变量样本，反变换得到化合物谱，经问题一模型得到 50 维连续预测与等级分布。问题一主模型只用化学特征、不用风格，画像因此完全由生成的化合物谱决定。问题一中化学模型未胜过风格基线的维度单独标注，这些维度上风格之间的画像差异不可靠。

风味指纹由化学指纹与感官指纹两部分组成。化学指纹取标准化潜空间偏移 $\delta_{sj} = (\hat{\mu}_{sj} - \bar{u}_j)/\sqrt{\Sigma_{W,jj}}$，即该风格在化合物 j 上偏离全体均值多少个风格内标准差，报告绝对偏移最大的 10 项。感官指纹取画像中位数偏离全部风格合并画像中位数最大的维度。化学解释在指纹产生后撰写，不改变指纹或模型。

6.2.4 跨风格迁移四步

迁移映射是秩变换后的高斯近似下的潜空间平移，分四步执行。

第一步是平移。在式 (7) 的模型下，协方差相同的两个高斯分布之间使潜空间代价最小的传输映射是平移：

$$\tilde{u} = u_b + \Delta_{s\to t}, \qquad \tilde{x}_j = Q_j(\Phi(\tilde{u}_j)). \tag{9}$$

式 (9) 中 $\Delta_{s\to t} = \hat{\mu}_t - \hat{\mu}_s$ 是目标风格与源风格的潜空间均值差，每款啤酒保留其相对本风格的个体偏离。

第二步是化学约束投影。化学层约束换到潜空间后，$x'_j \le b_j$ 等价于 $u'_j \le \beta_j$。求在潜空间马氏距离下最接近平移终点的可行点：

$$u^* = \arg\min_{u'} \ (u' - \tilde{u})^\top \Sigma_W^{-1} (u' - \tilde{u}) \quad \text{满足} \quad u'_j \le \beta_j, \ j \in \mathcal{D}_c. \tag{10}$$

约束只涉及 9 个坐标，用有效集法求解，其闭式解为 $u^* = \tilde{u} - \Sigma_{W,\cdot A}\,\Sigma_{W,AA}^{-1}(\tilde{u}_A - \beta_A)$，等于在缺陷坐标固定于上界时的条件均值。缺陷化合物被压回上界时，与之共变的化合物按风格内协方差一起调整。只截断缺陷列会产生数据中少见的组合，因此用投影而非截断。

第三步是感官路径搜索。感官层约束经问题一的树模型计算，不可微也不保证单调，不并入投影。沿路径 $u(\alpha) = u_b + \alpha(u^* - u_b)$，$\alpha$ 从 0 到 1、步长 0.05，取满足感官约束的最大网格点 α^* 作为交付。两端点都满足化学约束，可行集为凸集，整条路径满足化学约束。

第四步是原尺度复查。对交付的化合物谱在附件一原尺度逐列复查化学层上界，并用 231 列输入复查感官层。复查不通过的候选视为不可行，α^* 取下一个可行网格点。

图 11 给出问题三的完整流程。风格和化学谱经秩变换与风格条件潜在高斯模型，经留出啤酒的保真、新颖性、可用性检查，得到感官画像与风味指纹，再经潜空间平移、化学投影、感官路径与原尺度复查完成迁移。



图 11: 问题三方法流程：风格和化学谱经秩变换与风格条件潜在高斯模型生成化合物谱，迁移经潜空间平移、化学投影、感官路径与原尺度复查。

6.3 实验设计

表 14 按数据与生成列、表示、模型与选参、划分、评价器、对照生成器、画像、迁移约束、迁移对照九个环节列出正文报告的设置。验收标准在预运行后固定，属工程标准，不是独立验证，在正文如实说明。

表 14: 问题三实验设置与对照

环节	正文报告的设置	控制或检验什么
数据与生成列	250 款、22 种细分风格、225 个生成列；综合指标由成分派生，内标取训练中位数；4 个小样本风格标为证据有限	生成对象是单体化合物
表示	训练折经验分布映入正态得分；共同下限为并列原子，取截断正态条件期望	不同尺度与未检出状态统一处理
模型与选参	风格均值收缩 $\kappa \in \{0,1,2,5,10,20\}$，因子数 $k \in \{2,5,10,15,20,25,30\}$，纯因子与因子加模块块两种结构，对角与 Ledoit–Wolf 作对照；外层训练集内 5 折按留出潜空间评分选参	选参与报告分离，风格内共变的结构
划分	生成器按风格分层、以单款啤酒为单位的 5 折 × 5 次重复；画像用问题一的日期组外层划分	化学测量与品评日期无关，画像防止同日泄漏
评价器	随机森林 500 棵树只用真实啤酒训练；C2ST 置换 200 次并做真实对真实检验；按啤酒 bootstrap 2,000 次	判别器与生成器不共享高斯假设，检验能力由阳性对照给出
对照生成器	纯因子、无风格、逐列独立、复制、风格内插值五个对照	风格条件、化合物共变、新颖性各由一个对照检验
画像	每个风格生成 1,000 个化合物谱，经问题一全数据模型与残差池得到等级分布	画像只由化学谱决定
迁移约束	化学层 9 列，阈值取附件八均值口径；感官层 6 个缺陷维度预测等级不升高；沿路径 α 取 0 到 1、步长 0.05，原尺度复查	把任务的不恶化写成可检验的条件
迁移对照	平移、截断、原尺度平移三个消融，原谱不变、截断加感官搜索、检索真实目标风格三个同约束对照	约束、投影与潜空间各自的作用

6.4 结果

正式结果尚未交付，下列图表只规定内容与形式。

6.4.1 生成器验证

表 15 转置排版，行为指标、列为生成器。指标按取值层、分布层、新颖性三层分组。取值层包括下限比例误差与每款下限列数。分布层包括合并与条件 C2ST AUC、训练判生成与训练判训练之差、风格内相关误差、模块内相关。新颖性包括判别器距离比与近复制率。列为五种生成器、真实留出参照与验收阈值，单元格写数值与 95% 置信区间。

表 15: 问题三生成器验证（占位，正式产物验收后填写）

指标	主模型	纯因子	无风格	逐列独立	真实留出参照	验收阈值
取值层：下限比例误差	占位	占位	占位	占位	占位	占位
取值层：每款下限列数	占位	占位	占位	占位	占位	占位
分布层：合并 C2ST AUC	占位	占位	占位	占位	占位	占位
分布层：条件 C2ST AUC	占位	占位	占位	占位	占位	占位
分布层：风格内相关误差	占位	占位	占位	占位	占位	占位
分布层：模块内相关	占位	占位	占位	占位	占位	占位
新颖性：判别器距离比	占位	占位	占位	占位	占位	占位
新颖性：近复制率	占位	占位	占位	占位	占位	占位

6.4.2 化学指纹与生成谱

图 12 为三栏，分别为 Tripel、Kriek、Lambic。每栏取化学指纹绝对偏移最大的 10 个化合物，同一模块只取一个。每行一个化合物，箱线表示 1,000 个生成样本，散点表示该风格的真实啤酒，菱形与横线为化学指纹及其 bootstrap 区间。

占位图：三栏化学指纹，每栏取偏移最大的 10 个化合物，箱线为生成样本，散点为真实啤酒。出图后替换为 \includegraphics。

图 12: 化学指纹与生成谱。行名为化合物，箱线表示生成样本，散点表示真实啤酒，菱形为化学指纹及其区间。

6.4.3 感官画像

图 13 为三栏风格，行为 50 个维度，按六个维度组分块。点与横线为生成画像的中位数及 10% 到 90% 区间，叠加同风格留出真实啤酒的折外预测中位数与观测均分中位数。问题一未胜过风格基线的维度用灰色标签。

占位图：三栏感官画像，行为 50 个维度，点为生成画像中位数与区间，叠加真实啤酒的预测与观测。出图后替换为 `\includegraphics`。

图 13: 感官画像。三栏为三个风格，点与横线为生成画像的中位数与区间，叠加真实啤酒的预测与观测中位数。

6.4.4 迁移的代价与收益

表 16 为 Pils/Lager 到 Tripel 的 11 款逐款结果，列为啤酒、迁移强度、源谱与交付谱的目标风格概率、结论类别、起作用的化学约束数、首个不可行点违反的感官维度、原尺度改变列数与保留度。图 14 两栏对应此表，左栏为各方法的 Tripel 概率，右栏为 11 乘 15 的约束矩阵，直接证明缺陷不恶化。

表 16: Pils/Lager 到 Tripel 逐款迁移（占位，正式产物验收后填写）

啤酒	α^*	源谱 P(Tripel)	交付谱 P(Tripel)	结论类别	化学约束数	违反维度	保留度
占位	占位	占位	占位	占位	占位	占位	占位

占位图：左栏为各方法的目标风格概率，右栏为 11 乘 15 约束矩阵。出图后替换为 \includegraphics。

图 14: 迁移的代价与收益。左栏为各方法的 Tripel 概率，右栏为化学与感官约束矩阵，直接证明缺陷不恶化。

6.4.5 风格对热图

图 15 为 22 乘 22 热图，格内颜色为源风格啤酒达到参照范围的比例，对角留空，行列按风格潜空间均值的层次聚类排序，行尾附平均迁移强度的条形边栏。



图 15: 风格对热图。行列按风格潜空间均值的层次聚类排序，图注写明风格对之间不独立。

6.4.6 文字报告

正式结果验收后，文字报告选出的因子数与收缩强度及其在各外层折的频数、风格离散比超过 1.5 的风格、画像验证的中位数 Spearman、平移后违反化学约束的比例、原尺度复查不通过的候选数、以及敏感性的主要结论与例外。迁移只沿一条线段搜索，迁移强度小只说明该路径受限，不说明不存在满足约束的目标风格化合物谱。

7 模型评价与推广

本节用一张结论与证据表收束全文，随后列出优势与不足各若干条。每条结论都指向支撑它的图表编号，并注明适用边界。

表 17: 主要结论、支撑证据与适用边界

结论	支撑证据	适用边界
化学特征对品评小组均分有可复现的预测能力，主模型等级 MAE 0.479，显著优于只知风格的基线 0.527	表 8、图 3	连续 R^2 只有 0.184，信度中位数 0.53，预测能力有限
只用附件无法还原原始等级，两阶段对照 C1 等级 MAE 0.786	表 8、表 5	C1 按自身规则选定等级映射，仍以同一原始等级为真值
多数维度可靠支持的关键化合物是 1 到 2 个，第 3 位以报告为主	表 12、图 8	Top-3 是关联结果，不是因果主张
选择规则由模拟还原实验确定,只用化学矩阵,不依赖感官数据	图 6	模拟假定少数化合物按秩线性可加，与真实结构存在差异
酯类加标在独立实验中一致提高酯类评分，酒花与苦味对照不变	表 13	混合物含 6 到 7 种化合物，不能归因到单一化合物
风格条件生成模型在留出啤酒上通过大部分验收项，缺陷约束在几乎所有风格对上起作用	表 15、图 12	验收阈值在预运行后固定，属工程标准，不是独立验证
迁移只沿一条线段搜索，α^* 小不说明不存在满足约束的目标风格谱	图 14	结论针对选定路径与问题一模型
问题一主输出向中间等级收缩，几乎不给出 5 到 6 级，第二输出保持等级分布	表 9、图 4	这是以等级 MAE 为主指标的直接后果

7.1 优势

问题一预测品评等级，问题二找出关键化合物，问题三生成风格条件化合物谱并迁移，三个问题各有一条可独立验证的路径。问题一以逐品评员原始评分的啤酒均分为目标和真值，不依赖附件四从标准化值还原 0 到 6 分的换算；只用附件换算的对照 C1 端到端等级 MAE 为 0.786，主模型为 0.479，差距可直接读出。问题一的主指标、主输出、成功标准与对照胜出时的处理都在正式运行前写定，正式运行后按声明执行，没有按结果切换模型或规则。问题二的稳定性用日期组重抽量化，模拟还原实验只用化学矩阵，独立于感官数据，回应了根据结果调整规则的质疑。问题三的迁移把题面的不恶化要求写成化学层与感官层两层可检验的约束，并在潜空间与原始尺度两处复查。

7.2 不足

化学数据只解释品评小组均分的一小部分方差，连续 R^2 为 0.184，信度（同一批评分随机分两半后相关的外推值）中位数为 0.53，后者给出可解释方差的上限，两者并列说明预测能力接近测量噪声的上限。问题一的主输出向中间收缩，几乎不给出 5 到 6 级，而真值中这两个等级占 0.968%。随机森林对照的等级 MAE 为 0.472，低于主模型的 0.479，但 QWK 为 0.251，低于主模型的 0.290；主模型是运行前选定的模型，不是外层比较中误差最低的模型。问题二的第 3 位基本不稳定，入选频率按名次约为 0.60、0.36、0.22，与主要对照方法 M3 的 Top-1 一致比例只有 0.45，这是不同估计对象的差异，不是某一个错了。问题三的生成样本比真实啤酒更接近风格均值，风格判别器对真实啤酒的识别准确率为 0.550，对生成样本为 0.481，生成样本围绕收缩后的风格均值分布。问题三的感官层约束依赖问题一在缺陷维度上的预测，这些维度多为零分主导、信度低，化学层约束才是主要保证，感官层是模型层面的检查。