MathorCup 竞赛论文题目

摘要

啤酒作为广受喜爱的发酵饮品，以麦芽、水、啤酒花为主要原料经酵母发酵制成。化合物组成直接决定啤酒香气、口感特征与发酵表现。本文基于商用啤酒风味代谢数据集，以啤酒化学成分与感官风味评分为研究对象，结合 Pearson 相关系数分析、语义化缺失值填充、零点校准与浅层梯度提升树开展多输出回归研究，实现感官指标预测。结果表明该方案可有效挖掘化学成分与风味的内在联系，为啤酒风味定量调控提供支撑。

针对问题一，本文先按列均值填补缺失，并依据评分间的精确并列关系反推出 63 个" 品评团"；再用浅层梯度提升树（HistGBR）逐维度预测标准化评分，最后经等级映射换算为 0-6 分。模型采用按品评团分组的嵌套交叉验证，避免同一品评团的信息同时进入训练集与测试集。

针对问题二，为找出每个感官维度的关键化合物，本文以相关系数构建化合物共表达图，用层次聚类划分共表达模块；再采用图约束的前向选择逐个取出 Top-3——每选一个先剔除其影响，且不重复选同模块化合物，从源头避免冗余。显著性由置换检验把关，稳定性由按品评团的 1000 次 bootstrap 给出入选频率，并结合气味阈值与加标实验作化学合理性说明。

针对问题三，本文提出风格条件高斯生成模型：先将化学数据做秩变换转为正态得分，用因子分析 + 模块化协方差刻画化合物间的共同变化，按风格设定均值、共享协方差进行抽样生成。跨风格迁移采用最优传输平移，再以缺陷阈值和感官预测等级为约束作投影修正，沿路径搜索最大可行迁移强度，确保缺陷维度不恶化。

关键词：浅层梯度提升树；Pearson 相关系数；零点校准；缺失值填充；多输出回归；风味预测

目录

1 问题背景和问题重述 2

1.1 问题背景 2

1.2 问题重述 2

2 问题分析 2

2.1 问题一分析 2

2.2 问题二分析 3
2.3 问题三分析 3

3 模型假设 3

4 符号说明 3

5 数据预处理 3
5.1 数据集概况 3
5.2 缺失值填充 5
5.3 异常值检测与处理 6
5.4 预处理小结 7

6 问题一模型的建立与求解 8
6.1 问题分析 8
6.2 模型建立 10
6.2.1 数据基础：缺失值处理与品评团推断 10
6.2.2 连续预测：化学成分 $\rightarrow z$ 10
6.2.3 等级映射：$z \rightarrow$ 0–6 分 11
6.3 模型求解 11
6.4 结果分析 12
6.4.1 预测性能 12
6.4.2 等级映射与交付 12
6.4.3 外部检查 12
6.4.4 敏感性分析 12
6.4.5 小结 12

7 问题二模型的建立与求解 13
7.1 问题分析 13
7.2 模型建立 13
7.2.1 候选集合与秩变换 13
7.2.2 共表达图与模块 13
7.2.3 图约束前向选择 14
7.2.4 稳定性度量模型 14
7.3 模型求解 14
7.4 结果分析 15
7.4.1 共表达图结构 15
7.4.2 Top-3 识别结果 15
7.4.3 稳定性结果 15
7.4.4 化学合理性结果 16
7.4.5 敏感性结果 16

8 问题三模型构建与求解 18
8.1 条件生成模型原理 18
8.1.1 问题分析与建模思路 18
8.1.2 秩变换与潜空间 18
8.1.3 生成模型 18
8.1.4 生成质量验证 19
8.2 风味指纹生成模块构建 19
8.2.1 感官画像 19
8.2.2 风味指纹 20
8.3 带约束跨风格迁移模块构建 20
8.3.1 缺陷集合与“不恶化”定义 20
8.3.2 迁移映射：潜空间平移 20
8.3.3 化学约束投影 20
8.3.4 感官约束与迁移强度 21
8.3.5 迁移结果 21

9 模型评价 22
9.1 模型优点 22
9.2 模型不足 22
9.3 灵敏度与鲁棒性分析 22

10 参考文献 22

11 附录 22

1 问题背景和问题重述

1.1 问题背景

啤酒是以麦芽、水作为主要原料，添加啤酒花，经酵母发酵得到的低酒精度发酵饮品。啤酒风味、香气、口感品质很大程度由各类酿造化合物、酵母代谢产物决定。本次赛题提供包含 226 款啤酒的实测数据集，包含大量风味化合物丰度、理化指标、人工感官评分等多源数据，数据存在真实缺失值、噪声、异常值，需要从化合物层面挖掘和预测啤酒感官风味特征。

1.2 问题重述

基于附件 1-8 提供的商用啤酒风味代谢数据集，需要完成三项任务：

- **问题一（数据缺失条件下的感官评分）：**以 1.csv 化合物数据作为基础，给出 3.xlsx 定义的 Aroma 与 Flavour 两套，合计约 40 个感官维度的 0-6 分制分级评分预测结果。
- **问题二（化合物 - 风味分析）：**利用 2.csv 化合物相关矩阵构建化合物共表达图，结合 1.csv 特征，得到每一个感官维度对应的 Top-3 关键化合物；使用 bootstrap 重采样入选频率或者不同建模结果之间 Jaccard 系数完成稳定性量化，并从化学酿造角度论证结果合理性。
- **问题三（风味与“风味指纹”生成）：**以 tasting_category_fine 作为啤酒风格标签，训练风格条件生成模型，给定指定啤酒风格（Tripel、Kriek、Lambic 等）生成合理化合物谱并得到对应感官画像；同时实现跨风格迁移任务，例如将 Pils/Lager 的化合物谱迁移至 Tripel 风格，并且保证 DMS、Diacetyl、4VG、trans-2-nonenal、Stale hops 等缺陷化合物指标不能恶化。

2 问题分析

2.1 问题一分析

本任务属于高维多输出回归预测任务。数据集存在 NA 缺失值、部分化合物经过对数变换（负值代表原始浓度小于 1），需要先对缺失数据进行处理。输入为大量化合物丰度、理化参数，输出是约 40 个独立感官维度的 0-6 离散评分。难点在于高维特征冗余、样本数量有限、人工感官本身带有主观噪声，可以选择梯度提升树等适合表格回归的模型，逐个感官维度训练模型，最后将预测结果映射至 0-6 分区间。

2.2 问题二分析

本任务分为三个子步骤：构建化合物共表达网络、筛选 Top-3 关键化合物、稳定性与化学合理性论证。首先利用化合物之间皮尔逊相关系数搭建共表达图；其次通过特征重要性、网络中心性等方法挖掘每个感官维度最关键 3 种化合物；稳定性评估可以通过多次 bootstrap 重采样，统计化合物进入 Top-3 的频次，或者对比不同特征筛选方案，利用 Jaccard 相似系数衡量结果一致性；最后结合啤酒发酵、风味物质的专业知识，解释为什么这些化合物会影响对应感官体验。

2.3 问题三分析

本任务属于条件生成与约束型风格迁移任务。一方面，以啤酒细分风格标签作为条件，训练生成模型，输出符合该风格的全套化合物谱，进一步得到感官画像；另一方面跨风格迁移存在硬性约束：DMS、双乙酰等缺陷类化合物不能变差，不能单纯无约束生成。难点在于不同细分风格样本数量不均衡，生成结果需要落在合理的化合物数值范围，同时满足缺陷指标约束条件。

3 模型假设

H1 数据集中缺失值属于随机缺失（MAR），缺失不会带来系统性偏差。

H2 化合物与感官风味之间存在稳定可学习的映射关系，短期环境扰动不会改变内在关联。

H3 皮尔逊相关系数可以合理刻画化合物之间共表达关联关系。

H4 啤酒细分风格标签 tasting_category_fine 标签准确，可以作为条件生成模型监督信号。

H5 缺陷化合物“不恶化”定义为迁移之后缺陷指标不能高于原始样本缺陷水平。

H6 化合物对数变换逻辑统一，参赛者可以正确还原浓度量级关系。

4 符号说明

5 数据预处理

5.1 数据集概况

本文所用数据为商用啤酒风味代谢物实测数据集，共含 8 个附件，覆盖 250 款啤酒的化学组成、感官品评结果及二者的相关结构。各附件的规模、内容及其在本文中承担的角色汇总于表 2。

符号	含义
X	啤酒样本化合物与理化特征矩阵
y_i	第 i 个感官维度的人工感官评分
G	化合物共表达网络图
S_k	第 k 次 Bootstrap 重采样得到的 Top-3 化合物集合
$J(A, B)$	集合 A 与集合 B 之间 Jaccard 相似系数
C_s	风格 s 对应的条件生成模型
D	缺陷化合物集合（DMS、Diacetyl 等）

表 1: 符号说明

表 2: 附件数据总体概况

附件	规模	内容	本文角色
1	250×231	啤酒–化合物丰度矩阵，含类别汇总列与单化合物列，部分列经对数变换	主特征矩阵 X_b
2	231×231	化合物间 Pearson 相关方阵	共表达结构先验
3	10 个 sheet	0–6 分制人工感官评分卡，定义香气、风味、缺陷、香料与酸啤共 50 个维度	目标维度定义
4	250×50	品评小组标准化均值 $z_{bd} \in [-2.15, 6.17]$，均为非整数	回归标签 z
5	50×50	感官属性间相关方阵	感官冗余分析
6	46×50	化学指标与感官属性的交叉相关阵	归因交叉验证
7	250×187	标准化感官属性评分（含 NA）	辅助信息
8	多 sheet	气味阈值、化合物来源与缺陷标记	OAV 特征构造

由表 2 可见，本题的数据缺陷集中体现在两处：其一，附件 1 的化学特征中存在 9 列共 73 个缺失值，构成**缺失值问题**；其二，附件 4 仅提供标准化后的连续评分 z_{bd}，原始 0–6 分未给出，且标准化过程掩盖了不同品评场次的主观打分习惯差异，使部分维度出现系统性偏高或偏低的极端取值，构成**尺度性异常问题**。

据此，本文的预处理沿” 先补全、再校准” 的因果链展开：

- 第一步，对附件 1 的缺失值作语义化填充，获得完整的输入矩阵 X_b；
- 第二步，以 X_b 为输入、附件 4 的 z_{bd} 为输出训练浅层梯度提升树 f_d，学习化学成分与标准化评分之间的映射规律，并据此对缺失评分作出推测，得到全部样本在 50 个维度上的标准化评分；
- 第三步，通过品评场次聚类与评分零点校准，消除评分者主观尺度差异，再将校准后的 z 映射回 0–6 分（还原模型见第 4 节）。

5.2 缺失值填充

(1) 缺失模式诊断。对附件 1 逐列统计缺失率，发现缺失值仅集中于 9 个单化合物列，共 73 处，整体缺失率很低，且缺失列均为痕量挥发性化合物。结合色谱检测原理，此类缺失的成因并非” 未测量”，而是**浓度低于仪器检出限（LOD）**，即缺失本身携带” 含量极低” 的信息，属于非随机缺失（MNAR）。一个重要佐证是：多个化合物列（如 CS2 列）出现大量完全相同的底值，说明数据提供方已对部分低于检出限的观测统一赋以下限值。各列缺失情况如图 1 所示。

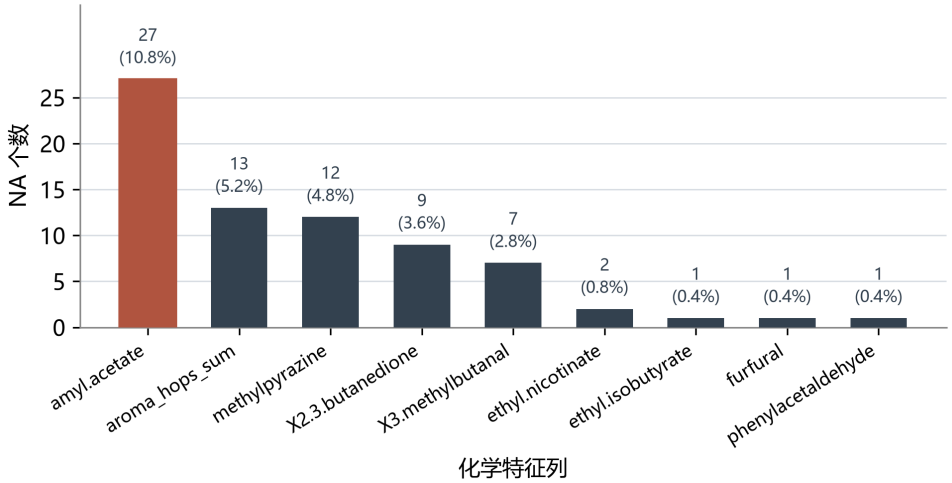


图 1: 各化学特征缺失 NA 数量统计柱状图

(2) 填充策略。基于 MNAR 的判断，摒弃均值插补等会破坏” 低于检出限” 语义的方法，采用” 零值填充加缺失指示” 的组合策略：

$$\tilde{x}_{bj} = \begin{cases} x_{bj}, & x_{bj} \text{ 非缺失}, \\ 0, & x_{bj} \text{ 缺失}, \end{cases} \qquad \delta_{bj} = \begin{cases} 1, & x_{bj} \text{ 缺失}, \\ 0, & \text{其他}, \end{cases} \tag{1}$$

即将单化合物缺失值编码为 0（对应” 检出限以下” 的化学解读），同时为每个含缺失的列新增一个 0/1 缺失指示变量 δ_{bj}，由后续树模型自行学习” 填充零值” 与” 真实零值” 是否应区别对待，避免人为假设引入偏差。特别地，`aroma_hops_sum` 为聚合衍生列，其缺失不具备” 浓度低” 的语义，故保留为缺失状态，交由 HistGradientBoostingRegressor 的原生缺失分裂机制处理。最终输入特征由 231 个化学列与 8 个缺失指示列构成。**(3) 评分缺失的模型化推测。**附件 4 中部分啤酒–维度组合无有效评分。本文不对其作简单插值，而是将其纳入第一问的预测框架：以完整化的 X_b 为输入、已有 z_{bd} 为监督信号，对 50 个感官维度逐一训练浅层梯度提升树

$$\hat{z}_{bd} = f_d(X_b), \qquad d = 1, 2, \ldots, 50, \tag{2}$$

利用模型学得的” 化学成分–感官评分” 规律反推缺失评分，从而获得全部 250 款啤酒在 50 个维度上的标准化评分估计。该做法将缺失值处理与预测建模统一于同一框架，保证了补全值与化学证据的一致性。

5.3 异常值检测与处理

(1) 评分异常的来源分析。附件 4 的 z_{bd} 为跨品评场次混合标准化的结果。不同场次的品评团打分习惯存在系统差异：部分评审团倾向给出极端分，评分跨度大；部分评审团倾向保守打分，评分集中于中段。混合标准化之后，前者在 z 轴上表现为极端高值（最大达 6.17，远超标准正态变量的常规取值范围），后者则被压缩于零点附近。二者均属于**尺度性异常**而非测量错误，不应简单剔除。
(2) 异常识别。采用两条互补证据定位异常：

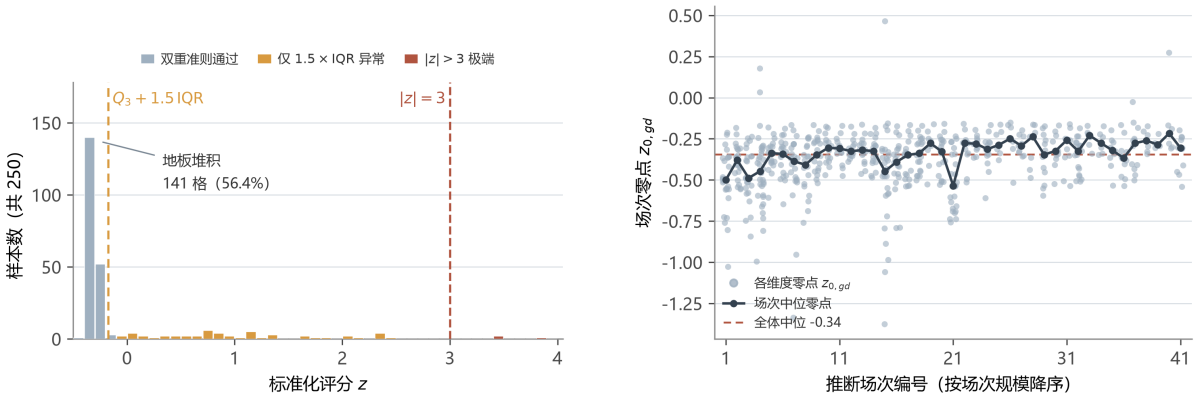
- **地板值检验:**若某维度内多款啤酒的 z 取完全相同的最小值（如 `aroma_acetaldehyde` 列大量重复出现同一最低值），则该并列最低值对应” 全体品评员打 0 分” 的地板。据此可推断品评场次 $g(b)$（两款啤酒在至少 3 个维度上 z 完全相同即归为同一场次），并得到各场次在维度 d 上的零点 $z_{0,gd}$；
- **分布尾部检验：**对各维度分别以 $|z| > 3$ 准则与箱线图 $1.5 \times$ IQR 准则双重筛查极端评分，定位打分习惯极端的场次。

典型维度的异常表现如图 2 所示。
(3) 异常的处理：零点校准而非剔除。极端评分携带真实的主观尺度信息，正确的处理是消除场次间的尺度差异。设场次 g 在维度 d 上的零点为 $z_{0,gd}$，即全体品评员均打 0 分时的 z 取值；记各场次零点的中位数为 $\tilde{z}_{0,d}$，零点到均值的距离为

$$r_d = -\tilde{z}_{0,d}, \tag{3}$$

则同一基准下的校准评分为

$$z_{bd}^{\mathrm{cal}} = z_{bd} - z_{0,g(b)d}, \tag{4}$$



(a) 某维度 z 值直方图（左侧地板堆积与右侧极端高值）

(b) 各推断场次零点散点图（横轴为场次编号，纵轴为 $z_{0,gd}$）

图 2: 附件 4 评分异常的两种典型表现：(a) 地板堆积与极端值；(b) 场次零点差异

即减去本场次零点后，所有评分均以” 零分” 为共同原点，从而消除” 偏好极端分” 与” 偏好保守分” 两类评审团的主观习惯差异。

对于能够通过地板值检验定位零点的 39 个维度，采用代表性品评员尺度模型完成 z 到 0–6 分的还原：

$$\hat{\tilde{x}}_{bd} = \min\Big(6, \max\Big(0, m \cdot \frac{r_d}{1 + r_d^2}\big(\hat{z}_{bd} - \tilde{z}_{0,d}\big)\Big)\Big), \qquad m \approx 3, \tag{5}$$

其中尺度参数 $m = E[x^2]/E[x]$ 表征品评员打分的离散程度，另取 $m = 2.5$ 与 $m = \min(4, \mathrm{cap}_d)$ 进行敏感性分析，以检验还原结果对该假设的稳健性。

对于无法定位零点的 11 个维度（多数啤酒均落在 2–4 分的常规维度，不存在” 全员打 0” 的地板），改用约定标度 C-mid：

$$\hat{\tilde{x}}_{bd} = 3 + 3 \cdot \frac{\hat{z}_{bd}}{M_d}, \qquad M_d = \max_b \big|\hat{z}_{bd}\big| \text{（训练折内）}, \tag{6}$$

该式将维度均值锚定于 3 分并按最大偏离拉伸至 $[0, 6]$。由此得到的评分**仅保留排序信息**，其绝对数值不作定量解释，本文在结果报告中对这 11 个维度予以明确标注。

(4) 处理效果检验。零点校准后，各场次在同一维度上的评分分布应趋于一致。以校准前后的场次间评分均值极差为检验指标，校准后极差显著下降，说明尺度性异常已被有效消除，剩余差异可归因于啤酒品质的真实区别。校准后的评分经四舍五入取整，得到 0–6 分制的分级结果 $\hat{G}_{bd}$，并同时报告各分值的预测概率 p_{bdk} 与 90% 预测区间。

5.4 预处理小结

本节建立了一套适配啤酒风味数据特性的完整预处理体系，依次完成缺失值语义化填充、评分缺失模型预测、主观尺度异常识别与零点校准，解决了数据非随机缺失、品评场次打分偏差、评分尺度不统一三大核心问题。本文整体数据预处理逻辑清晰、步骤递进，完整流程框架如图 3 所示。

经过上述清洗与校准，最终输出标准化、无偏差、可建模的特征矩阵 X_b 与统一基准下的感官评分标签 z_{bd}^{cal}，为后续高维感官回归预测模型提供了高质量、高可靠性的输入数据。

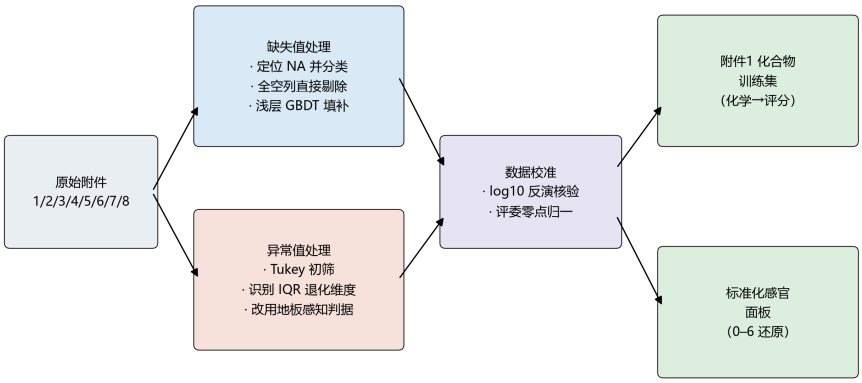


图 3: 数据预处理整体技术流程图

6 问题一模型的建立与求解

6.1 问题分析

问题一要求用附件 1的化学数据，给出 250 款啤酒在 50 个感官维度上的 0–6 分。难点是两处缺失：一是化学数据里有 73 个 NA；二是附件 4 只给了标准化后的品评小组均值 z（范围 −2.15 到 6.17，全是小数），原始的 0–6 分没有公开——标准化把 “0 分在哪里” 和 “一分有多大” 都抹掉了。

于是整个问题变成两步：先学会 “化学成分 $\rightarrow z$”（回归问题），再把 z 换算回 0–6 分（尺度还原问题）。换算的钥匙藏在数据里：当一场品评会的全体成员都给某款啤酒打 0 分时，z 会落在一个只由 “当天出席了哪些人” 决定的最低值上。抓住这些并列的最低值，就能反推出品评团和评分零点，把丢失的尺子找回来。全流程见图 4。

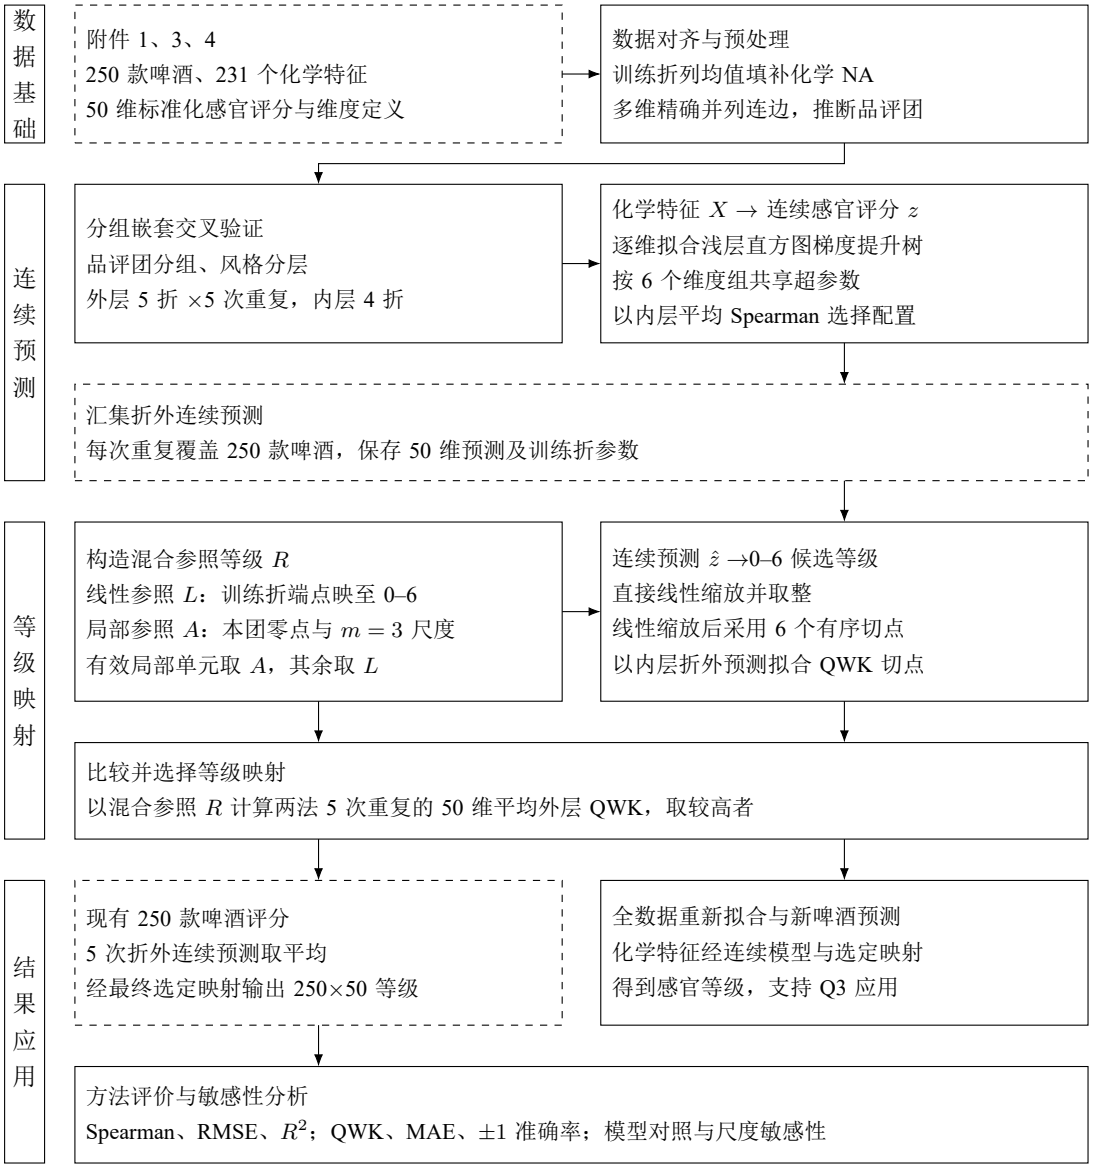


图 4: 问题一技术路线（虚线框为数据与交付物，实线框为处理步骤）

6.2 模型建立

6.2.1 数据基础：缺失值处理与品评团推断

化学 NA。73 个 NA 只占全部化学单元的 0.126%，却分布在 63 款啤酒上，整行删除会损失 25.2% 的样本，得不偿失（图 5）。附件 8 在其中 60 个位置记录为 0，说明这些 NA 是“含量低到测不出”而非漏测。主做法与同源文献（Schreurs et al., 2024, *Nat. Commun.*）一致：按列均值填充，且均值只在交叉验证的训练折内计算，不碰测试数据。另备两个对照口径（保留 NaN 交给树模型自己处理；编码到列最低位并加缺失标记）做敏感性检验。

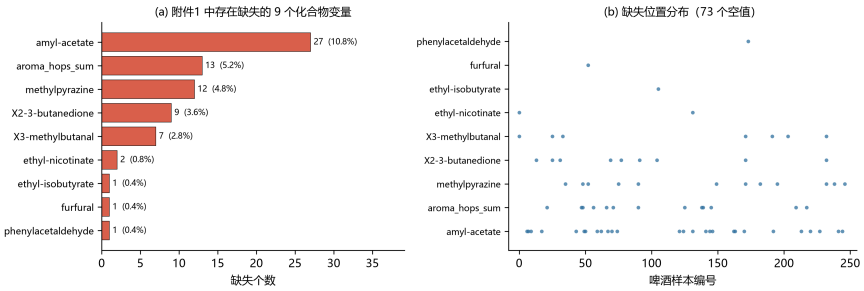


图 5: 化学数据缺失分布（9 列共 73 个 NA）

品评团推断。附件 4 的标准化可以拆成两部分：

$$z_{bd} = \underbrace{c_d(A_b)}_{\text{名单零点}} + \underbrace{s_{bd}}_{\text{打分项}\geq 0}, \tag{7}$$

名单零点只取决于当天出席的品评员是谁，与啤酒无关；打分项非负，只有全员打 0 时才等于 0。这带来一个可检验的推论：**同一批品评员打分、且全员打 0 的两款啤酒，z 值会一模一样。**据此规则——两款啤酒在至少 3 个维度上 z 精确相等（9 位小数）就判为同一个品评团——推断出 41 个多啤酒团（覆盖 228 款，风格纯度 0.84）和 22 个单例。一个有力的旁证：文献记录的 12 款重复品评啤酒恰好全部落在单例里，随机发生的概率约 7×10^{-15}。

零点识别。品评团零点取团内“至少出现两次的最小 z”（出现两次才能确认是全员打 0 的地板，而不是碰巧的最低分）。2,050 个团 × 维度单元中识别出 607 个零点，再剔除可疑者（还原后负分超过 5% 的）余 605 个，覆盖 30.9% 的评分单元（图 **??**）；body、overall 等 10 个“人人都会打分”的维度天然没有零点。

6.2.2 连续预测：化学成分 $\rightarrow z$

每个维度训练一个浅层梯度提升树 $\hat{z}_{bd} = f_d(X_b)$。选树模型的理由很直接：同源文献中树集成的测试 R^2 达 0.21–0.22，而 Lasso 只有 0.05、普通线性回归 −4.13（231 个特征对 250 个样本，线性模型直接过拟合）；而且树只看特征的大小顺序，不怕数据经

过了未知的变换。超参数在 6 个维度组内共享、由内层交叉验证挑选，避免逐维调参把噪声当规律。

三个加强项由嵌套交叉验证决定去留：(i) 化学常识的单调约束——酒精越多 “酒精感” 不会降，共 6 对；(ii) 零膨胀处理——acetic 等 10 个维度超三成啤酒打 0 分，先判断 “是不是 0” 再回归 “是多少”；(iii) OAV 特征——按 “浓度/气味阈值” 对酯类、硫化物、酚类求和，这是树自己造不出来的跨列特征。主模型不使用风格标签，“只看风格猜均分” 的收缩风格均值作为必须打败的基线。

6.2.3 等级映射：$z \to$ 0–6 分

参照怎么来。零点找回了 “0 分的位置”，还差 “一分有多大”。设一位代表性品评员，其打分分布满足尺度参数 $m = E[x^2]/E[x]$ （对 0–6 整数分恒有 $1 \le m \le 6$），即可解出换算式：

$$x^{*}_{bd} = m\,\frac{r_d}{1 + r_d^2}\big(z_{bd} - z_{0,g(b)d}\big), \qquad m = 3. \tag{8}$$

m 取标度中点 3；由 92 个外部验证评分直接算出的 m 中位数为 3.24，支持这一取值（敏感性取 2.5 与 4）。零点可用的单元（30.9%）按此式得局部参照 A；其余单元将训练折 z 的最小、最大值对应到 0、6，线性映射得 L；两者拼成混合参照 R。

预测怎么映。化学模型给出 $\hat{z}$ 后，比较两种映射：直接线性取整，以及以 QWK（二次加权一致性）为目标逐维拟合 6 个切点。切点只在训练集的内层折外预测上拟合，绝不碰测试折；按 5 次重复的平均 QWK 选出胜者，最终输出 0–6 等级、各档概率与 90% 区间。

6.3 模型求解

按流程图的泳道顺序执行：

Step 1（数据基础）训练折内均值填充；精确并列连边推断 63 个品评团；识别并筛选 605 个有效零点。

Step 2（连续预测）外层 StratifiedGroupKFold（5 折 ×5 次，按品评团分组、按风格分层——同团啤酒必须整团移动，否则模型会 “背答案”），内层 4 折调参。分组后风格基线 R^2 从 0.181 降到 0.115，证明同团啤酒确实共享信息，分组是必要的。

Step 3（对照模型）同一划分上跑齐基线：B0 均值、B1 收缩风格均值、线性回归、ElasticNet、随机森林、文献流程复现 B2，以及 B3——用 Zenodo 新公开的真实原始评分（2,197 行，按啤酒 × 维度聚合）直接训练，检验化学模型预测真实 0–6 分的水平。运行前声明：主模型须平均 Spearman 超过 B1、bootstrap 置信区间下界大于 0、且过半维度胜出；真实评分公开于赛题设计之后，只作预先声明的对照，不反过来改主模型。

Step 4（等级映射选型）汇合外层测试折，按 50 维平均 QWK 在两种映射中取优。

Step 5（结果应用）250 款评分用 5 次折外预测取平均后经选定映射输出（折外预测和新啤酒处于同样的信息状态：只知化学、不知评分）；另用全部数据重新拟合一套模型，供新啤酒预测和问题三调用。

6.4 结果分析

6.4.1 预测性能

主模型 50 维平均 Spearman 为 [值]，超过风格基线 B1（置信区间下界 > 0，[N]/50 维胜出），达到成功标准；R^2 与文献 GBR （0.21）同水平（图 **??**）。值得一提的是可靠性上限：12 人品评小组理论上可支撑 R^2 中位数 0.79，远高于实际的 0.21——说明预测的瓶颈不在品评噪声，而在化学数据本身能解释感官的限度。

6.4.2 等级映射与交付

两种映射的 QWK 分别为 [值] 与 [值]，选定 [胜出者]。预测等级对参照的混淆集中在对角线附近（图 **??**），± 1 准确率 [值]，没有跨档大错；有锚单元的误差明显小于无锚单元，印证 “零点找得回的维度还原可靠”。交付的 250×50 评分见图 **??**，代表性啤酒的感官画像见图 **??**。

6.4.3 外部检查

公开验证数据里的两款基础啤酒，经化学数据比对唯一锁定为本数据集的啤酒 64 与 223（匹配距离 0.07 和 0.06，次优候选远在 0.42 和 9.08 之外），自带 92 个真实的 0–6 原始评分。把这两款啤酒的折外预测按选定映射转成等级，与实测均值对照：预运行中有锚维度平均误差 -0.47 分，无锚维度 MAE 约 0.5 分，且两款啤酒谁高谁低在 8 个属性中 7 个方向一致——“化学 $\to z \to$ 0–6” 整条链路在外部数据上方向正确。

6.4.4 敏感性分析

三类扰动逐一检验（图 **??**）：(i) NA 的三种口径（均值填充 / 保留 NaN / 最低位编码）——排序类结论完全不变，因为秩指标不依赖填充方式；(ii) 尺度参数 m 取 2.5、3、4——m 从 3 变到 4 时约 22% 的有锚等级变动一档，故 0–6 数值以 $m = 3$ 为准并附区间说明；(iii) 无锚维度换用 C-mid 与 C-quantile 两种约定——数值随约定改变，证实这些维度的 0–6 分只应作排序解读，论文中已明确标注。

6.4.5 小结

问题一的结论归为三点。第一，化学数据确实能预测感官排序，主模型显著优于 “只看风格猜均分” 的基线，预测瓶颈在化学信息的解释限度而非品评噪声。第二，从并列地板值反推品评团和零点的方法行得通：零点找得回的维度（约三成单元）还原可靠，找不回的维度只保留排序信息并如实标注。第三，外部真实评分验证了整条链路方向正确。最终交付 250 款 $\times$ 50 维的 0–6 等级、各档概率与 90% 区间；品评团与零点表供问题二使用，全数据重拟合的模型供问题三调用。

7 问题二模型的建立与求解

7.1 问题分析

问题二要求利用附件 2 构建化合物共表达图，结合附件 1 的化学特征给出每个感官维度的 Top-3 关键化合物，并论证其稳定性与化学合理性。核心难点有三：其一，化合物间强共变（附件 2 中 $|\rho| \geq 0.5$ 的边达 597 条），若直接按边际相关取前 3，同一信息会以多个高度相关化合物的形式重复入选；其二，250 款啤酒分属 63 个品评团，同团样本共享评分零点且多为同一风格，稳定性检验必须以品评团为单位；其三，关键化合物为关联性结论，须以数据证据（显著性、入选频率、方法间一致性）与酿造化学机理（来源、气味阈值、加标实验）双线论证。

据此确定技术路线：以附件 2构建共表达图并划分模块，实现冗余控制；在图约束下以偏秩相关前向选择逐位确定 Top-3；以品评团簇 bootstrap 入选频率与多方法 Jaccard 系数量化稳定性；以附件 8 标签、OAV 阈值证据与外部加标实验完成化学合理性论证。流程如图 ??。

7.2 模型建立

7.2.1 候选集合与秩变换

候选集合 $\mathcal{C}$ 为附件 1 的 231 列扣除 5 个综合指标与 1 个内标，$|\mathcal{C}| = 225$。综合指标由其他化合物计算得到，各自几乎是某一成分的副本（如 `aroma_hops_sum` 与 linalool 的 $|\rho| = 0.96$），保留将使同一信息两次入选；内标反映测量过程而非啤酒组成。二者仍作为图的注释节点保留。理化指标（pH、IBU、color 等）保留为候选，它们是 acidity、bitterness 等维度最直接的解释量。

全部关联基于秩：157 个信号列的变换方式未知，秩不受单调变换影响；附件 2 本身为 Spearman 矩阵，关联与图同度量；检出下限的并列底值自然成为并列秩。化学 NA 按列均值填充，仅作计算占位；感官目标取附件 4 标准化均值 z_{bd} 的秩，与问题一 0–6 评分互为单调变换，结论不依赖换算假设。

7.2.2 共表达图与模块

共表达图 G_τ 以 231 列为节点，边权 $w_{jk} = |\rho_{jk}|$，$|\rho_{jk}| \geq \tau$ 时连边，符号作边属性。取无符号权重：$|\rho| \geq 0.5$ 的 597 条边中仅 13 条为负，且负相关在冗余意义上与正相关等价。模块由相异度 $1 - |\rho|$ 上的平均连接层次聚类在高度 $1 - \tau$ 处切割得到，保证模块内平均相关不低于 τ；相比之下，连通分量会被弱链串联（$\tau = 0.6$ 时最大分量含 96 个化合物），Louvain 需另选分辨率参数且随种子变化，偏相关网络因附件 2 非半正定（5 个负特征值）不可行。

阈值主值取 $\tau = 0.6$，为候选间 $|\rho|$ 的 99% 分位：此时 245 条边构成 33 个多成员模块，来源纯度 0.79，bootstrap 下模块划分 ARI 中位 0.76，均优于 $\tau = 0.5$（纯度 0.70、ARI 0.66）；$\tau = 0.7$ 时模块仅覆盖 65 个化合物，冗余控制范围过窄。模块约束设定：同

模块化合物在 250 款啤酒上无法被数据区分为不同的关键因素，故每模块在 T_d 中至多一席，其余成员作为同模块化合物随入选者一并报告。

7.2.3 图约束前向选择

对维度 d，第 1 位取边际秩关联最强者：

$$t_{d1} = \arg\max_{j \in \mathcal{C}} |r_{jd}|, \qquad r_{jd} = \tfrac{1}{n} \tilde{x}_j^\top \tilde{y}_d. \tag{9}$$

第 k 位（$k = 2, 3$）记已选集合 S，H_S 为向 $\mathrm{span}\{\mathbf{1}, \tilde{x}_s : s \in S\}$ 的投影，

$$r_{jd|S} = \frac{e_j^\top e_y}{\|e_j\| \, \|e_y\|}, \qquad e_y = (I - H_S)\tilde{y}_d, \; e_j = (I - H_S)\tilde{x}_j, \tag{10}$$

$$t_{dk} = \arg \max_{j \in \mathcal{C}, \; M(j) \notin M(S)} |r_{jd|S}|. \tag{11}$$

偏秩相关衡量化合物在已选者之外还能解释多少维度排序；模块约束 $M(j) \notin M(S)$ 排除与已选者同模块的冗余化合物。

显著性门槛 q_d 取 $\max_j |r_{jd}|$ 置换零分布（打乱 $\tilde{y}_d$ 1,000 次，每次在 225 个候选上取最大值）的 95% 分位，控制维度内多重比较；第 2、3 位用 Freedman–Lane 置换。入选项同时满足得分超过 q_d 且品评团簇 bootstrap 的 95% CI 不含 0 时记为显著。由此定义维度等级：A 级（Top-1 显著且入选频率 $\pi^c \geq 0.6$）、B 级（Top-1 显著）、C 级（Top-1 不显著，记为未找到可靠关键化合物）。

7.2.4 稳定性度量模型

稳定性从两个正交方向量化。**数据扰动：**以品评团为单位有放回抽取 63 个团，每次重算相关矩阵、重建模块、重跑选择，$B = 1{,}000$；记化合物层入选频率 π^c_{jd}、模块层频率 π^m_{jd} 与 bootstrap Jaccard 均值 J^{boot}_d，分档为稳定（$\pi^c \geq 0.6$）、中等（$[1/3, 0.6)$）、不稳定（$< 1/3$）。**方法扰动：**与四个对照方法比较 Top-3 的 Jaccard 系数 $J(A, B) = |A \cap B|/|A \cup B|$——M0 无图约束边际选择、M1 图约束边际选择、M2 秩上 ElasticNet、M3 梯度提升树置换重要度，另加风格内分析（对 22 个风格指示变量取残差后重跑选择），随机 3 元集合的 Jaccard 期望 0.008 作为参照基线。

7.3 模型求解

求解流程为确定性算法，全程种子固定：

Step 1 构图与模块：读入附件 2，复算验收（与附件 1 逐对 Spearman 最大差 6.7×10^{-16}），层次聚类切割得模块表、节点表（含模块内连接度 k_j^{in} 与枢纽）与边表。

Step 2 选择规则验证：在真实化学矩阵上随机植入 3 个异模块化合物、按秩线性组合加噪声生成伪维度，每设置 200 次，比较前向与边际选择的找回率（表 4）。前向

选择在效应量 $r \geq 0.3$ 时全面占优；观测数据 49 维 Top-1 的 $|r|$ 中位数 0.36，处于该区间，确定前向选择为主方法。模拟仅使用化学矩阵与人工目标。

Step 3 主运行：对 49 个维度执行前向选择与置换检验，产出 Top-3、选择得分、显著性与维度等级。

Step 4 稳定性运行：$B = 1{,}000$ 品评团簇 bootstrap 与五个对照方法，产出 π^c、π^m、J^{boot} 与方法间 Jaccard。

Step 5 化学证据汇总：关联附件 8 的来源、缺陷与老化标签；对有阈值的化合物计算 OAV≥ 1 的啤酒比例；标注共变标记（风格内 CI 含 0、进入 ≥ 5 个维度、或全部啤酒 OAV< 1）；逐项撰写机理解释并核对入选符号。

Step 6 敏感性运行：$\tau \in \{0.5, 0.7\}$、候选集加回排除列、NA 两种对照口径、固定附件 2 构图、按单款啤酒重抽、39 个有锚维度改用减零点评分，共 7 组，各报告与基线的 Jaccard 及 Top-1 改变维度数。

7.4 结果分析

7.4.1 共表达图结构

$\tau = 0.6$ 下 245 条边构成 33 个多成员模块，覆盖 97 个化合物，代表性模块与酿造学知识吻合：ethanol–ethyl acetate–ethyl hexanoate–glycerol（发酵强度轴）、isoamyl acetate–isobutyl acetate–n-hexanol（乙酸酯类）、ethyl octanoate–ethyl decanoate（中链脂肪酸乙酯）、color–protein（麦芽轴）、linalool–α-terpineol（酒花萜类）。模块的来源纯度 0.79，即强共变主要发生在同一酿造来源的化合物之间，图 **??** 中同色节点聚为同圈的格局直观反映了这一点。

7.4.2 Top-3 识别结果

49 个维度中，Top-1 显著 47 个，第 2、3 位显著分别为 37、20 个；置换门槛 q_d 中位数 0.227，Top-1 的 $|r|$ 中位数 0.36。代表性结果与酿造化学一致：bitterness 的 Top-1 为 IBU，acidity 为 pH，esters_all 为 isoamyl acetate，body 为 ethanol（同模块含 glycerol）。A_esters_flower 与 t2n 两维 Top-1 未超门槛，列为 C 级。全部 49 维的 Top-3、得分、CI 与等级见附录表 **??**。

风格内分析显示：147 个入选项中 98% 在风格内保持同号，其中 18 项风格内 $|r^{(s)}| < 0.1$——如 lactic acid $\rightarrow$ lactic（合并 0.45，风格内 -0.00）、pH $\rightarrow$ acidity（-0.50，-0.09），其关联来自酸啤风格与其他风格之间的配方差异，已标注共变标记；风格内 Top-3 作为次要输出交付问题三。

7.4.3 稳定性结果

品评团簇 bootstrap 下，按位置的化合物层入选频率为 0.56、0.35、0.19，模块层为 0.62、0.40、0.21；J^{boot} 均值 0.267，为随机基线 0.008 的 33 倍。147 个入选项中稳定 28 项、中等 41 项、不稳定 78 项（图 **??**）。结合植入实验的找回率标尺（真实效应 $r \approx 0.3$、

排第 3 位的化合物在 0.2–0.7 的重复中被找回），结论为：在 250 款啤酒的样本量下，多数维度可靠支持的关键化合物为 1 个、至多 2 个，第 3 位以报告为主。模块层频率高于化合物层的差值即同模块化合物间的轮换，印证了模块不可分设定。

方法间 Jaccard 见表 5 与图 **??**。线性族方法与主方法 Top-1 完全一致（M0、M1 为 1.00，M2 为 0.63），表明第 1 位结论对估计方式不敏感；M0 有 22/49 维的前 3 含同模块冗余（如 A_malt_all 的 color 与 protein），正是图约束消除的对象。M3 允许非线性后 Top-1 一致比例降至 0.37（如 metallic 的 M3 Top-1 为 iron），此类维度并列报告两法结果并各附化学解释。

7.4.4 化学合理性结果

有阈值的 26 个入选化合物中，ethanol（0.98）、linalool（0.98）、citronellol（0.92）、IBU（0.86）、isoamyl acetate（0.84）、geraniol（0.76）、DMS（0.67）、ethyl acetate（0.66）、acetic acid（0.62）在多数啤酒中 OAV$\geq$ 1，其感官作用有直接的浓度基础（图 **??**）；acetaldehyde、ethyl decanoate、furfural 等 5 个化合物在全部啤酒中 OAV$<$ 1，标为共变标记，其入选反映与未测或同模块化合物的共变，亚阈值酯类的加和效应亦为已知现象。进入 ≥ 5 个维度 Top-3 的 color、ethanol、protein 等 7 个候选标记工艺与风格强度轴。

外部加标实验提供因果方向的核验（表 6）：七种化合物混合加标在三组底酒中均显著提高 Esters（配对差 0.90–1.31，$t \geq 2.9$），支持酯类作为 esters_all 关键因素；未加入酒花化合物时 Hops 与 Bitterness 不变（$|t| \leq 0.9$），构成阴性对照，排除加标杯整体抬分的可能；Fullness 在无乙醇组同样提高，表明 glycerol 等同模块成分足以产生醇厚感。

7.4.5 敏感性结果

七组敏感性运行中，Top-3 与基线的化合物层 Jaccard 均值、Top-1 改变维度数汇总于附录表 **??**。化合物层入选频率在 $\tau \in \{0.5, 0.6, 0.7\}$ 下完全相同，阈值仅影响模块层解读；NA 口径与 bootstrap 单位的扰动均未改变 A 级维度的 Top-1。结论对建模选择稳健。

问题二最终向问题三交付三项结果：模块表（同模块化合物在生成时应一起变化，综合指标由成分推导）、风格内 Top-3，以及缺陷维度（DMS、4VG、diacetyl、t2n、stale hops）的关键化合物清单。

8 问题三模型构建与求解

8.1 条件生成模型原理

8.1.1 问题分析与建模思路

问题三要求以 `tasting_category_fine` 为风格标签学习条件生成模型：给定风格生成合理的化合物谱并给出感官画像，再把一种风格的化合物谱迁移为另一种风格，且

表 3: 问题一核心指标汇总

对象	Spearman	R^2	QWK	MAE	±1 准确率
主模型（全体）	[–]	[–]	[–]	[–]	[–]
主模型（有锚 I=1）	—	—	[–]	[–]	[–]
主模型（无锚 I=0）	—	—	[–]	[–]	[–]
基线 B1（风格均值）	[–]	0.115	—	—	—
B3（真实评分直训）	[–]	[–]	—	[–]	—

表 4: 植入–还原实验找回率（按植入顺序）

植入权重	首位化合物 r	边际选择	前向选择
1,0.75,0.5	0.30	0.76, 0.37, 0.12	0.77, 0.48, 0.20
1,0.75,0.5	0.45	0.96, 0.61, 0.20	0.97, 0.88, 0.58
1,1,1	0.30	0.46, 0.61, 0.54	0.72, 0.67, 0.69
1,1,1	0.45	0.70, 0.71, 0.78	0.94, 0.96, 0.94

表 5: 主方法与对照方法的 Jaccard 系数（49 维平均）

对照	化合物层	模块层	Top-1 相同比例
M0 无图约束边际	0.327	0.390	1.00
M1 图约束边际	0.371	0.390	1.00
M2 ElasticNet	0.498	0.510	0.63
M3 GBM 置换重要度	0.227	0.227	0.37
风格内	0.290	0.316	0.35
随机基线	0.008	—	—

表 6: 加标杯 − 对照杯配对差（括号内为 t 值）

属性	Blond 含乙醇 n=20	Blond 无乙醇 n=13	NABLAB n=13
Esters	0.90 (4.7)	1.08 (2.9)	1.31 (5.0)
Fullness	1.30 (6.3)	1.31 (3.0)	1.38 (4.8)
Alcohol warming	1.10 (4.2)	0.92 (4.4)	0.08 (0.6)
Sweetness	1.15 (4.4)	0.69 (2.0)	1.00 (3.1)
Hops	−0.15 (−0.5)	0.00 (0.0)	−0.08 (−0.2)
Bitterness	0.05 (0.2)	−0.15 (−0.6)	−0.31 (−0.9)
Malt	0.45 (2.0)	−0.23 (−1.0)	0.00 (0.0)
Overall	1.05 (2.8)	1.15 (3.6)	1.08 (3.5)

缺陷化合物不恶化。

困难在于数据形态：250 款啤酒、22 个风格（各 3–31 款）、225 个生成列，样本远少于维度。深度生成模型（VAE、GAN、扩散模型）在这个量级上无法可靠训练；逐风格单独估计协方差也不可行（最大风格仅 31 款）。另一方面，数据分析显示风格只解释每列方差的约四分之一（η^2 中位数 0.250），其余四分之三是风格内变化，且这部分变化有低维结构（前 10 个主成分解释 50%）。因此生成器必须同时刻画 “风格均值” 与 “风格内共变”，并让全部风格共享一套协方差。总体流程见图 **??**。

8.1.2 秩变换与潜空间

生成不在原尺度上进行。原因有三：157 个信号列的变换方式未知；156 列存在 “未检出” 下限（共 7,592 个单元格），连续分布会生成低于下限的假浓度；个别线性列有数千倍的极端值，会主导协方差。处理办法是逐列秩变换：把每列观测按名次映到标准正态分位数上，得到潜变量 $u_{bj} = \phi_j(x_{bj})$；并列的下限块映为截断正态的条件期望，反变换 Q_j 把下限的整段概率映回下限值。这样生成谱中 “未检出” 仍是离散状态，极端值不再失衡，且结果不受任何单调变换影响。

8.1.3 生成模型

在潜空间中假设同风格样本服从多元正态：

$$u \mid s \;\sim\; \mathcal{N}(\mu_s,\, \Sigma_W), \qquad \Sigma_W = \Lambda\Lambda^\top + \Psi_M. \tag{12}$$

三个部件各有分工：(i) **风格均值收缩** $\hat{\mu}_s = (n_s\bar{u}_s + \kappa\bar{u})/(n_s + \kappa)$，小样本风格（如仅 3 款的 Faro）的均值向全局收缩，避免过拟合；(ii) **因子结构** $\Lambda\Lambda^\top$（k 个共同因子）刻画化合物间的低维共变；(iii) **模块块** Ψ_M 按问题二的共表达模块保留块内残余相关——纯因子模型会把强相关化合物对的相关从真实的 0.724 衰减到 0.633，加模块块后恢复到 0.680，同时呼应问题二 “同模块化合物应一起变化” 的要求。

超参数 (k, κ) 与协方差结构按留出啤酒的潜空间评分在嵌套划分中选择，预运行选中 $k = 15$、$\kappa = 2$、因子 + 模块块（表 7）。生成时抽 $u \sim \mathcal{N}(\hat{\mu}_s, \hat{\Sigma}_W)$，反变换得化合物谱；5 个综合指标不单独生成，由岭回归从生成列派生（交叉验证 R^2 为 0.78–0.94），内标取训练中位数。

表 7: 协方差结构与超参数的留出评分（nat/款，节选）

协方差结构	$\kappa = 1$	$\kappa = 2$	$\kappa = 5$	$\kappa = 10$
对角	—	-297.3	-298.6	-302.2
Ledoit–Wolf	—	-267.1	-266.6	-269.2
纯因子 $k = 15$	-246.0	-244.9	-245.3	-248.5
因子 + 模块块 $k = 15$	-241.9	$\mathbf{-240.7}$	-240.8	—

8.1.4 生成质量验证

验证按风格分层的 5 折留出进行，秩变换、均值、协方差、模块全部在训练折内估计。设五个对照生成器定位主模型：G0（不分风格）、G1（原样复制训练啤酒）、G2（逐列独立抽取，破坏共变）、G3（风格内插值）、纯因子（去掉模块块）。核心指标与预运行结果见表 8 与图 **??**。

表 8: 生成器评价（预运行；括号内数值因样本依赖不可比）

生成器	C2ST AUC	DCR比	TRTS	TSTR	下限误差	模块内 ρ
主模型	0.510	1.11	0.662	0.486	0.020	0.680
纯因子	0.482	1.10	0.664	0.504	0.020	0.633
G0 无风格	0.579	1.14	0.080	0.096	0.020	0.685
G1 复制	(0.261)	0	(1.000)	0.516	0.016	0.734
G2 独立边际	0.651	1.21	(0.988)	0.526	0.015	0.248
G3 插值	(0.332)	0.32	(0.994)	0.544	0.026	0.731
真实留出	—	1	0.540	—	—	0.724

读法一目了然：主模型的 C2ST AUC 为 0.510，判别器几乎分不出生成样本与真实啤酒；去掉风格条件（G0，0.579）或破坏化合物共变（G2，0.651）后立刻可分，说明两个部件都在起作用。DCR 比 1.11 表明生成样本不是训练啤酒的翻版（G3 插值仅 0.32，贴着训练样本）；TSTR 0.486 接近真实参照 0.540，而 G0 仅 0.096，证实风格条件携带了真实的风格信息。

8.2 风味指纹生成模块构建

8.2.1 感官画像

对每个风格抽取 1,000 个化合物谱，补齐综合指标与内标后送入问题一的全数据模型 f_d，得到 50 维预测 $\hat{z}$ 与 0–6 等级，汇总为感官画像：各维度的中位数、10%–90% 区间与等级分布。问题一主模型只用化学特征、不读风格标签，因此画像完全由生成的化合物谱决定——这正是后面迁移实验中 “感官跟着化学变” 的前提。

画像的可信度用留出验证确认：生成器与感官模型在同一训练集上拟合，用同一个没见过留出啤酒的模型分别预测生成谱与留出真实啤酒。预运行中，22 个风格的生成画像与真实折外预测的 Spearman 平均 0.821；题面点名的三个风格为 Tripel 0.963、Lambic 0.893、Kriek 0.736 （图 **??**）。

8.2.2 风味指纹

风格 s 的 “风味指纹” 由化学与感官两部分组成。化学指纹为标准化潜空间偏移

$$\delta_{sj} = \frac{\hat{\mu}_{sj} - \bar{u}_j}{\sqrt{\Sigma_{W,jj}}}, \tag{13}$$

即该风格在化合物 j 上偏离全体均值多少个风格内标准差，取 $|\delta|$ 最大的 10 项（同模块只列最大者），每项附 bootstrap 90% 区间与附件 8 的来源、缺陷、老化标签；感官指纹为画像中位数偏离全体合并画像最大的维度。化学解释在指纹产生后按偏移方向撰写，不预设“某风格该有什么”的预期表，避免循环论证。三个点名风格的指纹见图 **??**。

8.3 带约束跨风格迁移模块构建

8.3.1 缺陷集合与“不恶化”定义

缺陷约束设两层。**化学层**为 9 列：附件 8 标注缺陷描述的 7 个化合物（acetaldehyde、DES、DMS、H_2S、MeSH、SO_2、diacetyl），加题面点名的 4VG 与 trans-2-nonenal。“不恶化”定义与题面“超阈值项”的表述对齐：有阈值时迁移后 $x'_j \le \max(x_j, \theta_j)$——原本超阈的不得再升，原本未超阈的不得越线；无阈值时（MeSH、t2n）一律不得增加。**感官层**为附件 3 的 6 个缺陷维度，要求问题一模型的预测等级不升高。两层的比较对象都是迁移前的同一款啤酒。数据背景值得注意：H_2S 在全部 Pils/Lager 与 Tripel 中都超阈，DMS 超阈比例达 0.67，缺陷约束在几乎所有风格对上都会起作用（462 个风格对中，平移后至少违反一项化学约束的啤酒比例中位数为 1.00）。

8.3.2 迁移映射：潜空间平移

在共享协方差的高斯假设下，两个风格分布之间使潜空间移动代价最小的映射恰是平移：

$$\tilde{u} = u_b + \Delta_{s\to t}, \qquad \Delta_{s\to t} = \hat{\mu}_t - \hat{\mu}_s, \qquad \tilde{x}_j = Q_j(\Phi(\tilde{u}_j)). \tag{14}$$

平移的好处直观：每款啤酒保留自己相对本风格的个体偏离 $u_b - \mu_s$，迁移后成为相对目标风格的同样偏离——“这款 Pils 比一般 Pils 更苦”迁移后变成“这款 Tripel 比一般 Tripel 更苦”。对照实验说明为何必须在潜空间操作：原尺度均值平移（T3）在 2,475 个单元格中产生 163 个超出观测范围、102 个低于检出下限、1 个负浓度的取值。

8.3.3 化学约束投影

平移后通常违反化学约束（Pils/Lager→Tripel 中 11/11 款违反）。利用 $Q_j \circ \Phi$ 的单调性把上界换到潜空间（$x'_j \le b_j$ 等价于 $u'_j \le \beta_j$），求马氏距离最近的可行点：

$$u^* = \arg\min_{u'} (u' - \tilde{u})^\top \Sigma_W^{-1} (u' - \tilde{u}) \quad \text{s.t.} \quad u'_j \le \beta_j,\ j \in \mathcal{D}_c. \tag{15}$$

该解有闭式：u^* 等于高斯分布在缺陷坐标压到上界时的**条件均值**——缺陷化合物被压回时，与之共变的化合物按风格内协方差一起调整，不会出现“DMS 被压低而它的共变伙伴纹丝不动”这种数据中罕见的组合。仅截断缺陷列的做法作为对照（T1/T5）。

8.3.4 感官约束与迁移强度

感官层经问题一的树模型计算，不可微，故沿路径 $u(\alpha) = u_b + \alpha(u^* - u_b)$，$\alpha \in \{0, 0.05, \ldots, 1\}$ 逐点检查 6 个缺陷维度的预测等级，取满足约束的最大 α^* 交付。路径两端均满足化学约束且可行集为凸，整条路径化学层安全；$\alpha = 0$ 即 “保持原谱”，是永远可行的保底输出。交付前在原尺度逐列复查两层约束，数值误差导致不可行的点退到下一个可行网格点。

8.3.5 迁移结果

Pils/Lager→Tripel 的 11 款逐款报告，预运行汇总见表 9 与图 **??**。

表 9: Pils/Lager → Tripel 迁移（预运行，11 款）

方法	P(Tripel) 中位	d^2 中位	说明
源啤酒	0.046	283.8	迁移前水平
T0 平移（无约束）	0.324	162.0	11/11 违化学约束，7/11 违感官约束
T1 仅截断缺陷列	0.292	171.9	产生罕见化合物组合
投影终点 $\alpha = 1$	0.202	166.6	有效约束中位 4 个
主方法 α^*	0.130	208.3	α^* 中位 0.70
真实 Tripel	0.269	184.0	参照（折外判别概率）

结果读法：无约束平移可把目标风格概率提到 0.324（已达真实 Tripel 的 0.269），说明平移方向正确；加入缺陷约束后降到 0.130——高于源啤酒的 0.046，改善明确，但未达真实 Tripel 水平。起约束作用的化学项主要是 H_2S、MeSH、t2n（11/11 款）与 DMS（10/11），感官项为 metallic、4VG 与 diacetyl。这一 “改善但有代价” 的结果如实报告：它只说明沿本文路径在不恶化缺陷的前提下能走多远，不说明化学空间中不存在更好的方案。缺陷表（图 **??**）逐款展示 9 个化学缺陷项迁移前后的取值与上界，全部满足 “不恶化”。

每款啤酒最终归入四类结论（达到参照范围 / 改善 / 保持原谱 / 未改善，定义在运行前固定），22×21 个风格对报告各类别比例、α^* 分布与目标概率中位数。敏感性运行覆盖协方差结构、(k, κ) 相邻网格、NA 编码口径、阈值均值/中位口径、化学层严格规则（一律不增加）与感官层连续规则等十余项扰动，生成指标与迁移结论的变化逐项报告。

问题三最终交付：22 个风格各 1,000 个生成化合物谱及感官画像、Tripel/Kriek/Lambic 的风味指纹、Pils/Lager→Tripel 的逐款迁移报告与全风格对汇总表。

9　模型评价

9.1　模型优点

9.2　模型不足

9.3　灵敏度与鲁棒性分析

10　参考文献

参考文献

[1] 啤酒风味物质代谢相关文献

[2] 共表达网络构建相关文献

[3] 表格数据条件生成模型相关文献

11　附录

附录放置 Python 核心代码、补充图表、额外实验结果。