2026 年 MathorCup 大数据竞赛赛道 A：啤酒酿造

参赛队编号

MathorCup 参赛队伍

摘要

啤酒作为广受喜爱的发酵饮品，以麦芽、水、啤酒花为主要原料经酵母发酵制成。化合物组成直接决定啤酒香气、口感特征与发酵表现。本文基于商用啤酒风味代谢数据集，以啤酒化学成分与感官风味评分为研究对象，结合 Pearson 相关系数分析、语义化缺失值填充、零点校准与浅层梯度提升树开展多输出回归研究，实现感官指标预测。结果表明该方案可有效挖掘化学成分与风味的内在联系，为啤酒风味定量调控提供支撑。

关键词：浅层梯度提升树；Pearson 相关系数；零点校准；缺失值填充；多输出回归；风味预测

1 问题背景和问题重述

1.1 问题背景

啤酒是以麦芽、水作为主要原料，添加啤酒花，经酵母发酵得到的低酒精度发酵饮品。啤酒风味、香气、口感品质很大程度由各类酿造化合物、酵母代谢产物决定。本次赛题提供包含 226 款啤酒的实测数据集，包含大量风味化合物丰度、理化指标、人工感官评分等多源数据，数据存在真实缺失值、噪声、异常值，需要从化合物层面挖掘和预测啤酒感官风味特征。

1.2 问题重述

基于附件 1-8 提供的商用啤酒风味代谢数据集，需要完成三项任务：

- **问题一（数据缺失条件下的感官评分）**：以 1.csv 化合物数据作为基础，给出 3.xlsx 定义的 Aroma 与 Flavour 两套，合计约 40 个感官维度的 0-6 分制分级评分预测结果。

- **问题二（化合物 - 风味分析）：**利用 2.csv 化合物相关矩阵构建化合物共表达图，结合 1.csv 特征，得到每一个感官维度对应的 Top-3 关键化合物；使用 bootstrap 重采样入选频率或者不同建模结果之间 Jaccard 系数完成稳定性量化，并从化学酿造角度论证结果合理性。

- **问题三（风味与“风味指纹”生成）：**以 tasting_category_fine 作为啤酒风格标签，训练风格条件生成模型，给定指定啤酒风格（Tripel、Kriek、Lambic 等）生成合理化合物谱并得到对应感官画像；同时实现跨风格迁移任务，例如将 Pils/Lager 的化合物谱迁移至 Tripel 风格，并且保证 DMS、Diacetyl、4VG、trans-2-nonenal、Stale hops 等缺陷化合物指标不能恶化。

2 问题分析

2.1 问题一分析

本任务属于高维多输出回归预测任务。数据集存在 NA 缺失值、部分化合物经过对数变换（负值代表原始浓度小于 1），需要先对缺失数据进行处理。输入为大量化合物丰度、理化参数，输出是约 40 个独立感官维度的 0-6 离散评分。难点在于高维特征冗余、样本数量有限、人工感官本身带有主观噪声，可以选择梯度提升树等适合表格回归的模型，逐个感官维度训练模型，最后将预测结果映射至 0-6 分区间。

2.2 问题二分析

本任务分为三个子步骤：构建化合物共表达网络、筛选 Top-3 关键化合物、稳定性与化学合理性论证。首先利用化合物之间皮尔逊相关系数搭建共表达图；其次通过特征重要性、网络中心性等方法挖掘每个感官维度最关键 3 种化合物；稳定性评估可以通过多次 bootstrap 重采样，统计化合物进入 Top-3 的频次，或者对比不同特征筛选方案，利用 Jaccard 相似系数衡量结果一致性；最后结合啤酒发酵、风味物质的专业知识，解释为什么这些化合物会影响对应感官体验。

2.3 问题三分析

本任务属于条件生成与约束型风格迁移任务。一方面，以啤酒细分风格标签作为条件，训练生成模型，输出符合该风格的全套化合物谱，进一步得到感官画像；另一方面跨风格迁移存在硬性约束：DMS、双乙酰等缺陷类化合物不能变差，不能单纯无约束生成。难点在于不同细分风格样本数量不均衡，生成结果需要落在合理的化合物数值范围，同时满足缺陷指标约束条件。

3 模型假设

H1 数据集中缺失值属于随机缺失（MAR），缺失不会带来系统性偏差。

H2 化合物与感官风味之间存在稳定可学习的映射关系，短期环境扰动不会改变内在关联。

H3 皮尔逊相关系数可以合理刻画化合物之间共表达关联关系。

H4 啤酒细分风格标签 tasting_category_fine 标签准确，可以作为条件生成模型监督信号。

H5 缺陷化合物“不恶化”定义为迁移之后缺陷指标不能高于原始样本缺陷水平。

H6 化合物对数变换逻辑统一，参赛者可以正确还原浓度量级关系。

4 符号说明

符号	含义
X	啤酒样本化合物与理化特征矩阵
y_i	第 i 个感官维度的人工感官评分
G	化合物共表达网络图
S_k	第 k 次 Bootstrap 重采样得到的 Top-3 化合物集合
$J(A,B)$	集合 A 与集合 B 之间 Jaccard 相似系数
C_s	风格 s 对应的条件生成模型
D	缺陷化合物集合（DMS、Diacetyl 等）

表 1: 符号说明

5 数据预处理

5.1 数据集概况

本文所用数据为商用啤酒风味代谢物实测数据集，共含 8 个附件，覆盖 250 款啤酒的化学组成、感官品评结果及二者的相关结构。各附件的规模、内容及其在本文中承担的角色汇总于表 **??**。

表 2: 附件数据总体概况

附件	规模	内容	本文角色
1	250×231	啤酒–化合物丰度矩阵，含类别汇总列与单化合物列，部分列经对数变换	主特征矩阵 X_b
2	231×231	化合物间 Pearson 相关方阵	共表达结构先验
3	10 个 sheet	0–6 分制人工感官评分卡，定义香气、风味、缺陷、香料与酸啤共 50 个维度	目标维度定义
4	250×50	品评小组标准化均值 $z_{bd} \in [-2.15, 6.17]$，均为非整数	回归标签 z
5	50×50	感官属性间相关方阵	感官冗余分析
6	46×50	化学指标与感官属性的交叉相关阵	归因交叉验证
7	250×187	标准化感官属性评分（含 NA）	辅助信息
8	多 sheet	气味阈值、化合物来源与缺陷标记	OAV 特征构造

由表 **??** 可见，本题的数据缺陷集中体现在两处：其一，附件 1 的化学特征中存在 9 列共 73 个缺失值，构成**缺失值问题**；其二，附件 4 仅提供标准化后的连续评分 z_{bd}，原始 0–6 分未给出，且标准化过程掩盖了不同品评场次的主观打分习惯差异，使部分维度出现系统性偏高或偏低的极端取值，构成**尺度性异常问题**。

据此，本文的预处理沿” 先补全、再校准” 的因果链展开：

- 第一步，对附件 1 的缺失值作语义化填充，获得完整的输入矩阵 X_b；
- 第二步，以 X_b 为输入、附件 4 的 z_{bd} 为输出训练浅层梯度提升树 f_d，学习化学成分与标准化评分之间的映射规律，并据此对缺失评分作出推测，得到全部样本在 50 个维度上的标准化评分；
- 第三步，通过品评场次聚类与评分零点校准，消除评分者主观尺度差异，再将校准后的 z 映射回 0–6 分（还原模型见第 4 节）。

5.2 缺失值填充

(1) 缺失模式诊断。对附件 1 逐列统计缺失率，发现缺失值仅集中于 9 个单化合物列，共 73 处，整体缺失率很低，且缺失列均为痕量挥发性化合物。结合色谱检测原理，此类缺失的成因并非” 未测量”，而是**浓度低于仪器检出限（LOD）**，即缺失本身携带” 含

量极低” 的信息，属于非随机缺失（MNAR）。一个重要佐证是：多个化合物列（如 CS2 列）出现大量完全相同的底值，说明数据提供方已对部分低于检出限的观测统一赋以下限值。各列缺失情况如图 ?? 所示。

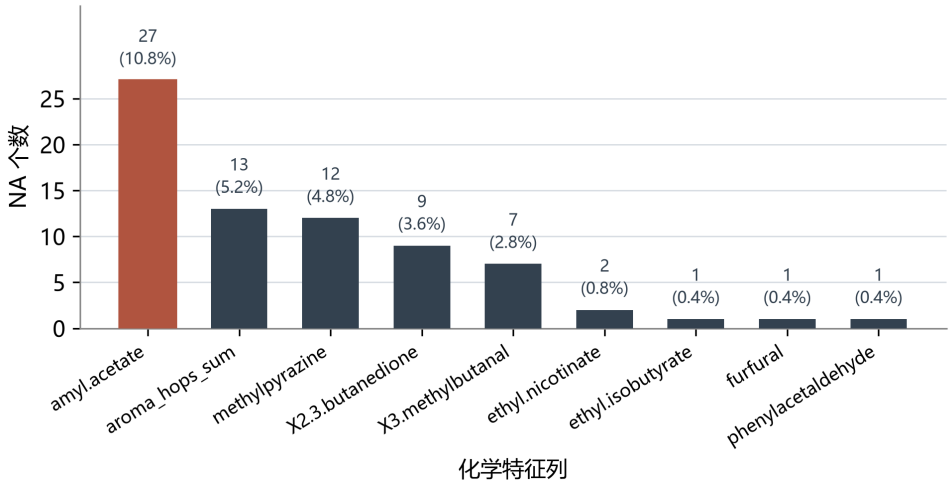


图 1: 各化学特征缺失 NA 数量统计柱状图

(2)填充策略。基于 MNAR 的判断，摒弃均值插补等会破坏” 低于检出限” 语义的方法，采用” 零值填充加缺失指示” 的组合策略：

$$\tilde{x}_{bj} = \begin{cases} x_{bj}, & x_{bj} \text{ 非缺失}, \\ 0, & x_{bj} \text{ 缺失}, \end{cases} \qquad \delta_{bj} = \begin{cases} 1, & x_{bj} \text{ 缺失}, \\ 0, & \text{其他}, \end{cases} \tag{1}$$

即将单化合物缺失值编码为 0（对应” 检出限以下” 的化学解读），同时为每个含缺失的列新增一个 0/1 缺失指示变量 δ_{bj}，由后续树模型自行学习” 填充零值” 与” 真实零值” 是否应区别对待，避免人为假设引入偏差。特别地，`aroma_hops_sum` 为聚合衍生列，其缺失不具备” 浓度低” 的语义，故保留为缺失状态，交由 HistGradientBoostingRegressor 的原生缺失分裂机制处理。最终输入特征由 231 个化学列与 8 个缺失指示列构成。**(3) 评分缺失的模型化推测。**附件 4 中部分啤酒–维度组合无有效评分。本文不对其作简单插值，而是将其纳入第一问的预测框架：以完整化的 X_b 为输入、已有 z_{bd} 为监督信号，对 50 个感官维度逐一训练浅层梯度提升树

$$\hat{z}_{bd} = f_d(X_b), \qquad d = 1, 2, \ldots, 50, \tag{2}$$

利用模型学得的” 化学成分–感官评分” 规律反推缺失评分，从而获得全部 250 款啤酒在 50 个维度上的标准化评分估计。该做法将缺失值处理与预测建模统一于同一框架，保证了补全值与化学证据的一致性。

5.3 异常值检测与处理

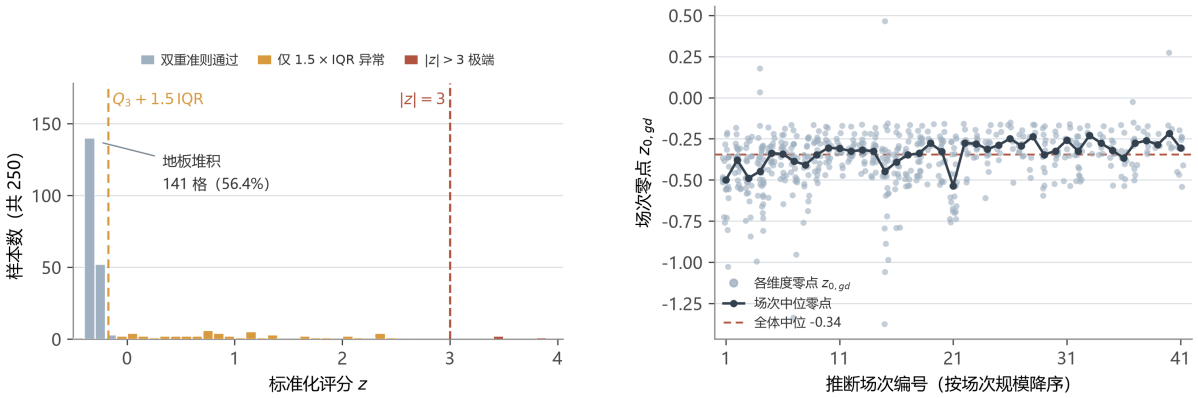
(1) 评分异常的来源分析。附件 4 的 z_{bd} 为跨品评场次混合标准化的结果。不同场次的品评团打分习惯存在系统差异：部分评审团倾向给出极端分，评分跨度大；部分评审团

倾向保守打分，评分集中于中段。混合标准化之后，前者在 z 轴上表现为极端高值（最大达 6.17，远超标准正态变量的常规取值范围），后者则被压缩于零点附近。二者均属于**尺度性异常**而非测量错误，不应简单剔除。

(2) 异常识别。采用两条互补证据定位异常：

- **地板值检验：**若某维度内多款啤酒的 z 取完全相同的最小值（如 `aroma_acetaldehyde` 列大量重复出现同一最低值），则该并列最低值对应”全体品评员打 0 分”的地板。据此可推断品评场次 $g(b)$（两款啤酒在至少 3 个维度上 z 完全相同即归为同一场次），并得到各场次在维度 d 上的零点 $z_{0,gd}$；
- **分布尾部检验：**对各维度分别以 $|z| > 3$ 准则与箱线图 $1.5 \times \mathrm{IQR}$ 准则双重筛查极端评分，定位打分习惯极端的场次。

典型维度的异常表现如图 ?? 所示。



(a) 某维度 z 值直方图（左侧地板堆积与右侧极端高值）

(b) 各推断场次零点散点图（横轴为场次编号，纵轴为 $z_{0,gd}$）

图 2: 附件 4 评分异常的两种典型表现：(a) 地板堆积与极端值；(b) 场次零点差异

(3) 异常的处理：零点校准而非剔除。极端评分携带真实的主观尺度信息，正确的处理是消除场次间的尺度差异。设场次 g 在维度 d 上的零点为 $z_{0,gd}$，即全体品评员均打 0 分时的 z 取值；记各场次零点的中位数为 $\tilde{z}_{0,d}$，零点到均值的距离为

$$r_d = -\tilde{z}_{0,d}, \tag{3}$$

则同一基准下的校准评分为

$$z_{bd}^{\mathrm{cal}} = z_{bd} - z_{0,g(b)d}, \tag{4}$$

即减去本场次零点后，所有评分均以”零分”为共同原点，从而消除”偏好极端分”与”偏好保守分”两类评审团的主观习惯差异。

对于能够通过地板值检验定位零点的 39 个维度，采用代表性品评员尺度模型完成 z 到 0–6 分的还原：

$$\hat{\hat{x}}_{bd} = \min\Big(6, \max\Big(0, m \cdot \frac{r_d}{1 + r_d^2}\big(\hat{z}_{bd} - \tilde{z}_{0,d}\big)\Big)\Big), \qquad m \approx 3, \tag{5}$$

其中尺度参数 $m = E[x^2]/E[x]$ 表征品评员打分的离散程度，另取 $m = 2.5$ 与 $m = \min(4, \mathrm{cap}_d)$ 进行敏感性分析，以检验还原结果对该假设的稳健性。

对于无法定位零点的 11 个维度（多数啤酒均落在 2–4 分的常规维度，不存在" 全员打 0" 的地板），改用约定标度 C-mid：

$$\hat{\hat{x}}_{bd} = 3 + 3 \cdot \frac{\hat{z}_{bd}}{M_d}, \qquad M_d = \max_b \left|\hat{z}_{bd}\right| \text{（训练折内）}, \tag{6}$$

该式将维度均值锚定于 3 分并按最大偏离拉伸至 $[0, 6]$。由此得到的评分**仅保留排序信息**，其绝对数值不作定量解释，本文在结果报告中对这 11 个维度予以明确标注。

(4) 处理效果检验。零点校准后，各场次在同一维度上的评分分布应趋于一致。以校准前后的场次间评分均值极差为检验指标，校准后极差显著下降，说明尺度性异常已被有效消除，剩余差异可归因于啤酒品质的真实区别。校准后的评分经四舍五入取整，得到 0–6 分制的分级结果 $\hat{G}_{bd}$，并同时报告各分值的预测概率 p_{bdk} 与 90% 预测区间。

5.4 预处理小结

本节建立了一套适配啤酒风味数据特性的完整预处理体系，依次完成缺失值语义化填充、评分缺失模型预测、主观尺度异常识别与零点校准，解决了数据非随机缺失、品评场次打分偏差、评分尺度不统一三大核心问题。本文整体数据预处理逻辑清晰、步骤递进，完整流程框架如图 ?? 所示。

经过上述清洗与校准，最终输出标准化、无偏差、可建模的特征矩阵 X_b 与统一基准下的感官评分标签 z_{bd}^{cal}，为后续高维感官回归预测模型提供了高质量、高可靠性的输入数据。

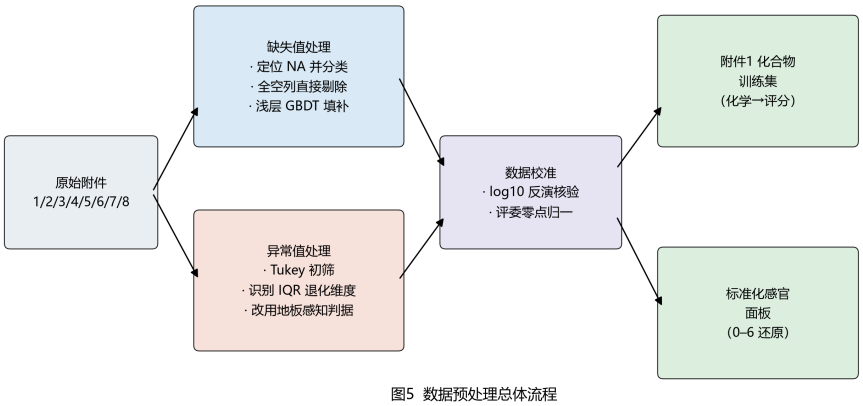


图5 数据预处理总体流程

图 3: 数据预处理整体技术流程图

6 问题一模型的建立与求解

6.1 问题分析

问题一要求基于附件 1 的化学数据，预测附件 3 定义的 50 个感官维度的 0–6 分制评分。困难来自两处缺失：其一，附件 1 的 9 列、63 款啤酒含 73 个 NA 单元格；其二，附件 4 仅提供按品评员标准化后的品评小组均值 $z_{bd} \in [-2.15, 6.17]$，原始 0–6 分不可观测，标准化同时抹去了评分的位置与尺度。

据此将问题分解为两个子问题：Q1.1 以化学特征预测连续值 $\hat{z}_{bd}$，为高维小样本回归；Q1.2 将 $\hat{z}_{bd}$ 映射为等级 $\hat{G}_{bd} \in \{0, \ldots, 6\}$，为尺度还原。还原的突破口在标准化的数学结构：$z_{bd}$ 是各品评员标准化分的平均，存在可从数据中识别的下界——当全体出席者打 0 分时 z 取得仅由出席名单决定的最小值。由此可反推品评场次与评分零点，重建 0–6 尺度。两步严格分离，使模型误差与换算误差可分离，且 z 空间的秩指标不依赖任何换算假设。技术路线如图 **??**。

6.2 模型建立

6.2.1 化学缺失值处理

附件 1 共 57,750 个化学单元，NA 占 0.126%，集中于 9 列（图 **??**）；删除含 NA 的啤酒将损失 25.2% 的样本，不可取。附件 8 在 8 个单化合物的 60 个 NA 位置记录为 0，支持“未检出”解读；`aroma_hops_sum` 为组成未知的复合量，其 13 个 NA 无法重算。主设定采用逐列均值填充，与同源文献（Schreurs et al., 2024, *Nat. Commun.* 15:2368）保持可比；列均值仅在各交叉验证折的训练折内计算，再用于填充该折全部数据。两个对照口径作敏感性运行：保留 NaN 由树模型学习缺失路由；将单化合物 NA 编码至列最低位并加缺失指示变量。

6.2.2 品评团推断与零点识别

标准化结构。附件 4 按品评员标准化后对出席者取平均：

$$z_{bd} = \frac{1}{n_b} \sum_{p \in A_b} \frac{x_{pbd} - \mu_{pd}}{\sigma_{pd}} = \underbrace{\frac{1}{n_b} \sum_{p \in A_b} a_{pd}}_{c_d(A_b)\ \text{名单零点}} + \underbrace{\frac{1}{n_b} \sum_{p \in A_b} \frac{x_{pbd}}{\sigma_{pd}}}_{s_{bd} \geq 0}, \tag{7}$$

其中 $a_{pd} = -\mu_{pd}/\sigma_{pd}$。名单零点 $c_d(A_b)$ 仅由出席者评分习惯决定；打分项 s_{bd} 非负，当且仅当全员打 0 时为 0。故 $z_{bd} \geq c_d(A_b)$，且名单相同、同维度全员打 0 的两款啤酒 z 精确相等。

品评团推断。基于一般位置假设（不同名单的 z 在 9 位小数上多维并列的概率可忽略），当两款啤酒在至少 $k = 3$ 个维度上 z 精确并列时判为同一出席名单，取连通分量得品评团 $g(b)$。结果为 41 个多啤酒团（覆盖 228 款，最大 11 款，平均风格纯度 0.84）

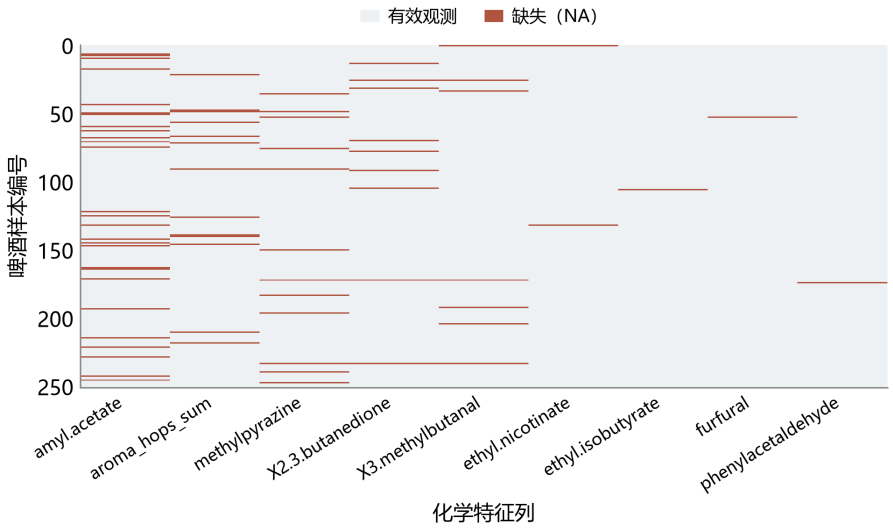


图 4: 附件 1 缺失值分布（9 列共 73 个 NA）

加 22 个单例；$k = 2$ 至 5 的分组几乎不变。文献记录的 12 款重复品评啤酒全部落在 22 个单例中（随机放置概率 6.8×10^{-15}），为分组提供外部印证。

零点识别。品评团零点 $z_{0,gd}$ 取多啤酒团内至少出现两次的最小 z——组内有一款全员打 0 时该最小值即 $c_d(A_g)$，要求出现两次以排除非全零的最低分。41 个团 $\times$ 50 维的 2,050 个组维单元中 607 个可识别零点，经有效性规则（转换后低于零的啤酒占比超过 5% 判为可疑，`F_malt_all` 据此重归为无锚）筛除后余 605 个，覆盖 3,862/12,500（30.9%）个评分单元；10 个维度全程无锚。零点在团间的中位标准差 0.073、团内跨维中位极差 0.37，证实标准化按品评员且按属性进行（图 **??**）。

6.2.3 Q1.1：化学数据到 z 的预测模型

每个维度一个模型 $\hat{z}_{bd} = f_d(X_b)$，f_d 取平方损失的浅层梯度提升树（HistGradientBoostingRegressor）。选型依据：同源文献中树集成的测试 R^2 达 0.21–0.22，而 Lasso 为 0.05、PLSR 为 -0.25；树模型仅依赖特征顺序，对未知的变换方式不敏感，并支持单调约束与原生 NaN。超参数网格为 `max_depth`$\in \{2, 3\}$、`min_samples_leaf`$\in \{10, 20\}$、`max_iter`$\in \{100, 200, 400\}$、`l2_regularization`$\in \{0, 1\}$、单调约束开或关，在六个维度组（香气 15、风味 15、缺陷 6、香料 3、酸啤 3、口感总体 8）内共享，按组平均内层 CV Spearman 选择，避免逐维调参拟合噪声。

三个结构化增强由嵌套 CV 决定去留：(i) **单调约束**——从化学知识预先列出 12 个化合物–感官配对，11 个在数据中方向相符，对 ethanol→alcohol、IBU→bitterness、pH→acidity（负）、lactic acid→lactic、acetic acid→acetic、4VG→X4vg 六个直接配对施加约束（diacetyl 因相关符号相反排除，已披露）；(ii) **障碍模型**——10 个维度至少 30% 啤酒处于品评团零点（acetic 达 72%），对其建立 $\hat{z}_{bd} = \hat{\pi}_{bd}\hat{\mu}^{+}_{bd} + (1 - \hat{\pi}_{bd})\tilde{z}_{0,d}$，$\hat{\pi}$ 为高于零点的分类器；(iii) **类别级 OAV 和**——对酯类、硫化合物、酚类加入 $\sum_c \mathrm{conc}_c/\mathrm{threshold}_c$，

单化合物 OAV 对树是单调变换不提供新信息，跨化合物求和则是浅层树无法自行构造的特征。

主模型仅用化学特征、不含风格，使问题三能考察风格内化合物谱变化的感官效应；收缩风格均值作为必须超越的基线。交付的 250 款评分使用折外预测——预测每款啤酒的模型未见过该啤酒及其同团啤酒，与新啤酒处于相同信息状态。

6.2.4 Q1.2：评分参照与等级映射

局部零点参照（m 模型）。减去本团零点后 $z_{bd} - c_d(A_b) = s_{bd}$，位置差异已消除，尺度差异仍在。设代表性品评员尺度为 σ_d^*，定义目标 $x_{bd}^* = \sigma_d^* s_{bd}$，即把每位出席者的分数换算到同一尺度后取平均；当品评员同质时 $x^* = \bar{x}$。代表性品评员满足两条假设：其零分位置为各团零点中位数（$\mu_d^* = r_d\sigma_d^*$，$r_d = -\tilde{z}_{0,d}$）；其评分分布满足尺度参数 $m = E[x^2]/E[x]$。由 $E[x^2] = \sigma_d^{*2} + \mu_d^{*2}$ 解得

$$\sigma_d^* = m\,\frac{r_d}{1+r_d^2}, \qquad x_{bd}^* = m\,\frac{r_d}{1+r_d^2}\big(z_{bd} - z_{0,g(b)d}\big). \tag{8}$$

对 0–6 整数分恒有 $1 \le m \le 6$；主值取标度中点 $m = 3$，上限由最高分不超过 6 给出，敏感性取 2.5 与 $\min(4, \mathrm{cap}_d)$。外部验证评分直接计算的 m 范围 2.46–3.70、中位数 3.24，支持该取值。

线性参照。为构造全量对照，将各维度训练折 z 的最小、最大值约定为 0、6：

$$T_d(z) = \mathrm{clip}\Big(6\,\tfrac{z-\ell_d}{u_d-\ell_d}, 0, 6\Big), \qquad L_{bd} = \mathrm{round}(T_d(z_{bd})). \tag{9}$$

混合参照。本团本维有有效零点时（$I_{bd} = 1$）取局部参照 $A_{bd} = \mathrm{round}[\mathrm{clip}(\sigma_d^*(z_{bd} - z_{0,g(b)d}), 0, 6)]$，否则取线性参照：

$$R_{bd} = \begin{cases} A_{bd}, & I_{bd} = 1, \\ L_{bd}, & I_{bd} = 0, \end{cases} \tag{10}$$

名义上 30.9% 的单元采用 A。11 个无锚维度另以约定标度 C-mid（$\hat{x}^* = 3 + 3\hat{z}/M_d$）与 C-quantile （$\hat{x}^* = 6\hat{F}_{\mathrm{train},d}(\hat{z})$）作敏感性对照，其数值仅携带排序信息。

预测映射。对化学模型的连续预测 $\hat{z}_{bd}$，比较两种不读取测试评分与测试组零点的映射：(i) 直接线性映射 $\hat{G}_{bd}^{\mathrm{lin}} = \mathrm{round}(T_d(\hat{z}_{bd}))$；(ii) QWK 优化切点——以内层折外预测对混合参照 R 的二次加权 Kappa 为目标，逐维拟合 6 个有序切点，选定后直接用于外层测试折。两法共用同一连续预测与外层划分，按 5 次重复的 50 维平均折外 QWK 选型，并在选定映射下输出等级概率 p_{bdk} 与 90% 区间。

6.3 模型求解

Step 1 预处理与品评团：训练折内列均值填充；精确并列（$k = 3$，9 位小数）构建连通分量得 63 个品评团；逐组维识别零点并执行有效性规则，得 605 个有效组维零点。

Step 2 嵌套交叉验证：外层 StratifiedGroupKFold（5 折，按品评团分组、按风格分层）重复 5 次，内层 4 折同分组调参；单调约束、障碍模型、OAV 和的去留由内层 CV Spearman 决定。按团分组使风格基线 R^2 从 0.181 降至 0.115，其中 0.013 由场次效应贡献，证实分组必要。

Step 3 基线与对照模型：同一划分、同一特征集上运行 B0（训练折均值）、B1（收缩风格均值 $(n_s\bar{z}_{sd}+5\bar{z}_d)/(n_s+5)$）、前 10 特征线性回归、ElasticNet（分位数变换后标准化）、随机森林、文献流程复现 B2、化学 + 风格模型。运行前声明：仅当 ElasticNet 的 50 维平均 Spearman 不低于主模型时主模型改为线性；化学模型须平均 Spearman 超过 B1、品评团簇 bootstrap（2,000 次）配对差 CI 下界大于 0、且在至少一半维度上胜过 B1，否则回退为化学 + 风格模型。

Step 4 等级映射选型：以外层训练集的内层折外预测拟合 QWK 切点，汇合外层测试折计算两种映射对 R 的逐维 QWK，5 次重复平均较高者胜出，并列取直接线性映射。保存逐次逐折预测与训练折参数，保证选型全程无泄漏。

Step 5 交付：250 款 × 50 维折外预测经选定映射输出 $\hat{G}_{bd}$、p_{bdk} 与 90% 区间；全数据重拟合模型留给新啤酒与问题三。

泄漏防护贯穿全程：附件 8 的 SHAP/MDI/基础预测不读取；附件 2、5、6 不用于选择；每个拟合量（填充均值、风格均值、线性端点、参照尺度、QWK 切点）均在对应训练折内估计；测试啤酒的本团零点仅用于构造测试参照，预测映射不读取；外部验证评分仅用于报告。

6.4 结果分析

6.4.1 预测性能

主模型在合并 250 款折外预测上的 50 维平均 Spearman 为 [正式运行值]，与 B1 的配对差 95% CI 下界大于 0，在 [N]/50 个维度上胜过 B1，满足运行前声明的成功标准；RMSE/SD 与 R^2 与同源文献 Table 1 的 GBR（0.21）处于同一水平，而线性回归（-4.13）与 PLSR（-0.25）在 $p \approx n$ 下完全失效，印证树模型选型（图 **??**）。可靠性上限分析表明 12 人品评小组可达 R^2 的中位数为 0.79，远高于实际 0.21，预测误差的主体来自化学数据对感官的解释限度而非品评噪声。

6.4.2 等级映射与交付评分

两种映射对混合参照 R 的 50 维平均 QWK 分别为 [值] 与 [值]，选定 [胜出者]；在 $I=1$（局部参照）与 $I=0$ 子集上分别报告的 QWK、MAE 与 ±1 准确率见表 **??**。局部单元上 A 与 L 的取整差异比例为 [值]，两种参照来源的尺度一致性可接受。交付的 250 款 × 50 维评分以热力图呈现（图 **??**），典型啤酒的预测感官画像与附件 4 观测高度吻合（图 **??**）。

6.4.3 外部检查

公开验证数据的两款基础啤酒与附件 8 校准化学数据在取整精度内唯一匹配（标准化对数距离 0.07 与 0.06，次优匹配 0.42 与 9.08），提供 92 个实测 0–6 原始评分。将两款啤酒的折外预测按选定映射转为等级与实测均值比较：预运行中有锚维度平均误差 -0.47（$m = 3$）、无锚 C-mid 的 MAE 为 0.49–0.58，且两款啤酒的差异在 8 个属性中 7 个符号一致，表明 “化学 $\to z \to$ 0–6” 全链路在外部数据上方向正确；正式运行以选定映射重新报告该检查。

6.4.4 敏感性结果

NA的三种口径（均值填充/原生 NaN/最低位并列加指示）、$m \in \{2.5, 3, \min(4, \mathrm{cap}_d)\}$、无锚维度的 C-mid 与 C-quantile 约定逐一扰动：Spearman 类结论不随 NA 口径与 m 改变（秩指标不依赖换算假设）；m 在 3 与 4 之间时 22% 的有锚等级变动一级，故 0–6 数值结论以 $m = 3$ 为准并附区间；无锚维度的数值在两种约定间的变化如实报告，其评分仅作排序解释。零点可疑（7 维）与零点脆弱（来自单一品评团，4 维）的维度另以 C-mid 作局部参照的敏感性运行。

问题一最终交付：250 款 $\times$ 50 维的 0–6 等级、等级概率与 90% 区间；推断品评团、零点表与 `at_zero` 掩码交付问题二；全数据重拟合的正向模型 f_d 交付问题三作为生成结果的感官评估器。

7 问题二模型的建立与求解

7.1 问题分析

问题二要求利用附件 2 构建化合物共表达图，结合附件 1 的化学特征给出每个感官维度的 Top-3 关键化合物，并论证其稳定性与化学合理性。核心难点有三：其一，化合物间强共变（附件 2 中 $|\rho| \geq 0.5$ 的边达 597 条），若直接按边际相关取前 3，同一信息会以多个高度相关化合物的形式重复入选；其二，250 款啤酒分属 63 个品评团，同团样本共享评分零点且多为同一风格，稳定性检验必须以品评团为单位；其三，关键化合物为关联性结论，须以数据证据（显著性、入选频率、方法间一致性）与酿造化学机理（来源、气味阈值、加标实验）双线论证。

据此确定技术路线：以附件 2 构建共表达图并划分模块，实现冗余控制；在图约束下以偏秩相关前向选择逐位确定 Top-3；以品评团簇 bootstrap 入选频率与多方法 Jaccard 系数量化稳定性；以附件 8 标签、OAV 阈值证据与外部加标实验完成化学合理性论证。流程如图 **??**。

7.2 模型建立

7.2.1 候选集合与秩变换

候选集合 $\mathcal{C}$ 为附件 1 的 231 列扣除 5 个综合指标与 1 个内标，$|\mathcal{C}| = 225$。综合指标由其他化合物计算得到，各自几乎是某一成分的副本（如 `aroma_hops_sum` 与 linalool 的 $|\rho| = 0.96$），保留将使同一信息两次入选；内标反映测量过程而非啤酒组成。二者仍作为图的注释节点保留。理化指标（pH、IBU、color 等）保留为候选，它们是 acidity、bitterness 等维度最直接的解释量。

全部关联基于秩：157 个信号列的变换方式未知，秩不受单调变换影响；附件 2 本身为 Spearman 矩阵，关联与图同度量；检出下限的并列底值自然成为并列秩。化学 NA 按列均值填充，仅作计算占位；感官目标取附件 4 标准化均值 z_{bd} 的秩，与问题一 0–6 评分互为单调变换，结论不依赖换算假设。

7.2.2 共表达图与模块

共表达图 G_τ 以 231 列为节点，边权 $w_{jk} = |\rho_{jk}|$，$|\rho_{jk}| \geq \tau$ 时连边，符号作边属性。取无符号权重：$|\rho| \geq 0.5$ 的 597 条边中仅 13 条为负，且负相关在冗余意义上与正相关等价。模块由相异度 $1 - |\rho|$ 上的平均连接层次聚类在高度 $1 - \tau$ 处切割得到，保证模块内平均相关不低于 τ；相比之下，连通分量会被弱链串联（$\tau = 0.6$ 时最大分量含 96 个化合物），Louvain 需另选分辨率参数且随种子变化，偏相关网络因附件 2 非半正定（5 个负特征值）不可行。

阈值主值取 $\tau = 0.6$，为候选间 $|\rho|$ 的 99% 分位：此时 245 条边构成 33 个多成员模块，来源纯度 0.79，bootstrap 下模块划分 ARI 中位 0.76，均优于 $\tau = 0.5$（纯度 0.70、ARI 0.66）；$\tau = 0.7$ 时模块仅覆盖 65 个化合物，冗余控制范围过窄。模块约束设定：同模块化合物在 250 款啤酒上无法被数据区分为不同的关键因素，故每模块在 T_d 中至多一席，其余成员作为同模块化合物随入选者一并报告。

7.2.3 图约束前向选择

对维度 d，第 1 位取边际秩关联最强者：

$$t_{d1} = \arg\max_{j \in \mathcal{C}} |r_{jd}|, \qquad r_{jd} = \tfrac{1}{n} \tilde{x}_j^\top \tilde{y}_d. \tag{11}$$

第 k 位（$k = 2, 3$）记已选集合 S，H_S 为向 $\mathrm{span}\{\mathbf{1}, \tilde{x}_s : s \in S\}$ 的投影，

$$r_{jd|S} = \frac{e_j^\top e_y}{\|e_j\| \, \|e_y\|}, \qquad e_y = (I - H_S)\tilde{y}_d, \; e_j = (I - H_S)\tilde{x}_j, \tag{12}$$

$$t_{dk} = \arg \max_{j \in \mathcal{C},\, M(j) \notin M(S)} |r_{jd|S}|. \tag{13}$$

偏秩相关衡量化合物在已选者之外还能解释多少维度排序；模块约束 $M(j) \notin M(S)$ 排除与已选者同模块的冗余化合物。

显著性门槛 q_d 取 $\max_j |r_{jd}|$ 置换零分布（打乱 $\tilde{y}_d$ 1,000 次，每次在 225 个候选上取最大值）的 95% 分位，控制维度内多重比较；第 2、3 位用 Freedman–Lane 置换。入选项同时满足得分超过 q_d 且品评团簇 bootstrap 的 95% CI 不含 0 时记为显著。由此定义维度等级：A 级（Top-1 显著且入选频率 $\pi^c \geq 0.6$）、B 级（Top-1 显著）、C 级（Top-1 不显著，记为未找到可靠关键化合物）。

7.2.4 稳定性度量模型

稳定性从两个正交方向量化。**数据扰动：**以品评团为单位有放回抽取 63 个团，每次重算相关矩阵、重建模块、重跑选择，$B = 1{,}000$；记化合物层入选频率 π^c_{jd}、模块层频率 π^m_{jd} 与 bootstrap Jaccard 均值 J^{boot}_d，分档为稳定（$\pi^c \geq 0.6$）、中等（$[1/3, 0.6)$）、不稳定（$< 1/3$）。**方法扰动：**与四个对照方法比较 Top-3 的 Jaccard 系数 $J(A,B) = |A \cap B|/|A \cup B|$——M0 无图约束边际选择、M1 图约束边际选择、M2 秩上 ElasticNet、M3 梯度提升树置换重要度，另加风格内分析（对 22 个风格指示变量取残差后重跑选择），随机 3 元集合的 Jaccard 期望 0.008 作为参照基线。

7.3 模型求解

求解流程为确定性算法，全程种子固定：

Step 1 构图与模块：读入附件 2，复算验收（与附件 1 逐对 Spearman 最大差 6.7×10^{-16}），层次聚类切割得模块表、节点表（含模块内连接度 k^{in}_j 与枢纽）与边表。

Step 2 选择规则验证：在真实化学矩阵上随机植入 3 个异模块化合物、按秩线性组合加噪声生成伪维度，每设置 200 次，比较前向与边际选择的找回率（表 **??**）。前向选择在效应量 $r \geq 0.3$ 时全面占优；观测数据 49 维 Top-1 的 $|r|$ 中位数 0.36，处于该区间，确定前向选择为主方法。模拟仅使用化学矩阵与人工目标。

Step 3 主运行：对 49 个维度执行前向选择与置换检验，产出 Top-3、选择得分、显著性与维度等级。

Step 4 稳定性运行：$B = 1{,}000$ 品评团簇 bootstrap 与五个对照方法，产出 π^c、π^m、J^{boot} 与方法间 Jaccard。

Step 5 化学证据汇总：关联附件 8 的来源、缺陷与老化标签；对有阈值的化合物计算 OAV≥ 1 的啤酒比例；标注共变标记（风格内 CI 含 0、进入 ≥ 5 个维度、或全部啤酒 OAV< 1）；逐项撰写机理解释并核对入选符号。

Step 6 敏感性运行：$\tau \in \{0.5, 0.7\}$、候选集加回排除列、NA 两种对照口径、固定附件 2 构图、按单款啤酒重抽、39 个有锚维度改用减零点评分，共 7 组，各报告与基线的 Jaccard 及 Top-1 改变维度数。

7.4 结果分析

7.4.1 共表达图结构

$\tau = 0.6$ 下 245 条边构成 33 个多成员模块，覆盖 97 个化合物，代表性模块与酿造学知识吻合：ethanol–ethyl acetate–ethyl hexanoate–glycerol（发酵强度轴）、isoamyl acetate–isobutyl acetate–n-hexanol（乙酸酯类）、ethyl octanoate–ethyl decanoate（中链脂肪酸乙酯）、color–protein（麦芽轴）、linalool–α-terpineol（酒花萜类）。模块的来源纯度 0.79，即强共变主要发生在同一酿造来源的化合物之间，图 **??** 中同色节点聚为同圈的格局直观反映了这一点。

7.4.2 Top-3 识别结果

49 个维度中，Top-1 显著 47 个，第 2、3 位显著分别为 37、20 个；置换门槛 q_d 中位数 0.227，Top-1 的 $|r|$ 中位数 0.36。代表性结果与酿造化学一致：bitterness 的 Top-1 为 IBU，acidity 为 pH，esters_all 为 isoamyl acetate，body 为 ethanol（同模块含 glycerol）。A_esters_flower 与 t2n 两维 Top-1 未超门槛，列为 C 级。全部 49 维的 Top-3、得分、CI 与等级见附录表 **??**。

风格内分析显示：147 个入选项中 98% 在风格内保持同号，其中 18 项风格内 $|r^{(s)}| < 0.1$——如 lactic acid $\rightarrow$ lactic（合并 0.45，风格内 -0.00）、pH $\rightarrow$ acidity（-0.50，-0.09），其关联来自酸啤风格与其他风格之间的配方差异，已标注共变标记；风格内 Top-3 作为次要输出交付问题三。

7.4.3 稳定性结果

品评团簇 bootstrap 下，按位置的化合物层入选频率为 0.56、0.35、0.19，模块层为 0.62、0.40、0.21；J^{boot} 均值 0.267，为随机基线 0.008 的 33 倍。147 个入选项中稳定 28 项、中等 41 项、不稳定 78 项（图 **??**）。结合植入实验的找回率标尺（真实效应 $r \approx 0.3$、排第 3 位的化合物在 0.2–0.7 的重复中被找回），结论为：在 250 款啤酒的样本量下，多数维度可靠支持的关键化合物为 1 个、至多 2 个，第 3 位以报告为主。模块层频率高于化合物层的差值即同模块化合物间的轮换，印证了模块不可分设定。

方法间 Jaccard 见表 **??** 与图 **??**。线性族方法与主方法 Top-1 完全一致（M0、M1 为 1.00，M2 为 0.63），表明第 1 位结论对估计方式不敏感；M0 有 22/49 维的前 3 含同模块冗余（如 A_malt_all 的 color 与 protein），正是图约束消除的对象。M3 允许非线性后 Top-1 一致比例降至 0.37（如 metallic 的 M3 Top-1 为 iron），此类维度并列报告两法结果并各附化学解释。

7.4.4 化学合理性结果

有阈值的 26 个入选化合物中，ethanol（0.98）、linalool（0.98）、citronellol（0.92）、IBU（0.86）、isoamyl acetate（0.84）、geraniol（0.76）、DMS（0.67）、ethyl acetate（0.66）、

acetic acid（0.62）在多数啤酒中 OAV≥ 1，其感官作用有直接的浓度基础（图 **??**）；acetaldehyde、ethyl decanoate、furfural 等 5 个化合物在全部啤酒中 OAV< 1，标为共变标记，其入选反映与未测或同模块化合物的共变，亚阈值酯类的加和效应亦为已知现象。进入 ≥ 5 个维度 Top-3 的 color、ethanol、protein 等 7 个候选标记工艺与风格强度轴。

外部加标实验提供因果方向的核验（表 **??**）：七种化合物混合加标在三组底酒中均显著提高 Esters（配对差 0.90–1.31，$t \geq 2.9$），支持酯类作为 esters_all 关键因素；未加入酒花化合物时 Hops 与 Bitterness 不变（$|t| \leq 0.9$），构成阴性对照，排除加标杯整体抬分的可能；Fullness 在无乙醇组同样提高，表明 glycerol 等同模块成分足以产生醇厚感。

7.4.5 敏感性结果

七组敏感性运行中，Top-3 与基线的化合物层 Jaccard 均值、Top-1 改变维度数汇总于附录表 **??**。化合物层入选频率在 $\tau \in \{0.5, 0.6, 0.7\}$ 下完全相同，阈值仅影响模块层解读；NA 口径与 bootstrap 单位的扰动均未改变 A 级维度的 Top-1。结论对建模选择稳健。

问题二最终向问题三交付三项结果：模块表（同模块化合物在生成时应一起变化，综合指标由成分推导）、风格内 Top-3，以及缺陷维度（DMS、4VG、diacetyl、t2n、stale hops）的关键化合物清单。

8 问题三模型建立与求解

8.1 条件生成模型原理

选用适合表格数据条件生成模型（如 CTGAN 等），将啤酒细分风格标签 tasting_category_fine 作为条件输入，学习不同风格啤酒化合物谱分布。

8.2 风味指纹生成模块构建

输入指定啤酒风格标签（Tripel、Kriek、Lambic），模型输出该风格对应的全套化合物谱，再通过问题一训练好的感官评分模型，得到该风格的感官画像。

8.3 带约束跨风格迁移模块构建

目标：将 Pils/Lager 样本化合物谱迁移至 Tripel 风格；硬性约束：DMS、Diacetyl、4VG、trans-2-nonenal、Stale hops 缺陷化合物指标不能恶化，在生成损失函数增加约束项，保证缺陷指标满足条件。

8.4 结果评估与分析

评估生成化合物谱分布是否符合真实样本分布，对比迁移前后风味变化与缺陷化合物指标，可视化不同风格风味指纹。

9 模型评价

9.1 模型优点

9.2 模型不足

9.3 灵敏度与鲁棒性分析

10 参考文献

参考文献

[1] 啤酒风味物质代谢相关文献

[2] 共表达网络构建相关文献

[3] 表格数据条件生成模型相关文献

11 附录

附录放置 Python 核心代码、补充图表、额外实验结果。