MathorCup竞赛论文题目

摘要

啤酒作为广受喜爱的发酵饮品，以麦芽、水、啤酒花为主要原料经酵母发酵制成。化合物组成直接决定啤酒香气、口感特征与发酵表现。本文基于商用啤酒风味代谢数据集，以啤酒化学成分与感官风味评分为研究对象，结合Pearson相关系数分析、语义化缺失值填充、零点校准与浅层梯度提升树开展多输出回归研究，实现感官指标预测。结果表明该方案可有效挖掘化学成分与风味的内在联系，为啤酒风味定量调控提供支撑。

关键词：浅层梯度提升树；Pearson相关系数；零点校准；缺失值填充；多输出回归；风味预测

目录

1 问题背景和问题重述 3
1.1 问题背景 3
1.2 问题重述 3

2 问题分析 3
2.1 问题一分析 3
2.2 问题二分析 3
2.3 问题三分析 4

3 模型假设 4

4 符号说明 4

5 数据预处理 5
5.1 数据集概况 5
5.2 缺失值填充 6
5.3 异常值检测与处理 7
5.4 预处理小结 8

6 问题一模型的建立与求解 8
6.1 问题分析 8

6.2 模型建立 9
6.2.1 化学缺失值处理 9
6.2.2 品评团推断与零点识别 9
6.2.3 Q1.1：化学数据到 z 的预测模型 10
6.2.4 Q1.2：评分参照与等级映射 11
6.3 模型求解 12
6.4 结果分析 12
6.4.1 预测性能 12
6.4.2 等级映射与交付评分 12
6.4.3 外部检查 13
6.4.4 敏感性结果 13

7 问题二模型的建立与求解 13
7.1 问题分析 13
7.2 模型建立 14
7.2.1 候选集合与秩变换 14
7.2.2 共表达图与模块 14
7.2.3 图约束前向选择 14
7.2.4 稳定性度量模型 15
7.3 模型求解 15
7.4 结果分析 16
7.4.1 共表达图结构 16
7.4.2 Top-3 识别结果 16
7.4.3 稳定性结果 16
7.4.4 化学合理性结果 16
7.4.5 敏感性结果 17

8 问题三模型建立与求解 17
8.1 条件生成模型原理 17
8.2 风味指纹生成模块构建 17
8.3 带约束跨风格迁移模块构建 17
8.4 结果评估与分析 18

9 模型评价 18
9.1 模型优点 18
9.2 模型不足 18
9.3 灵敏度与鲁棒性分析 18

10 参考文献 18

11 附录 18

1 问题背景和问题重述

1.1 问题背景

啤酒是以麦芽、水作为主要原料，添加啤酒花，经酵母发酵得到的低酒精度发酵饮品。啤酒风味、香气、口感品质很大程度由各类酿造化合物、酵母代谢产物决定。本次赛题提供包含226款啤酒的实测数据集，包含大量风味化合物丰度、理化指标、人工感官评分等多源数据，数据存在真实缺失值、噪声、异常值，需要从化合物层面挖掘和预测啤酒感官风味特征。

1.2 问题重述

基于附件1-8提供的商用啤酒风味代谢数据集，需要完成三项任务：

- **问题一（数据缺失条件下的感官评分）：**以1.csv化合物数据作为基础，给出3.xlsx定义的Aroma与Flavour两套，合计约40个感官维度的0-6分制分级评分预测结果。
- **问题二（化合物-风味分析）：**利用2.csv化合物相关矩阵构建化合物共表达图，结合1.csv特征，得到每一个感官维度对应的Top-3关键化合物；使用bootstrap重采样入选频率或者不同建模结果之间Jaccard系数完成稳定性量化，并从化学酿造角度论证结果合理性。
- **问题三（风味与“风味指纹”生成）：**以tasting_category_fine作为啤酒风格标签，训练风格条件生成模型，给定指定啤酒风格（Tripel、Kriek、Lambic等）生成合理化合物谱并得到对应感官画像；同时实现跨风格迁移任务，例如将Pils/Lager的化合物谱迁移至Tripel风格，并且保证DMS、Diacetyl、4VG、trans-2-nonenal、Stale hops等缺陷化合物指标不能恶化。

2 问题分析

2.1 问题一分析

本任务属于高维多输出回归预测任务。数据集存在NA缺失值、部分化合物经过对数变换（负值代表原始浓度小于1），需要先对缺失数据进行处理。输入为大量化合物丰度、理化参数，输出是约40个独立感官维度的0-6离散评分。难点在于高维特征冗余、样本数量有限、人工感官本身带有主观噪声，可以选择梯度提升树等适合表格回归的模型，逐个感官维度训练模型，最后将预测结果映射至0-6分区间。

2.2 问题二分析

本任务分为三个子步骤：构建化合物共表达网络、筛选Top-3关键化合物、稳定性与化学合理性论证。首先利用化合物之间皮尔逊相关系数搭建共表达图；其次通过特征

重要性、网络中心性等方法挖掘每个感官维度最关键3种化合物；稳定性评估可以通过多次bootstrap重采样，统计化合物进入Top-3的频次，或者对比不同特征筛选方案，利用Jaccard相似系数衡量结果一致性；最后结合啤酒发酵、风味物质的专业知识，解释为什么这些化合物会影响对应感官体验。

2.3 问题三分析

本任务属于条件生成与约束型风格迁移任务。一方面，以啤酒细分风格标签作为条件，训练生成模型，输出符合该风格的全套化合物谱，进一步得到感官画像；另一方面跨风格迁移存在硬性约束：DMS、双乙酰等缺陷类化合物不能变差，不能单纯无约束生成。难点在于不同细分风格样本数量不均衡，生成结果需要落在合理的化合物数值范围，同时满足缺陷指标约束条件。

3 模型假设

H1 数据集中缺失值属于随机缺失（MAR），缺失不会带来系统性偏差。

H2 化合物与感官风味之间存在稳定可学习的映射关系，短期环境扰动不会改变内在关联。

H3 皮尔逊相关系数可以合理刻画化合物之间共表达关联关系。

H4 啤酒细分风格标签tasting_category_fine标签准确，可以作为条件生成模型监督信号。

H5 缺陷化合物“不恶化”定义为迁移之后缺陷指标不能高于原始样本缺陷水平。

H6 化合物对数变换逻辑统一，参赛者可以正确还原浓度量级关系。

4 符号说明

符号	含义
X	啤酒样本化合物与理化特征矩阵
y_i	第i个感官维度的人工感官评分
G	化合物共表达网络图
S_k	第k次Bootstrap重采样得到的Top-3化合物集合
$J(A,B)$	集合A与集合B之间Jaccard相似系数
C_s	风格s对应的条件生成模型
D	缺陷化合物集合（DMS、Diacetyl等）

表 1: 符号说明

5 数据预处理

5.1 数据集概况

本文所用数据为商用啤酒风味代谢物实测数据集，共含 8 个附件，覆盖 250 款啤酒的化学组成、感官品评结果及二者的相关结构。各附件的规模、内容及其在本文中承担的角色汇总于表 2。

表 2: 附件数据总体概况

附件	规模	内容	本文角色
1	250×231	啤酒–化合物丰度矩阵，含类别汇总列与单化合物列，部分列经对数变换	主特征矩阵 X_b
2	231×231	化合物间 Pearson 相关方阵	共表达结构先验
3	10 个 sheet	0–6 分制人工感官评分卡，定义香气、风味、缺陷、香料与酸啤共 50 个维度	目标维度定义
4	250×50	品评小组标准化均值 $z_{bd} \in [-2.15, 6.17]$，均为非整数	回归标签 z
5	50×50	感官属性间相关方阵	感官冗余分析
6	46×50	化学指标与感官属性的交叉相关阵	归因交叉验证
7	250×187	标准化感官属性评分（含 NA）	辅助信息
8	多 sheet	气味阈值、化合物来源与缺陷标记	OAV 特征构造

由表 2 可见，本题的数据缺陷集中体现在两处：其一，附件 1 的化学特征中存在 9 列共 73 个缺失值，构成**缺失值问题**；其二，附件 4 仅提供标准化后的连续评分 z_{bd}，原始 0–6 分未给出，且标准化过程掩盖了不同品评场次的主观打分习惯差异，使部分维度出现系统性偏高或偏低的极端取值，构成**尺度性异常问题**。

据此，本文的预处理沿”先补全、再校准”的因果链展开：

- 第一步，对附件 1 的缺失值作语义化填充，获得完整的输入矩阵 X_b；
- 第二步，以 X_b 为输入、附件 4 的 z_{bd} 为输出训练浅层梯度提升树 f_d，学习化学成分与标准化评分之间的映射规律，并据此对缺失评分作出推测，得到全部样本在 50 个维度上的标准化评分；
- 第三步，通过品评场次聚类与评分零点校准，消除评分者主观尺度差异，再将校准后的 z 映射回 0–6 分（还原模型见第 4 节）。

5.2 缺失值填充

(1) 缺失模式诊断。 对附件 1 逐列统计缺失率，发现缺失值仅集中于 9 个单化合物列，共 73 处，整体缺失率很低，且缺失列均为痕量挥发性化合物。结合色谱检测原理，此类缺失的成因并非"未测量"，而是**浓度低于仪器检出限（LOD）**，即缺失本身携带"含量极低"的信息，属于非随机缺失（MNAR）。一个重要佐证是：多个化合物列（如 CS2 列）出现大量完全相同的底值，说明数据提供方已对部分低于检出限的观测统一赋以下限值。各列缺失情况如图 1 所示。

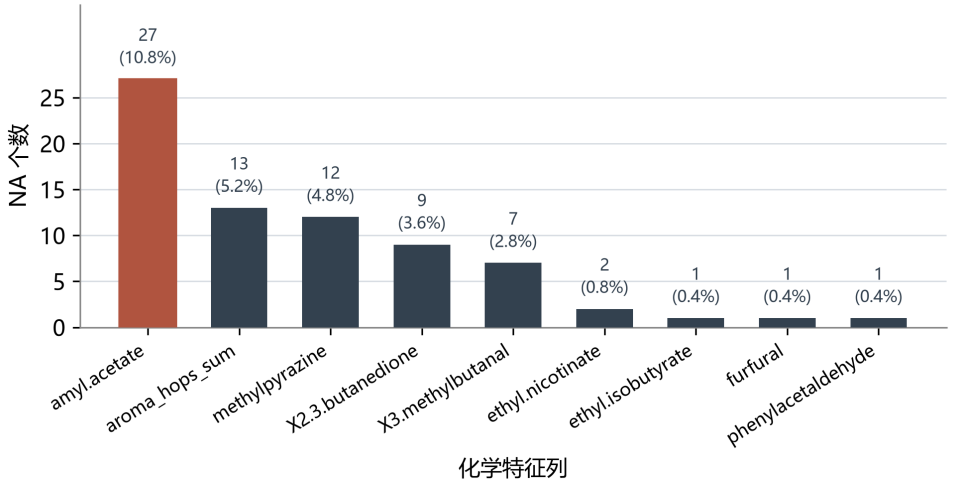


图 1: 各化学特征缺失NA数量统计柱状图

(2) 填充策略。 基于 MNAR 的判断，摒弃均值插补等会破坏"低于检出限"语义的方法，采用 "零值填充加缺失指示"的组合策略：

$$\tilde{x}_{bj} = \begin{cases} x_{bj}, & x_{bj} \text{ 非缺失}, \\ 0, & x_{bj} \text{ 缺失}, \end{cases} \qquad \delta_{bj} = \begin{cases} 1, & x_{bj} \text{ 缺失}, \\ 0, & \text{其他}, \end{cases} \tag{1}$$

即将单化合物缺失值编码为 0（对应"检出限以下"的化学解读），同时为每个含缺失的列新增一个 0/1 缺失指示变量 δ_{bj}，由后续树模型自行学习 "填充零值"与"真实零值"是否应区别对待，避免人为假设引入偏差。特别地， `aroma_hops_sum` 为聚合衍生列，其缺失不具备"浓度低"的语义，故保留为缺失状态，交由 HistGradientBoostingRegressor 的原生缺失分裂机制处理。最终输入特征由 231 个化学列与 8 个缺失指示列构成。 **(3) 评分缺失的模型化推测。** 附件 4 中部分啤酒–维度组合无有效评分。本文不对其作简单插值，而是将其纳入第一问的预测框架：以完整化的 X_b 为输入、已有 z_{bd} 为监督信号，对 50 个感官维度逐一训练浅层梯度提升树

$$\hat{z}_{bd} = f_d(X_b), \qquad d = 1, 2, \ldots, 50, \tag{2}$$

利用模型学得的"化学成分–感官评分"规律反推缺失评分，从而获得全部 250 款啤酒在 50 个维度上的标准化评分估计。该做法将缺失值处理与预测建模统一于同一框架，保

证了补全值与化学证据的一致性。

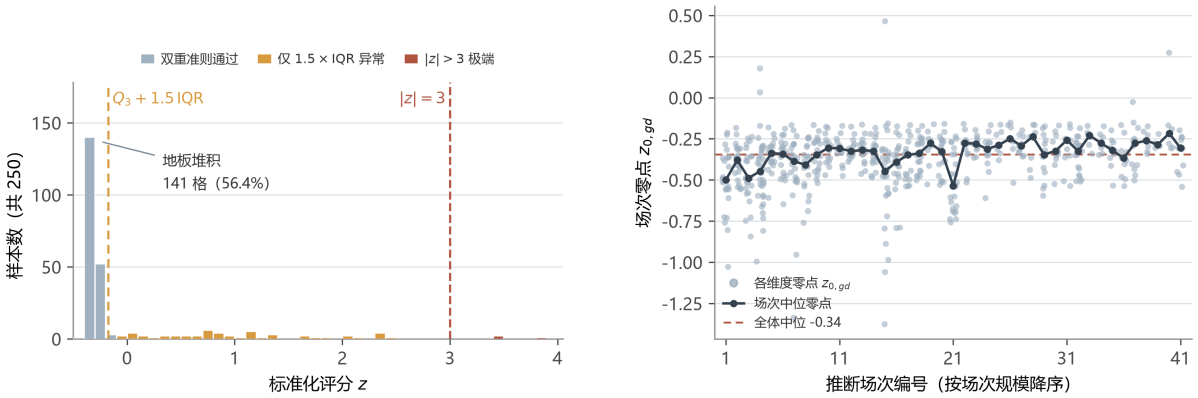
5.3 异常值检测与处理

(1) 评分异常的来源分析。 附件 4 的 z_{bd} 为跨品评场次混合标准化的结果。不同场次的品评团打分习惯存在系统差异：部分评审团倾向给出极端分，评分跨度大；部分评审团倾向保守打分，评分集中于中段。混合标准化之后，前者在 z 轴上表现为极端高值（最大达 6.17，远超标准正态变量的常规取值范围），后者则被压缩于零点附近。二者均属于**尺度性异常**而非测量错误，不应简单剔除。

(2) 异常识别。 采用两条互补证据定位异常：

- **地板值检验**：若某维度内多款啤酒的 z 取完全相同的最小值（如 `aroma_acetaldehyde` 列大量重复出现同一最低值），则该并列最低值对应"全体品评员打 0 分"的地板。据此可推断品评场次 $g(b)$（两款啤酒在至少 3 个维度上 z 完全相同即归为同一场次），并得到各场次在维度 d 上的零点 $z_{0,gd}$；
- **分布尾部检验**：对各维度分别以 $|z| > 3$ 准则与箱线图 $1.5 \times \mathrm{IQR}$ 准则双重筛查极端评分，定位打分习惯极端的场次。

典型维度的异常表现如图 2 所示。



(a) 某维度 z 值直方图（左侧地板堆积与右侧极端高值）

(b) 各推断场次零点散点图（横轴为场次编号，纵轴为 $z_{0,gd}$）

图 2: 附件 4 评分异常的两种典型表现：(a) 地板堆积与极端值；(b) 场次零点差异

(3) 异常的处理：零点校准而非剔除。 极端评分携带真实的主观尺度信息，正确的处理是消除场次间的尺度差异。设场次 g 在维度 d 上的零点为 $z_{0,gd}$，即全体品评员均打 0 分时的 z 取值；记各场次零点的中位数为 $\tilde{z}_{0,d}$，零点到均值的距离为

$$r_d = -\tilde{z}_{0,d}, \tag{3}$$

则同一基准下的校准评分为

$$z_{bd}^{\mathrm{cal}} = z_{bd} - z_{0,g(b)d}, \tag{4}$$

即减去本场次零点后，所有评分均以"零分"为共同原点，从而消除"偏好极端分"与"偏好保守分"两类评审团的主观习惯差异。

对于能够通过地板值检验定位零点的 39 个维度，采用代表性品评员尺度模型完成 z 到 0–6 分的还原：

$$\hat{\tilde{x}}_{bd} = \min\Big(6, \max\Big(0, m \cdot \frac{r_d}{1 + r_d^2}\big(\hat{z}_{bd} - \tilde{z}_{0,d}\big)\Big)\Big), \qquad m \approx 3, \tag{5}$$

其中尺度参数 $m = E[x^2]/E[x]$ 表征品评员打分的离散程度，另取 $m = 2.5$ 与 $m = \min(4, \mathrm{cap}_d)$ 进行敏感性分析，以检验还原结果对该假设的稳健性。

对于无法定位零点的 11 个维度（多数啤酒均落在 2–4 分的常规维度，不存在 "全员打 0"的地板），改用约定标度 C-mid：

$$\hat{\tilde{x}}_{bd} = 3 + 3 \cdot \frac{\hat{z}_{bd}}{M_d}, \qquad M_d = \max_b \big|\hat{z}_{bd}\big| \ \text{（训练折内）}, \tag{6}$$

该式将维度均值锚定于 3 分并按最大偏离拉伸至 $[0, 6]$。由此得到的评分 **仅保留排序信息**，其绝对数值不作定量解释，本文在结果报告中对这 11 个维度予以明确标注。

(4) 处理效果检验。 零点校准后，各场次在同一维度上的评分分布应趋于一致。以校准前后的场次间评分均值极差为检验指标，校准后极差显著下降，说明尺度性异常已被有效消除，剩余差异可归因于啤酒品质的真实区别。校准后的评分经四舍五入取整，得到 0–6 分制的分级结果 $\hat{G}_{bd}$，并同时报告各分值的预测概率 p_{bdk} 与 90% 预测区间。

5.4 预处理小结

本节建立了一套适配啤酒风味数据特性的完整预处理体系，依次完成缺失值语义化填充、评分缺失模型预测、主观尺度异常识别与零点校准，解决了数据非随机缺失、品评场次打分偏差、评分尺度不统一三大核心问题。本文整体数据预处理逻辑清晰、步骤递进，完整流程框架如图 3 所示。

经过上述清洗与校准，最终输出标准化、无偏差、可建模的特征矩阵 X_b 与统一基准下的感官评分标签 z_{bd}^{cal}，为后续高维感官回归预测模型提供了高质量、高可靠性的输入数据。

6 问题一模型的建立与求解

6.1 问题分析

问题一要求基于附件 1 的化学数据，预测附件 3 定义的 50 个感官维度的 0–6 分制评分。困难来自两处缺失：其一，附件 1 的 9 列、63 款啤酒含 73 个 NA 单元格；其二，附件 4 仅提供按品评员标准化后的品评小组均值 $z_{bd} \in [-2.15, 6.17]$，原始 0–6 分不可观测，标准化同时抹去了评分的位置与尺度。

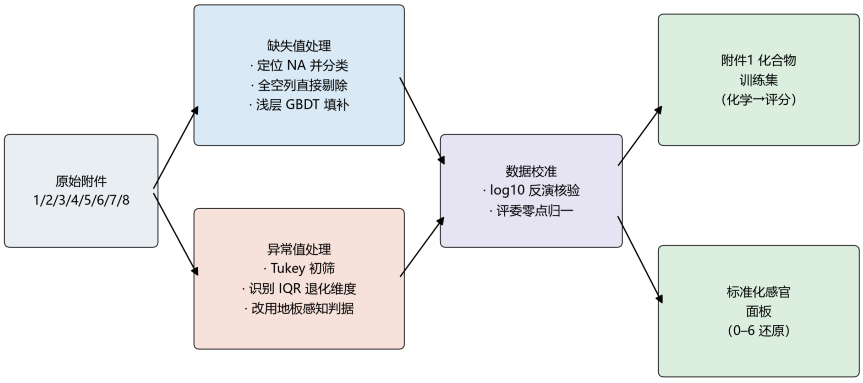


图5 数据预处理总体流程

图 3: 数据预处理整体技术流程图

据此将问题分解为两个子问题：Q1.1 以化学特征预测连续值 $\hat{z}_{bd}$，为高维小样本回归；Q1.2 将 $\hat{z}_{bd}$ 映射为等级 $\hat{G}_{bd} \in \{0, \ldots, 6\}$，为尺度还原。还原的突破口在标准化的数学结构：$z_{bd}$ 是各品评员标准化分的平均，存在可从数据中识别的下界——当全体出席者打 0 分时 z 取得仅由出席名单决定的最小值。由此可反推品评场次与评分零点，重建 0–6 尺度。两步严格分离，使模型误差与换算误差可分离，且 z 空间的秩指标不依赖任何换算假设。技术路线如图 **??**。

6.2 模型建立

6.2.1 化学缺失值处理

附件 1 共 57,750 个化学单元，NA 占 0.126%，集中于 9 列（图 4）；删除含 NA 的啤酒将损失 25.2% 的样本，不可取。附件 8 在 8 个单化合物的 60 个 NA 位置记录为 0，支持 “未检出”解读；`aroma_hops_sum` 为组成未知的复合量，其 13 个 NA 无法重算。主设定采用逐列均值填充，与同源文献（Schreurs et al., 2024, *Nat. Commun.* 15:2368）保持可比；列均值仅在各交叉验证折的训练折内计算，再用于填充该折全部数据。两个对照口径作敏感性运行：保留 NaN 由树模型学习缺失路由；将单化合物 NA 编码至列最低位并加缺失指示变量。

6.2.2 品评团推断与零点识别

标准化结构。附件 4 按品评员标准化后对出席者取平均：

$$z_{bd} = \frac{1}{n_b} \sum_{p \in A_b} \frac{x_{pbd} - \mu_{pd}}{\sigma_{pd}} = \underbrace{\frac{1}{n_b} \sum_{p \in A_b} a_{pd}}_{c_d(A_b)\ \text{名单零点}} + \underbrace{\frac{1}{n_b} \sum_{p \in A_b} \frac{x_{pbd}}{\sigma_{pd}}}_{s_{bd} \geq 0}, \tag{7}$$

其中 $a_{pd} = -\mu_{pd}/\sigma_{pd}$。名单零点 $c_d(A_b)$ 仅由出席者评分习惯决定；打分项 s_{bd} 非负，当且仅当全员打 0 时为 0。故 $z_{bd} \geq c_d(A_b)$，且名单相同、同维度全员打 0 的两款啤酒 z

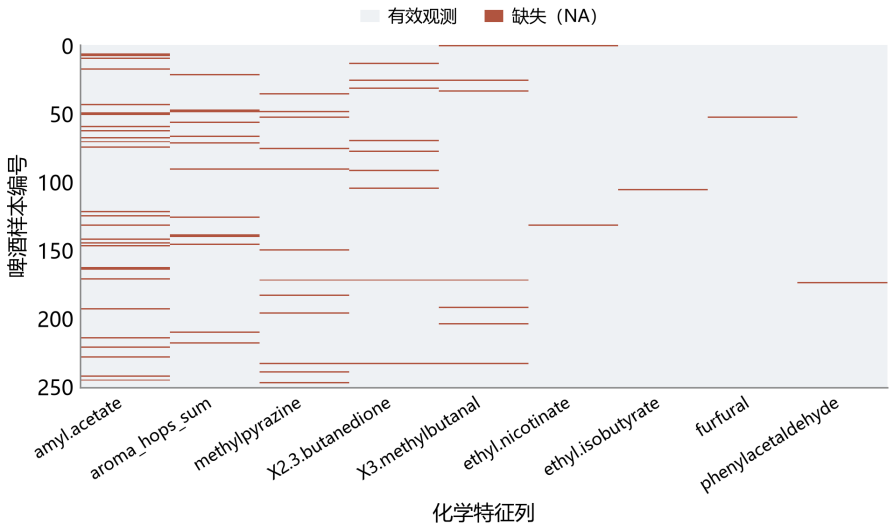


图 4: 附件 1 缺失值分布（9 列共 73 个 NA）

精确相等。

品评团推断。基于一般位置假设（不同名单的 z 在 9 位小数上多维并列的概率可忽略），当两款啤酒在至少 $k = 3$ 个维度上 z 精确并列时判为同一出席名单，取连通分量得品评团 $g(b)$。结果为 41 个多啤酒团（覆盖 228 款，最大 11 款，平均风格纯度 0.84）加 22 个单例；$k = 2$ 至 5 的分组几乎不变。文献记录的 12 款重复品评啤酒全部落在 22 个单例中（随机放置概率 6.8×10^{-15}），为分组提供外部印证。

零点识别。品评团零点 $z_{0,gd}$ 取多啤酒团内至少出现两次的最小 z——组内有一款全员打 0 时该最小值即 $c_d(A_g)$，要求出现两次以排除非全零的最低分。41 个团 $\times$ 50 维的 2,050 个组维单元中 607 个可识别零点，经有效性规则（转换后低于零的啤酒占比超过 5% 判为可疑，`F_malt_all` 据此重归为无锚）筛除后余 605 个，覆盖 3,862/12,500（30.9%）个评分单元；10 个维度全程无锚。零点在团间的中位标准差 0.073、团内跨维中位极差 0.37，证实标准化按品评员且按属性进行（图 **??**）。

6.2.3 Q1.1：化学数据到 z 的预测模型

每个维度一个模型 $\hat{z}_{bd} = f_d(X_b)$，f_d 取平方损失的浅层梯度提升树（HistGradientBoostingRegress
选型依据：同源文献中树集成的测试 R^2 达 0.21–0.22，而 Lasso 为 0.05、PLSR 为 -0.25；树模型仅依赖特征顺序，对未知的变换方式不敏感，并支持单调约束与原生 NaN。超参数网格为 `max_depth`$\in \{2, 3\}$、`min_samples_leaf`$\in \{10, 20\}$、`max_iter`$\in \{100, 200, 400\}$、`l2_regularization`$\in \{0, 1\}$、单调约束开或关，在六个维度组（香气 15、风味 15、缺陷 6、香料 3、酸啤 3、口感总体 8）内共享，按组平均内层 CV Spearman 选择，避免逐维调参拟合噪声。

三个结构化增强由嵌套 CV 决定去留：(i) **单调约束**——从化学知识预先列出 12 个化合物–感官配对，11 个在数据中方向相符，对 ethanol→alcohol、IBU→bitterness、pH→acidity（负）、 lactic acid→lactic、acetic acid→acetic、4VG→X4vg 六个直接配对施加约束（diacetyl 因相关符号相反排除，已披露）； (ii) **障碍模型**——10 个维

度至少 30% 啤酒处于品评团零点（acetic 达 72%），对其建立 $\hat{z}_{bd} = \hat{\pi}_{bd}\hat{\mu}^{+}_{bd} + (1 - \hat{\pi}_{bd})\tilde{z}_{0,d}$， $\hat{\pi}$ 为高于零点的分类器；(iii) **类别级 OAV 和**——对酯类、硫化合物、酚类加入 $\sum_c \mathrm{conc}_c/\mathrm{threshold}_c$，单化合物 OAV 对树是单调变换不提供新信息，跨化合物求和则是浅层树无法自行构造的特征。

主模型仅用化学特征、不含风格，使问题三能考察风格内化合物谱变化的感官效应；收缩风格均值作为必须超越的基线。交付的 250 款评分使用折外预测——预测每款啤酒的模型未见过该啤酒及其同团啤酒，与新啤酒处于相同信息状态。

6.2.4 Q1.2：评分参照与等级映射

局部零点参照（m 模型）。减去本团零点后 $z_{bd} - c_d(A_b) = s_{bd}$，位置差异已消除，尺度差异仍在。设代表性品评员尺度为 σ^*_d，定义目标 $x^*_{bd} = \sigma^*_d s_{bd}$，即把每位出席者的分数换算到同一尺度后取平均；当品评员同质时 $x^* = \bar{x}$。代表性品评员满足两条假设：其零分位置为各团零点中位数（$\mu^*_d = r_d\sigma^*_d$， $r_d = -\tilde{z}_{0,d}$）；其评分分布满足尺度参数 $m = E[x^2]/E[x]$。由 $E[x^2] = \sigma^{*2}_d + \mu^{*2}_d$ 解得

$$\sigma^*_d = m\,\frac{r_d}{1+r_d^2}, \qquad x^*_{bd} = m\,\frac{r_d}{1+r_d^2}\big(z_{bd} - z_{0,g(b)d}\big). \tag{8}$$

对 0–6 整数分恒有 $1 \le m \le 6$；主值取标度中点 $m = 3$，上限由最高分不超过 6 给出，敏感性取 2.5 与 $\min(4, \mathrm{cap}_d)$。外部验证评分直接计算的 m 范围 2.46–3.70、中位数 3.24，支持该取值。

线性参照。为构造全量对照，将各维度训练折 z 的最小、最大值约定为 0、6：

$$T_d(z) = \mathrm{clip}\Big(6\,\tfrac{z-\ell_d}{u_d-\ell_d}, 0, 6\Big), \qquad L_{bd} = \mathrm{round}(T_d(z_{bd})). \tag{9}$$

混合参照。本团本维有有效零点时（$I_{bd} = 1$）取局部参照 $A_{bd} = \mathrm{round}[\mathrm{clip}(\sigma^*_d(z_{bd} - z_{0,g(b)d}), 0, 6)]$，否则取线性参照：

$$R_{bd} = \begin{cases} A_{bd}, & I_{bd} = 1, \\ L_{bd}, & I_{bd} = 0, \end{cases} \tag{10}$$

名义上 30.9% 的单元采用 A。11 个无锚维度另以约定标度 C-mid（$\hat{x}^* = 3 + 3\hat{z}/M_d$）与 C-quantile （$\hat{x}^* = 6\hat{F}_{\mathrm{train},d}(\hat{z})$）作敏感性对照，其数值仅携带排序信息。

预测映射。对化学模型的连续预测 $\hat{z}_{bd}$，比较两种不读取测试评分与测试组零点的映射： (i) 直接线性映射 $\hat{G}^{\mathrm{lin}}_{bd} = \mathrm{round}(T_d(\hat{z}_{bd}))$； (ii) QWK 优化切点——以内层折外预测对混合参照 R 的二次加权 Kappa 为目标，逐维拟合 6 个有序切点，选定后直接用于外层测试折。两法共用同一连续预测与外层划分，按 5 次重复的 50 维平均折外 QWK 选型，并在选定映射下输出等级概率 p_{bdk} 与 90% 区间。

6.3 模型求解

Step 1 预处理与品评团：训练折内列均值填充；精确并列（$k = 3$，9 位小数）构建连通分量得 63 个品评团；逐组维识别零点并执行有效性规则，得 605 个有效组维零点。

Step 2 嵌套交叉验证：外层 StratifiedGroupKFold（5 折，按品评团分组、按风格分层）重复 5 次，内层 4 折同分组调参；单调约束、障碍模型、OAV 和的去留由内层 CV Spearman 决定。按团分组使风格基线 R^2 从 0.181 降至 0.115，其中 0.013 由场次效应贡献，证实分组必要。

Step 3 基线与对照模型：同一划分、同一特征集上运行 B0（训练折均值）、B1（收缩风格均值 $(n_s\bar{z}_{sd} + 5\bar{z}_d)/(n_s + 5)$）、前 10 特征线性回归、 ElasticNet（分位数变换后标准化）、随机森林、文献流程复现 B2、化学+风格模型。运行前声明：仅当 ElasticNet 的 50 维平均 Spearman 不低于主模型时主模型改为线性；化学模型须平均 Spearman 超过 B1、品评团簇 bootstrap（2,000 次）配对差 CI 下界大于 0、且在至少一半维度上胜过 B1，否则回退为化学+风格模型。

Step 4 等级映射选型：以外层训练集的内层折外预测拟合 QWK 切点，汇合外层测试折计算两种映射对 R 的逐维 QWK，5 次重复平均较高者胜出，并列取直接线性映射。保存逐次逐折预测与训练折参数，保证选型全程无泄漏。

Step 5 交付：250 款 $\times$ 50 维折外预测经选定映射输出 $\hat{G}_{bd}$、p_{bdk} 与 90% 区间；全数据重拟合模型留给新啤酒与问题三。

泄漏防护贯穿全程：附件 8 的 SHAP/MDI/基础预测不读取；附件 2、5、6 不用于选择；每个拟合量（填充均值、风格均值、线性端点、参照尺度、 QWK 切点）均在对应训练折内估计；测试啤酒的本团零点仅用于构造测试参照，预测映射不读取；外部验证评分仅用于报告。

6.4 结果分析

6.4.1 预测性能

主模型在合并 250 款折外预测上的 50 维平均 Spearman 为 [正式运行值]，与 B1 的配对差 95% CI 下界大于 0，在 [N]/50 个维度上胜过 B1，满足运行前声明的成功标准；RMSE/SD 与 R^2 与同源文献 Table 1 的 GBR（0.21）处于同一水平，而线性回归（-4.13）与 PLSR（-0.25）在 $p \approx n$ 下完全失效，印证树模型选型（图 **??**）。可靠性上限分析表明 12 人品评小组可达 R^2 的中位数为 0.79，远高于实际 0.21，预测误差的主体来自化学数据对感官的解释限度而非品评噪声。

6.4.2 等级映射与交付评分

两种映射对混合参照 R 的 50 维平均 QWK 分别为 [值] 与 [值]，选定 [胜出者]；在 $I = 1$（局部参照）与 $I = 0$ 子集上分别报告的 QWK、MAE 与 ± 1 准确率见表 **??**。局部单元上 A 与 L 的取整差异比例为 [值]，两种参照来源的尺度一致性可接受。交付的

250 款 × 50 维评分以热力图呈现（图 ??），典型啤酒的预测感官画像与附件 4 观测高度吻合（图 ??）。

6.4.3 外部检查

公开验证数据的两款基础啤酒与附件 8 校准化学数据在取整精度内唯一匹配（标准化对数距离 0.07 与 0.06，次优匹配 0.42 与 9.08），提供 92 个实测 0–6 原始评分。将两款啤酒的折外预测按选定映射转为等级与实测均值比较：预运行中有锚维度平均误差 -0.47（$m = 3$）、无锚 C-mid 的 MAE 为 0.49–0.58，且两款啤酒的差异在 8 个属性中 7 个符号一致，表明“化学 $\to z \to$ 0–6”全链路在外部数据上方向正确；正式运行以选定映射重新报告该检查。

6.4.4 敏感性结果

NA 的三种口径（均值填充/原生 NaN/最低位并列加指示）、$m \in \{2.5, 3, \min(4, \mathrm{cap}_d)\}$、无锚维度的 C-mid 与 C-quantile 约定逐一扰动：Spearman 类结论不随 NA 口径与 m 改变（秩指标不依赖换算假设）；m 在 3 与 4 之间时 22% 的有锚等级变动一级，故 0–6 数值结论以 $m = 3$ 为准并附区间；无锚维度的数值在两种约定间的变化如实报告，其评分仅作排序解释。零点可疑（7 维）与零点脆弱（来自单一品评团，4 维）的维度另以 C-mid 作局部参照的敏感性运行。

问题一最终交付：250 款 × 50 维的 0–6 等级、等级概率与 90% 区间；推断品评团、零点表与 `at_zero` 掩码交付问题二；全数据重拟合的正向模型 f_d 交付问题三作为生成结果的感官评估器。

7 问题二模型的建立与求解

7.1 问题分析

问题二要求利用附件 2 构建化合物共表达图，结合附件 1 的化学特征给出每个感官维度的 Top-3 关键化合物，并论证其稳定性与化学合理性。核心难点有三：其一，化合物间强共变（附件 2 中 $|\rho| \geq 0.5$ 的边达 597 条），若直接按边际相关取前 3，同一信息会以多个高度相关化合物的形式重复入选；其二，250 款啤酒分属 63 个品评团，同团样本共享评分零点且多为同一风格，稳定性检验必须以品评团为单位；其三，关键化合物为关联性结论，须以数据证据（显著性、入选频率、方法间一致性）与酿造化学机理（来源、气味阈值、加标实验）双线论证。

据此确定技术路线：以附件 2 构建共表达图并划分模块，实现冗余控制；在图约束下以偏秩相关前向选择逐位确定 Top-3；以品评团簇 bootstrap 入选频率与多方法 Jaccard 系数量化稳定性；以附件 8 标签、OAV 阈值证据与外部加标实验完成化学合理性论证。流程如图 ??。

7.2 模型建立

7.2.1 候选集合与秩变换

候选集合 $\mathcal{C}$ 为附件 1 的 231 列扣除 5 个综合指标与 1 个内标，$|\mathcal{C}| = 225$。综合指标由其他化合物计算得到，各自几乎是某一成分的副本（如 `aroma_hops_sum` 与 linalool 的 $|\rho| = 0.96$），保留将使同一信息两次入选；内标反映测量过程而非啤酒组成。二者仍作为图的注释节点保留。理化指标（pH、IBU、color 等）保留为候选，它们是 acidity、bitterness 等维度最直接的解释量。

全部关联基于秩：157 个信号列的变换方式未知，秩不受单调变换影响；附件 2 本身为 Spearman 矩阵，关联与图同度量；检出下限的并列底值自然成为并列秩。化学 NA 按列均值填充，仅作计算占位；感官目标取附件 4 标准化均值 z_{bd} 的秩，与问题一 0–6 评分互为单调变换，结论不依赖换算假设。

7.2.2 共表达图与模块

共表达图 G_τ 以 231 列为节点，边权 $w_{jk} = |\rho_{jk}|$， $|\rho_{jk}| \geq \tau$ 时连边，符号作边属性。取无符号权重： $|\rho| \geq 0.5$ 的 597 条边中仅 13 条为负，且负相关在冗余意义上与正相关等价。模块由相异度 $1 - |\rho|$ 上的平均连接层次聚类在高度 $1 - \tau$ 处切割得到，保证模块内平均相关不低于 τ；相比之下，连通分量会被弱链串联（$\tau = 0.6$ 时最大分量含 96 个化合物）， Louvain 需另选分辨率参数且随种子变化，偏相关网络因附件 2 非半正定（5 个负特征值）不可行。

阈值主值取 $\tau = 0.6$，为候选间 $|\rho|$ 的 99% 分位：此时 245 条边构成 33 个多成员模块，来源纯度 0.79，bootstrap 下模块划分 ARI 中位 0.76，均优于 $\tau = 0.5$（纯度 0.70、ARI 0.66）；$\tau = 0.7$ 时模块仅覆盖 65 个化合物，冗余控制范围过窄。模块约束设定：同模块化合物在 250 款啤酒上无法被数据区分为不同的关键因素，故每模块在 T_d 中至多一席，其余成员作为同模块化合物随入选者一并报告。

7.2.3 图约束前向选择

对维度 d，第 1 位取边际秩关联最强者：

$$t_{d1} = \arg\max_{j \in \mathcal{C}} |r_{jd}|, \qquad r_{jd} = \tfrac{1}{n} \tilde{x}_j^\top \tilde{y}_d. \tag{11}$$

第 k 位（$k = 2, 3$）记已选集合 S，H_S 为向 $\mathrm{span}\{\mathbf{1}, \tilde{x}_s : s \in S\}$ 的投影，

$$r_{jd|S} = \frac{e_j^\top e_y}{\|e_j\| \, \|e_y\|}, \qquad e_y = (I - H_S)\tilde{y}_d, \; e_j = (I - H_S)\tilde{x}_j, \tag{12}$$

$$t_{dk} = \arg \max_{j \in \mathcal{C}, \; M(j) \notin M(S)} |r_{jd|S}|. \tag{13}$$

偏秩相关衡量化合物在已选者之外还能解释多少维度排序；模块约束 $M(j) \notin M(S)$ 排除与已选者同模块的冗余化合物。

显著性门槛 q_d 取 $\max_j |r_{jd}|$ 置换零分布（打乱 $\tilde{y}_d$ 1,000 次，每次在 225 个候选上取最大值）的 95% 分位，控制维度内多重比较；第 2、3 位用 Freedman–Lane 置换。入选项同时满足得分超过 q_d 且品评团簇 bootstrap 的 95% CI 不含 0 时记为显著。由此定义维度等级：A 级（Top-1 显著且入选频率 $\pi^c \geq 0.6$）、 B 级（Top-1 显著）、C 级（Top-1 不显著，记为未找到可靠关键化合物）。

7.2.4 稳定性度量模型

稳定性从两个正交方向量化。**数据扰动**：以品评团为单位有放回抽取 63 个团，每次重算相关矩阵、重建模块、重跑选择，$B = 1{,}000$；记化合物层入选频率 π^c_{jd}、模块层频率 π^m_{jd} 与 bootstrap Jaccard 均值 J^{boot}_d，分档为稳定（$\pi^c \geq 0.6$）、中等（$[1/3, 0.6)$）、不稳定（$< 1/3$）。**方法扰动**：与四个对照方法比较 Top-3 的 Jaccard 系数 $J(A,B) = |A \cap B|/|A \cup B|$——M0 无图约束边际选择、M1 图约束边际选择、M2 秩上 ElasticNet、M3 梯度提升树置换重要度，另加风格内分析（对 22 个风格指示变量取残差后重跑选择），随机 3 元集合的 Jaccard 期望 0.008 作为参照基线。

7.3 模型求解

求解流程为确定性算法，全程种子固定：

Step 1 构图与模块：读入附件 2，复算验收（与附件 1 逐对 Spearman 最大差 6.7×10^{-16}），层次聚类切割得模块表、节点表（含模块内连接度 k^{in}_j 与枢纽）与边表。

Step 2 选择规则验证：在真实化学矩阵上随机植入 3 个异模块化合物、按秩线性组合加噪声生成伪维度，每设置 200 次，比较前向与边际选择的找回率（表 **??**）。前向选择在效应量 $r \geq 0.3$ 时全面占优；观测数据 49 维 Top-1 的 $|r|$ 中位数 0.36，处于该区间，确定前向选择为主方法。模拟仅使用化学矩阵与人工目标。

Step 3 主运行：对 49 个维度执行前向选择与置换检验，产出 Top-3、选择得分、显著性与维度等级。

Step 4 稳定性运行：$B = 1{,}000$ 品评团簇 bootstrap 与五个对照方法，产出 π^c、π^m、J^{boot} 与方法间 Jaccard。

Step 5 化学证据汇总：关联附件 8 的来源、缺陷与老化标签；对有阈值的化合物计算 OAV≥ 1 的啤酒比例；标注共变标记（风格内 CI 含 0、进入 ≥ 5 个维度、或全部啤酒 OAV< 1）；逐项撰写机理解释并核对入选符号。

Step 6 敏感性运行：$\tau \in \{0.5, 0.7\}$、候选集加回排除列、NA 两种对照口径、固定附件 2 构图、按单款啤酒重抽、39 个有锚维度改用减零点评分，共 7 组，各报告与基线的 Jaccard 及 Top-1 改变维度数。

7.4 结果分析

7.4.1 共表达图结构

$\tau = 0.6$ 下 245 条边构成 33 个多成员模块，覆盖 97 个化合物，代表性模块与酿造学知识吻合：ethanol–ethyl acetate–ethyl hexanoate–glycerol（发酵强度轴）、 isoamyl acetate–isobutyl acetate–n-hexanol（乙酸酯类）、 ethyl octanoate–ethyl decanoate（中链脂肪酸乙酯）、 color–protein（麦芽轴）、linalool–α-terpineol（酒花萜类）。模块的来源纯度 0.79，即强共变主要发生在同一酿造来源的化合物之间，图 **??** 中同色节点聚为同圈的格局直观反映了这一点。

7.4.2 Top-3 识别结果

49 个维度中，Top-1 显著 47 个，第 2、3 位显著分别为 37、20 个；置换门槛 q_d 中位数 0.227，Top-1 的 $|r|$ 中位数 0.36。代表性结果与酿造化学一致：bitterness 的 Top-1 为 IBU，acidity 为 pH，esters_all 为 isoamyl acetate，body 为 ethanol（同模块含 glycerol）。A_esters_flower 与 t2n 两维 Top-1 未超门槛，列为 C 级。全部 49 维的 Top-3、得分、CI 与等级见附录表 **??**。

风格内分析显示：147 个入选项中 98% 在风格内保持同号，其中 18 项风格内 $|r^{(s)}| < 0.1$——如 lactic acid $\rightarrow$ lactic（合并 0.45，风格内 -0.00）、pH $\rightarrow$ acidity（-0.50，-0.09），其关联来自酸啤风格与其他风格之间的配方差异，已标注共变标记；风格内 Top-3 作为次要输出交付问题三。

7.4.3 稳定性结果

品评团簇 bootstrap 下，按位置的化合物层入选频率为 0.56、0.35、 0.19，模块层为 0.62、0.40、0.21；J^{boot} 均值 0.267，为随机基线 0.008 的 33 倍。147 个入选项中稳定 28 项、中等 41 项、不稳定 78 项（图 **??**）。结合植入实验的找回率标尺（真实效应 $r \approx 0.3$、排第 3 位的化合物在 0.2–0.7 的重复中被找回），结论为：在 250 款啤酒的样本量下，多数维度可靠支持的关键化合物为 1 个、至多 2 个，第 3 位以报告为主。模块层频率高于化合物层的差值即同模块化合物间的轮换，印证了模块不可分设定。

方法间 Jaccard 见表 **??** 与图 **??**。线性族方法与主方法 Top-1 完全一致（M0、M1 为 1.00，M2 为 0.63），表明第 1 位结论对估计方式不敏感；M0 有 22/49 维的前 3 含同模块冗余（如 A_malt_all 的 color 与 protein），正是图约束消除的对象。M3 允许非线性后 Top-1 一致比例降至 0.37（如 metallic 的 M3 Top-1 为 iron），此类维度并列报告两法结果并各附化学解释。

7.4.4 化学合理性结果

有阈值的 26 个入选化合物中，ethanol（0.98）、linalool（0.98）、citronellol（0.92）、IBU（0.86）、isoamyl acetate（0.84）、 geraniol（0.76）、DMS（0.67）、ethyl acetate（0.66）、acetic acid（0.62）在多数啤酒中 OAV≥ 1，其感官作用有直接的浓度基础（图

??）；acetaldehyde、ethyl decanoate、furfural 等 5 个化合物在全部啤酒中 OAV<1，标为共变标记，其入选反映与未测或同模块化合物的共变，亚阈值酯类的加和效应亦为已知现象。进入 ≥ 5 个维度 Top-3 的 color、ethanol、protein 等 7 个候选标记工艺与风格强度轴。

外部加标实验提供因果方向的核验（表 ??）：七种化合物混合加标在三组底酒中均显著提高 Esters（配对差 0.90–1.31，$t \geq 2.9$），支持酯类作为 esters_all 关键因素；未加入酒花化合物时 Hops 与 Bitterness 不变（$|t| \leq 0.9$），构成阴性对照，排除加标杯整体抬分的可能；Fullness 在无乙醇组同样提高，表明 glycerol 等同模块成分足以产生醇厚感。

7.4.5 敏感性结果

七组敏感性运行中，Top-3 与基线的化合物层 Jaccard 均值、Top-1 改变维度数汇总于附录表 ??。化合物层入选频率在 $\tau \in \{0.5, 0.6, 0.7\}$ 下完全相同，阈值仅影响模块层解读； NA 口径与 bootstrap 单位的扰动均未改变 A 级维度的 Top-1。结论对建模选择稳健。

问题二最终向问题三交付三项结果：模块表（同模块化合物在生成时应一起变化，综合指标由成分推导）、风格内 Top-3，以及缺陷维度（DMS、4VG、diacetyl、t2n、stale hops）的关键化合物清单。

8 问题三模型建立与求解

8.1 条件生成模型原理

选用适合表格数据条件生成模型（如CTGAN等），将啤酒细分风格标签tasting_category_fine作为条件输入，学习不同风格啤酒化合物谱分布。

8.2 风味指纹生成模块构建

输入指定啤酒风格标签（Tripel、Kriek、Lambic），模型输出该风格对应的全套化合物谱，再通过问题一训练好的感官评分模型，得到该风格的感官画像。

8.3 带约束跨风格迁移模块构建

目标：将Pils/Lager样本化合物谱迁移至Tripel风格；硬性约束：DMS、Diacetyl、4VG、trans-2-nonenal、Stale hops缺陷化合物指标不能恶化，在生成损失函数增加约束项，保证缺陷指标满足条件。

8.4 结果评估与分析

评估生成化合物谱分布是否符合真实样本分布，对比迁移前后风味变化与缺陷化合物指标，可视化不同风格风味指纹。

9 模型评价

9.1 模型优点

9.2 模型不足

9.3 灵敏度与鲁棒性分析

10 参考文献

参考文献

[1] 啤酒风味物质代谢相关文献

[2] 共表达网络构建相关文献

[3] 表格数据条件生成模型相关文献

11 附录

附录放置Python核心代码、补充图表、额外实验结果。