2026 年 MathorCup 数学应用挑战赛（A 题）

啤酒酿造化合物分析与风味预测

第五章 数据预处理

5 数据预处理

建模之前，首先对 8 个附件的规模、标识列与取值口径做统一核查，并完成缺失值填充、异常值判定、对数底数核验与评分量纲还原四项工作。本章的全部数值均由原始附件直接统计得到，未引入任何外部数据。

5.1 数据概览与一致性核查

本赛题提供的附件涵盖化合物丰度、化合物间相关性、感官记分卡、标准化感官面板与理化参数等多个层面，其规模与缺失情况如表 1 所示。

表 1: 各附件数据概览与缺失情况

附件	内容	规模（样本 × 列）	有效测量变量	缺失单元格	缺失率
1 (`1.csv`)	化合物丰度矩阵	250×234	231	73	0.125%
2 (`2.csv`)	化合物相关矩阵	231×232	231	0	0
3 (`3.xlsx`)	感官记分卡	12 张记分卡	50	—	—
4 (`4.csv`)	标准化感官评分	250×53	50	0	0
7 (`7.csv`)	感官属性面板	250×189	183	750	1.59%

核查中有三点需专门说明。

第一，样本量口径。题面正文提及 “226 种啤酒”，但实测附件 1、附件 4、附件 7 的样本行数均为 250。两者不一致，且无法由数据本身调和，故本研究一律以实测的 $n = 250$ 为准，并在全文保持该口径；题面数字仅在讨论中提及，不参与任何计算。

第二，变量列数口径。附件 1 共 234 列，剔除 `beer`、`beer_id` 与 `tasting_category_fine` 三个标识/分类列后，有效测量变量为 231 个；附件 2 的相关性矩阵恰为 231×231，与之**完全对应**。这说明两份附件的变量口径一致，可直接联用而无需对齐映射——附件 2 的行序与附件 1 的测量列序一一对应，是后续构建共表达网络的前提。

第三，附件 7 的列构成。189 列中，3 列为标识与风格标签，另有 3 列为全空列（详见缺失值填充一小节），故有效测量变量为 183 个，全部为数值型感官属性。此外，附件 3 汇总表所列的 50 个感官变量与附件 4 的 50 个数值列**一一对应**：前者给出 0–6 原始记分及其记分规则，后者为 250 个样本的标准化面板，二者共同构成问题一的目标变量。

5.2 缺失值填充

5.2.1 缺失情况的定位

对主要数值附件逐单元格扫描，得到附件 1 的 73 个空值集中于 9 个化合物变量，明细见表 2 与图 1。

表 2: 附件 1 中存在缺失的化合物变量

变量	缺失个数	占 250 个样本的比例
amyl.acetate	27	10.8%
aroma_hops_sum	13	5.2%
methylpyrazine	12	4.8%
X2.3.butanedione	9	3.6%
X3.methylbutanal	7	2.8%
ethyl.nicotinate	2	0.8%
ethyl.isobutyrate	1	0.4%
furfural	1	0.4%
phenylacetaldehyde	1	0.4%
合计	73	—

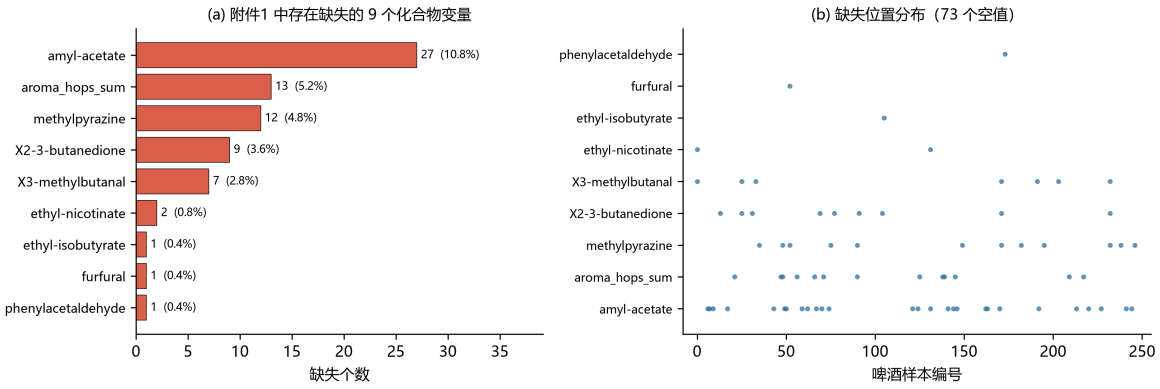


图 1: 附件 1 缺失值分布

图 1(b) 显示，缺失位置沿样本轴近似均匀散布，未出现按样本成片缺失或按变量成段缺失的情形。这说明缺失并非由某一批次测量整体失败引起，而更接近逐次进样的偶发失效。该观

察支持“逐变量建模填补”而非“整行删除”的策略：若删除含缺失的样本，仅 `amyl.acetate` 一项即损失 27 个样本点，且缺失集中在特定样本区间，会造成风格分布偏移。

5.2.2 附件 7 的全空列处理

附件 7 的 `palate_acetaldehyde`、`palate_acetate`、`palate_dentist` 三个列在全部 250 个样本上均为空（各 250 个 NA，合计 750 个）。对缺失率达 100% 的变量，任何插补算法都只能凭空生成数据，其输出完全由模型先验决定而不含任何观测信息。因此本研究**直接剔除**这三个列，不纳入后续建模，并在结果讨论中注明。

5.2.3 填补模型：浅层梯度提升树

题面要求“从化学成分出发还原 0–6 评分”，因此缺失填补不应是孤立的统计插值，而应与下游的“化学成分 $\rightarrow$ 评分”映射共用同一套函数形式。为此，本研究以浅层梯度提升树作为填补模型。

设第 j 个存在缺失的变量，其完整观测样本集为 $\mathcal{O}_j$，缺失样本集为 $\mathcal{M}_j$。以化学成分为输入 $\mathbf{x}_i \in \mathbb{R}^p$、标准化评分为目标，第 m 轮的浅层回归树为 f_m，学习率为 η，则缺失位置的预测值为

$$\hat{y}_i^{(j)} \;=\; \sum_{m=1}^{M} \eta\, f_m(\mathbf{x}_i), \qquad i \in \mathcal{M}_j. \tag{1}$$

式 (1) 的意义在于：该提升树一旦训练完成，即成为一个以化学成分为输入、标准化评分为输出的显式函数，既可用于补齐附件 1 的 73 个空值，也可用于预测题面所要求的缺失评分，两者共用同一套参数，避免了“插补模型”与“预测模型”口径不一致的问题。

选择“浅层”（树深 $d \le 3$）而非深树，基于三点考虑：

1. 本数据 $n = 250$ 而 $p \approx 233$，样本量远小于特征数，深树极易记忆训练样本。限制树深相当于对模型复杂度施加显式正则。
2. 附件 2 表明化合物之间存在显著共线性。线性插补（如回归插补、MICE 的线性条件模型）在共线设计下方差会被放大；树模型按特征逐一贪心切分，对共线性不敏感。
3. 化合物与感官评分之间多为**阈值型**关系——浓度越过感知阈值后评分才上升。树的阶梯函数形式比线性形式更贴合这一物理机制。

为防止信息泄漏，式 (1) 的提升树在**每一个交叉验证折内重新拟合**：先在训练折上训练，再对验证折的缺失位置做预测；在全量数据上拟合的填补器不得用于任何评估环节。

5.3 异常值的检测与处理

5.3.1 量纲归一与朴素判据

附件 4 与附件 7 的变量取值区间差异极大，直接比较绝对偏差没有意义。参照通行做法，先做 Min–Max 归一化：

$$X' = \frac{X - X_{\min}}{X_{\max} - X_{\min}}, \tag{2}$$

其中 X 为原始数据，X' 为归一化数据，$X_{\min}$、$X_{\max}$ 分别为该变量的最小值与最大值。随后用 Tukey 的 1.5 倍四分位距规则初筛，即

$$x_i \text{ 判为异常} \iff x_i \notin \left[Q_1 - 1.5\,\mathrm{IQR},\ Q_3 + 1.5\,\mathrm{IQR}\right], \qquad \mathrm{IQR} = Q_3 - Q_1. \tag{3}$$

初筛结果见表 3。

表 3: 朴素 Tukey 规则的初筛结果（已剔除标识列）

数据表	数值列数	被标记样本数	标记率	IQR = 0 的列数	退化列占比
附件 4	50	693	5.54%	0	0
附件 7	183	3899	8.52%	59	32.24%

5.3.2 朴素判据的失效及其原因

初筛结果暴露出一个必须处理的问题：附件 7 的 183 个数值型感官维度中，有 59 个（32.24%）满足 $Q_1 = Q_3$，即 IQR = 0。

此时式 (3) 的区间退化为单点 $[Q_3, Q_3]$，任何不等于该点的取值都会被判为异常。而这 59 个维度的分布形态属于典型的**零膨胀**：183 个维度中有 177 个（96.7%）超过半数样本取地板值（对应 0–6 量表中的 “不存在”）。于是 $Q_1 = Q_3 = f_j$（地板值），而所有真正被评委打过分的样本全部落在区间之外，被整体标记为异常，见图 2。

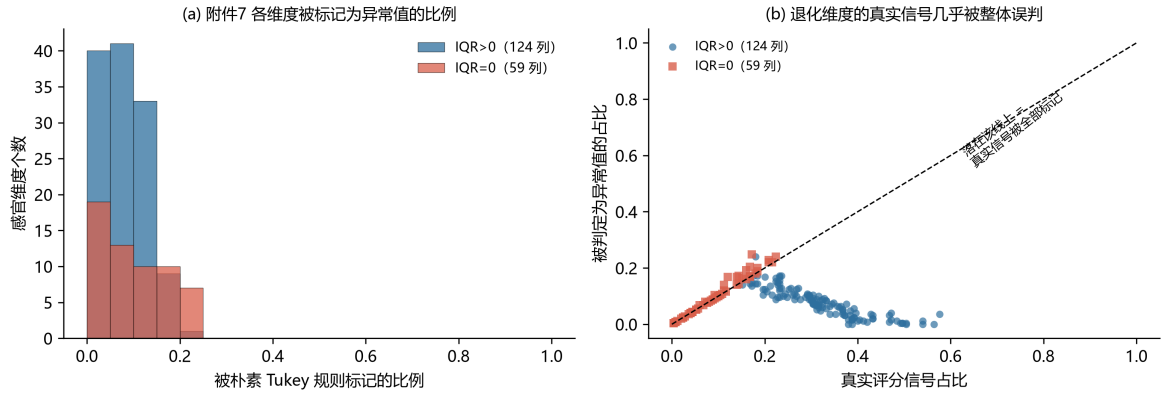


图 2: 附件 7 感官维度的异常值判定

图 2(b) 将 “真实评分信号占比” 与 “被判定异常的占比” 逐维度对照：59 个退化维度几乎全部落在对角线上，意味着**该维度有多少真实信号，就被误判多少异常**。这 59 个维度共含

14750 个样本，其中真实信号 1380 个（9.36%），而被判定为异常的达 1480 例——误判规模与真实信号规模相当。

这一现象说明，对本数据直接套用 “箱线图 + 中位数替换” 的常规流程会造成严重的信息破坏：被替换掉的恰恰是该维度唯一有效的观测。

5.3.3 地板感知的异常判定

为此，本研究提出地板感知判据。对每个维度 j，先识别地板值

$$f_j \;=\; \arg\min_{v} \; \#\big\{\, x_{ij} = v \,\big\}, \tag{4}$$

即出现频次最高的取值;再将样本划分为地板集合 $T_j = \{x_{ij} = f_j\}$ 与尾部集合 $S_j = \{x_{ij} > f_j\}$。地板集合对应 “0 分（不存在）”，属正常取值，不参与异常判定；仅在尾部集合内部识别真正的极端高值：

$$x_{ij} \text{ 判为异常} \iff x_{ij} \;>\; \mathrm{med}(S_j) + 3 \times 1.4826 \times \mathrm{MAD}(S_j), \tag{5}$$

其中 $\mathrm{MAD}(S_j)$ 为尾部集合的绝对中位差，系数 1.4826 使 MAD 在正态假设下与标准差等价。式 (5) 用中位数与 MAD 替代均值与标准差，以抵抗尾部自身极端值的影响。

对附件 4 的 50 个数值列（$Q_1 \neq Q_3$，判据未退化），朴素 Tukey 结果仍然有效，直接沿用。

5.3.4 处理方式：标记而不剔除

与常规做法不同，本研究对识别出的异常值**只做标记、不做替换或剔除**，理由有三：

1. 感官评价中的极端高分是有效信息。某款啤酒在 `amyl.acetate`、`4VG` 等维度上得高分，正是该样本的判别性特征，用中位数替换会抹掉这一信息。
2. 下游主模型为梯度提升树，其分裂准则基于特征排序而非取值大小，对异常值天然稳健，无需预先清洗。
3. 保留标记位可作为后续灵敏度分析的开关：分别在 “含异常” 与 “剔除异常” 两种口径下重跑问题一模型，若结论一致，则说明结果不依赖于异常值处理方式，这比单次替换更有说服力。

5.4 对数底数核验与量纲统一

题面明确要求 “参与者需自行核实变换底数（$\log_{10}$ 或 $\ln$），并明确正负值与原始浓度的对应逻辑”。本研究采用**交叉核验法**：附件 1 与附件 8 对同一批化合物给出两组独立取值，若附件 1 存放的是 $z = \log_b c$，则应有 b^z 还原出附件 8 的浓度。对 37 个可交叉核验的化合物列，分别以三种假设反演并计算平均绝对误差，结果见表 4。

表 4: 附件 1 对数变换底数的判定（37 个化合物列）

假设底数	平均绝对误差 MAE	MAE 取值区间	判定
$\log_{10}$	2.48×10^{-10}	$[1.8 \times 10^{-10}, 2.81 \times 10^{-10}]$	**成立**
ln	1.37	[0.25, 2.97]	否
恒等变换	24.70	[0.92, 453.30]	否

结论明确：以 $\log_{10}$ 反演时误差为 2.48×10^{-10}，已达双精度浮点的舍入极限；以 ln 反演时误差为 1.37，相差十个数量级。故附件 1 的对数底为 $\log_{10}$。

由此，列中取值的正负含义为

$$z > 0 \Leftrightarrow c > 1, \qquad z = 0 \Leftrightarrow c = 1, \qquad z < 0 \Leftrightarrow 0 < c < 1. \tag{6}$$

负值**不代表“负浓度”**，而是浓度低于 1 个计量单位；各列计量单位（mg/L 与 μg/L）见附件 1 的列元数据。

5.4.1 检出限地板

进一步核验发现，231 个化合物列全部存在一个反复出现的最小取值，其中 26 列的地板效应足以影响建模。经检验，该值恒等于该列**最小检出正值的一半**（比值 $0.5 \pm 5 \times 10^{-10}$，覆盖全部 26 列）。这符合分析化学中对低于检出限样本的“半最小值”编码惯例。地板占比最高的若干化合物见表 5 与图 3。

表 5: 检出限地板效应显著的化合物

化合物	地板样本占比	唯一取值数	地板含义
CS2	83.6%	42	低于检出限
ethyl.2.methyl.butyrate	34.0%	163	低于检出限
ethyl.isovalerate	33.2%	166	低于检出限
DES	11.6%	222	低于检出限
ethyl.propionate	4.0%	238	低于检出限
H2S	4.0%	241	低于检出限
isobutanol	2.0%	246	低于检出限
acetaldehyde	0.4%	250	正常低值

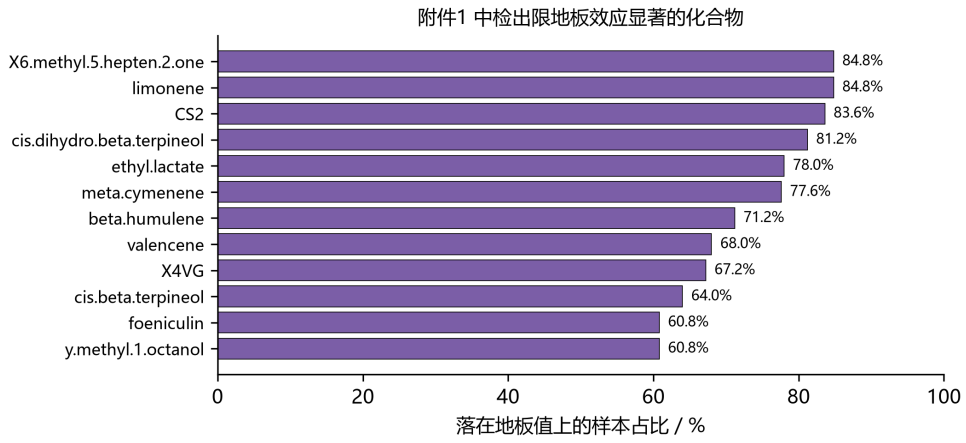


图 3: 附件 1 中检出限地板效应显著的化合物

231 个化合物列中有 79 列（34.2%）的地板样本占比达到 10% 以上。这一判定对后续建模有直接影响：地板值是**左删失数据**而非真实低浓度。若直接把它们当作连续观测参与相关性计算或回归拟合，会人为压低方差、抬高地板点与其它变量之间的虚假相关。因此本研究在问题二的相关性分析与问题三的生成建模中，对地板占比高的化合物单独处理，并在灵敏度分析中报告剔除地板点后的结果变化。

5.5 评分零点归一

附件 3 含 12 张按啤酒组织的感官记分卡与 1 张汇总表。每张记分卡在香气与口感两个区段各**预留** 6 个评委列（香气 E/G/I/K/M/O，口感 S/U/W/Y/AA/AC），量表锚点为 0（不存在）至 6（突出/压倒性），并在单元格中以 `ISBLANK` 嵌套公式自动统计各样本的有效评分人数。

不同评委存在系统性的**用分习惯**差异：有的倾向打极端分（集中于 0 与 6），有的倾向保守（集中于 2–4）。若直接对各评委评分求平均，这种 “用分尺度” 的差异会被误当作 “风味强度” 的差异，从而污染目标变量。

为此，本研究引入评委零点校正。设评委 r 被归入第 $g(r)$ 类（如 “极端型” 与 “保守型”），其评分零点 θ_g 定义为该类评委相对同一样本全体评委中位数的系统性偏移：

$$\theta_g \;=\; \operatorname{median}_{i,\, r\in g}\left(\, s_{ir} - \bar{s}_i \,\right), \tag{7}$$

其中 s_{ir} 为评委 r 对样本 i 的原始评分，$\bar{s}_i$ 为样本 i 的评委均值。校准评分为

$$\tilde{s}_{ir} \;=\; s_{ir} - \theta_{g(r)}. \tag{8}$$

式 (7) 用中位数而非均值估计零点，可避免个别极端评分主导偏移量。校准后各评委处于同一基准，再汇总并投影回量表范围：

$$\hat{s}_i \;=\; \Pi_{[0,6]}\left(\frac{1}{|R_i|}\sum_{r\in R_i}\tilde{s}_{ir}\right), \qquad \Pi_{[0,6]}(x)=\min\{6,\ \max\{0,\ x\}\}. \tag{9}$$

式 (9) 即为从标准化面板还原出的 0–6 实际打分。需要说明的是，评委的分类算法与零点的联合估计涉及迭代求解，属于问题一模型的组成部分，其完整推导见问题一模型的建立与求解一节；本节仅完成数据侧的口径统一与量纲还原。

5.6 数据预处理流程

综合上述步骤，本研究的数据预处理流程如图 4 所示：先做数据概览与一致性核查，再分两条支路并行处理缺失值与异常值，随后统一量纲并核验对数底数，最后完成评分零点归一，输出可直接用于问题一至问题三建模的洁净数据集。

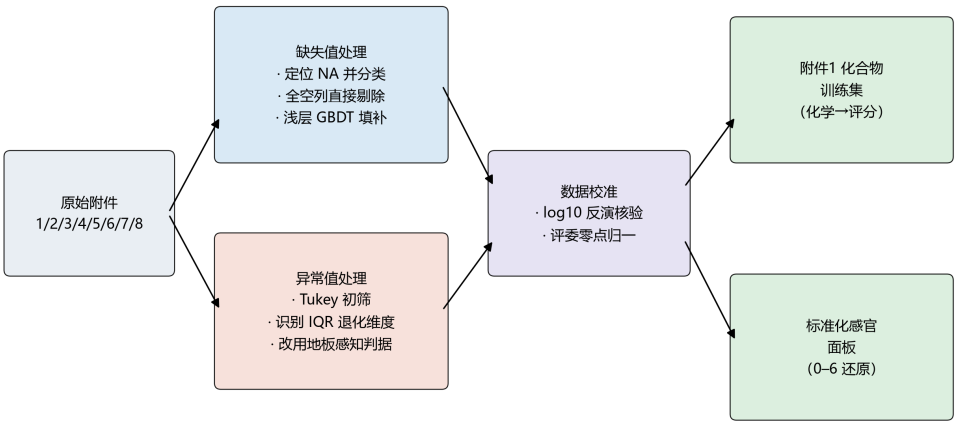


图5 数据预处理总体流程

图 4: 数据预处理总体流程