啤酒化学数据与感官评分

数据预处理

3　数据预处理

本研究先确定样本、变量和评分的含义，再分别构造三个问题的输入。化学缺失值填充属于特征预处理；没有品评记录的新啤酒的评分则属于问题一的预测任务。凡涉及模型拟合的变换均在训练折内估计，再作用于验证折。

3.1　数据来源、样本对齐与感官目标

附件 1 含 250 款啤酒、231 个化学及理化特征；题面所称的 226 是化学参数数量的误读，样本量以附件实测行数为准。附件 2 为这些特征的相关矩阵，附件 3 定义感官记分卡，附件 4 给出 250 款啤酒的 50 维标准化品评小组均值。附件 8 提供部分化合物的校准浓度、气味阈值及来源标签。附件 5、6 只作相关结构核对，附件 7 为另一套描述符，不与附件 3 的 50 维评分合并。

附件 1–8 与 Schreurs 等人在 *Nature Communications* 发表的数据记录（Zenodo 10653704）对应。作者后来在同一数据记录的新版（Zenodo 23624915）公布逐品评员原始评分，覆盖相同的 250 款啤酒。该文件在赛题发布后公布，本文明确披露其来源；问题一另设仅使用附件的完整对照，以展示没有该文件时的结果。

原始评分共 2197 条记录，来自 16 名品评员和 37 个品评日期；50 个维度均为 0–6 的整数且无缺失。原始文件中的 `beer_name` 对应附件 1、4 的行号，并非附件的 `beer` 列。以行号对齐后，原始品评小组均分与附件 4 逐维 Spearman 相关系数的中位数为 0.969；错误地按 `beer` 列对齐时为 -0.010。因此对齐检查先于任何建模。

设 $\mathcal{R}_b$ 为啤酒 b 的全部原始评分记录，x_{id} 为记录 i 在感官维度 d 的分数，则

$$\bar{x}_{bd} = \frac{1}{|\mathcal{R}_b|} \sum_{i \in \mathcal{R}_b} x_{id}, \qquad G_{bd} = \lfloor \min\{6, \max\{0, \bar{x}_{bd}\}\} + 0.5 \rfloor . \tag{1}$$

同一啤酒即使在多个日期接受品评，也只形成一个啤酒层面的目标。附件 3 汇总表与原始记录共有 50 个可用维度；模板中另有乙醛属性，但原始评分和附件 4 均无对应列，故不生成该属性的预测。

附件 4 是原始评分按“品评员 × 维度”标准化后再按啤酒汇总的结果。按这一规则可在 12500 个单元中复现 11274 个（90.2%，误差中位数 2.8×10^{-10}）。其余单元集中于 12 个维度，

涉及标准差为零的品评员–维度组合，发布数据中的处理常数尚未识别。标准化去掉了原始 0–6 量表的位置和尺度，仅凭附件 4 不能唯一恢复原始等级。因此主分析直接以式 (1)为目标；附件 4 只用于数据核对、仅用附件的对照和问题二的敏感性分析。

3.2 化学特征的尺度与缺失

附件 1 的 231 列不能一律解释为浓度。将其中可对齐的 70 列与附件 8 的校准数据逐列比较，37 列在正浓度处满足 $x = \log_{10} c$，33 列在列级中位残差意义下保持线性尺度。后者仍有 80 个单元与附件 8 不一致，分布于 24 款啤酒；主分析以附件 1 为准，附件 8 替换值只作敏感性运行。其余 157 列是未经绝对浓度校准的气相色谱–质谱信号，另有 4 列为 `_sum` 综合指标。表 1 给出四类变量的处理。

表 1: 附件 1 化学及理化特征的尺度判定与使用口径

类别	列数	证据与解释	建模处理
校准对数列	37	$\lvert x - \log_{10} c\rvert$ 的逐列中位数小于 10^{-6}；自然对数不符	需要浓度时用 10^x
校准线性列	33	$\lvert x - c\rvert$ 的逐列中位数小于 10^{-6}，但部分单元不一致	保留附件 1 原值
未校准色谱–质谱信号	157	无逐列底数和绝对浓度证据；共同下限按未检出状态解释	保留发布值及其秩
综合指标	4	组成与计算公式未提供	保留特征，不反变换

对 37 个已校准对数列，$x < 0$ 只表示 $0 < c < 1$ 个该列的计量单位，并非负浓度。对 157 个未校准信号列，将其按常用对数相对峰面积解释是*尺度假设*，不是从附件逐列证实的事实；不能用 10^x 声称恢复绝对浓度。主树模型直接使用发布值，不再取一次对数。单调尺度变换不改变树的分裂顺序。

附件 1 的 $250 \times 231 = 57750$ 个特征单元有 73 个空值（0.126%），集中于 9 列和 63 款啤酒；删去这些啤酒将损失 25.2% 的样本。附件 8 在 8 个单化合物的 60 个空值位置记录为零，但跨附件的编码差异不足以证明这些空值必然低于检出限。主设定逐列使用*训练折非缺失观测的均值*填充，作为计算占位值，不赋予其真实浓度含义。内层与外层交叉验证均独立计算填充值。以训练折中位数加缺失指示、模型原生缺失路由，以及单化合物最低位编码作为敏感性对照。

另有 142 个未校准信号列共享下限 -1.81781854，涉及 6807 个单元。本文把该值作为未检出状态并赋予最低秩；现有材料不能确认其仪器检出限或替代流程，因此不把它解释成精确峰面积。极端化学取值和罕见的感官高分均保留原值，不以箱线图规则删除。对异常值的敏感性在具体模型中检验，避免预处理阶段先行抹去可能有意义的风味差异。

3.3 三项任务的数据表示与验证单位

问题一以 231 个特征预测式 (1)的品评小组均分，再由预测分布得到 0–6 等级。37 个品评日期因 12 款跨日期品评的啤酒相连，合并成 25 个日期组；交叉验证按日期组隔离，同一日期的品评情境不跨训练与测试两侧。

问题二将 231 列中的 5 个综合指标和 1 个内标排除，留下 225 个单体化合物候选。附件 2 提供共表达关系；化学特征及 $\bar{x}_{bd}$ 均转为秩，以免不同单位和尾部取值支配关联。`barnyard` 与 `stale_hops` 的原始记录有 99.4% 相同：前者仍可预测，但不单独做化合物归因。稳定性重抽以 25 个日期组为单位。

问题三以同一 225 列建立风格条件生成模型。未检出下限视为并列的离散状态，变换及反变换均在训练折内确定；综合指标由生成化合物另行派生，内标不作为生成对象。风格条件来自附件的细分风格标签。生成器用按风格分层的留出啤酒验证化学分布；涉及感官画像时另用问题一的日期组划分，避免借助同一品评情境评估自身。

图 1 汇总了数据核验、尺度处理与三个问题的接口。图中的数量是数据检查结果，模型效果由各问题的留出实验另行报告。



图 1: 数据来源、预处理决定与三个问题的输入输出。图内“原始评分”指作者在同一数据记录新版公布的逐品评员 0–6 分记录。